



Segmentación de la invasión por vegetación a líneas de transmisión eléctrica usando aprendizaje profundo en imágenes de drone

Mateo Cano Solis

Universidad Nacional de Colombia
Facultad de Minas
Medellín, Colombia
2024

Segmentación de la invasión por vegetación a líneas de transmisión eléctrica usando aprendizaje profundo en imágenes de drone

Mateo Cano Solis

Tesis presentada como requisito parcial para optar al título de:
Magister en Ingeniería - Analítica

Directores:

John Robert Ballesteros Parra
John Willian Branch Bedoya

Universidad Nacional de Colombia
Facultad de Minas
Medellín, Colombia
2024

Agradecimientos

Agradezco sinceramente a mis tutores, cuyo apoyo y orientación han sido fundamentales para el desarrollo de este trabajo. Sus ideas y amplio conocimiento han sido una inspiración constante y me han permitido construir una sólida base para este proyecto.

También quiero expresar mi gratitud a la Universidad Nacional de Colombia por brindarme esta invaluable oportunidad de aprendizaje y crecimiento. Esta institución ha sido el escenario perfecto para emprender un apasionante viaje del conocimiento, permitiendo expandir mis horizontes y descubrir nuevos caminos académicos.

Asimismo, quiero destacar el papel fundamental del Grupo de Investigación GIDIA de la Universidad Nacional de Colombia. Su compromiso con la excelencia académica y la innovación ha sido un referente en mi formación. Gracias a su labor, he tenido acceso a recursos, experiencias y colaboraciones que han enriquecido enormemente mi proceso de aprendizaje y me han motivado a seguir creciendo como profesional.

Resumen

Segmentación de la invasión por vegetación a líneas de transmisión eléctrica usando aprendizaje profundo en imágenes de drone

El trabajo de tesis se enfoca en abordar el problema de los cortes de energía en líneas de transmisión eléctrica debido a la invasión de vegetación. Se propone un enfoque basado en el uso de imágenes de drones y técnicas de aprendizaje profundo para anticipar y detectar la presencia de vegetación en estas líneas. El objetivo general es desarrollar un flujo de trabajo que permita segmentar áreas invadidas por vegetación, mediante la creación de un conjunto de datos público de imágenes de drones, la preparación y fusión de datos, y la selección de una arquitectura de aprendizaje profundo para la detección.

El método propuesto se presenta como una alternativa más eficiente y confiable en comparación con los métodos tradicionales de revisión manual en campo. El enfoque busca proporcionar una herramienta efectiva para la detección temprana de invasión de vegetación, contribuyendo así a mejorar la calidad y confiabilidad del suministro eléctrico y reduciendo los costos asociados a los cortes de energía generados por este problema.

Palabras clave: GeoAI, Drones, Invasión por vegetación, Líneas eléctricas, Aprendizaje profundo, Segmentación, Inteligencia artificial, Aprendizaje automático

Abstract

Segmentation of vegetation encroachment on electrical transmission lines using deep learning on drone images

The thesis work focuses on addressing the issue of power outages in electrical transmission lines caused by vegetation encroachment. An approach is proposed that relies on drone imagery and deep learning techniques to anticipate and detect vegetation invasion in these lines. The overall objective is to develop a workflow that allows for the segmentation of vegetation-invaded areas, achieved through the creation of a public dataset of drone images, data preparation and fusion strategies, and the selection of a deep learning architecture for detection.

The proposed method is presented as a more efficient and reliable alternative compared to traditional manual field inspection methods. The approach aims to provide an effective tool for early detection of vegetation encroachment, thereby contributing to enhancing the quality and reliability of the electrical power supply and reducing costs associated with power outages caused by this problem.

Keywords: GeoAI, UAV, Vegetation encroachment, Power lines, Deep learning, Semantic segmentation, Artificial intelligence, Machine learning

Contenido

1. Introducción	10
1.1. Motivación	10
1.2. Preguntas de investigación	11
1.3. Objetivos	12
1.3.1. Objetivo general	12
1.3.2. Objetivos específicos	12
1.4. Estructura	12
2. Marco teórico de referencia	13
3. Revisión sistemática de la literatura	16
3.1. Diseño de la Búsqueda	16
3.2. Resultados y discusiones	16
4. Segmentación de la invasión por vegetación a líneas de transmisión eléctrica usando aprendizaje profundo en imágenes de drone	21
4.1. Creación del conjunto de datos	21
4.2. Implementación de Estrategias de Preparación de Datos	24
4.2.1. Adquisición y procesamiento de datos	24
4.2.2. Etiquetado de datos	25
4.2.3. Teselación de datos y verificación de desequilibrio de clases	27
4.2.4. Aumentación de datos	28
4.3. Selección de arquitectura de aprendizaje profundo para segmentar la invasión por vegetación en líneas eléctricas	30
4.3.1. Exploración de la Arquitectura de Aprendizaje Profundo y Funciones de Pérdida	30
4.3.2. Estrategia de Entrenamiento para la arquitectura de aprendizaje profundo	33
4.3.3. Resultados de la etapa de entrenamiento	34
4.3.4. Evaluación del rendimiento de las arquitecturas entrenadas para la segmentación semántica.	35
5. Creación de flujo de automatización de segmentación de vegetación en líneas eléctricas	39
6. Conclusiones	41
Referencias	42

1. Introducción

Los efectos de los cortes de energía son un gran problema para las sociedades modernas debido a su amplia necesidad de dispositivos y equipos electrónicos, esto genera un reto para las compañías de transmisión de energía eléctrica debido a su obligación de brindar un servicio confiable [1]. En el proceso de transmisión existen diferentes retos para garantizar la confiabilidad, uno de estos es en las líneas de transmisión elevadas, en donde es recurrente afectaciones relacionadas a invasión por vegetación en las líneas de transmisión y en elementos como conductores [2]. El impacto de este tipo de problemas puede generar pérdidas millonarias para las empresas de distribución y para empresas que dependen directamente de la energía en su proceso productivo.

Anticipar la invasión por vegetación en las líneas de transmisión de energía es un reto a nivel empresarial (y en algunos casos gubernamental), por esto a nivel académico se ha vuelto un tema en donde se han desarrollado diferentes investigaciones que involucran el uso de imágenes satelitales, aéreas y recientemente de drones con apoyo en técnicas estereográficas y de aprendizaje profundo, buscando automatizar la tarea de revisión manual que se debe realizar en la actualidad a través de recorridos en campo [1]. Debido a los bajos costos, a la facilidad de uso y la rapidez, el uso de drones se ha convertido en uno de los métodos con más potencial para la detección de invasión por vegetación [1], [3], sin embargo existe una alta limitación en conjuntos de datos obtenidos por estos, y que por tanto imposibilitan el desarrollo de nuevas técnicas de aprendizaje profundo.

Es por esto por lo que se propone la adquisición de imágenes de drones para generar un conjunto de datos público, con el fin de disponibilizar datos para futuras investigaciones, y a su vez implementar un flujo de trabajo para segmentar áreas de invasión por vegetación a las líneas de transmisión eléctrica.

1.1. Motivación

La dependencia cada vez más fuerte de las sociedades modernas en fuentes de electricidad confiables, disponibles y sustentables es cada vez más grande, generando un reto para las compañías que brindan los servicios de generación, transporte y distribución de energía [1]. Uno de los problemas más críticos que presenta el proceso de transporte de energía está relacionado con el transporte en líneas de transmisión elevadas [4]. Existen múltiples afectaciones que pueden sufrir estas líneas, entre las más comunes se tiene: vegetación cerca de las redes con potencial de caída y posible contacto, vegetación en contacto con las líneas y contacto de vegetación con elementos como conductores [2].

En los estudios realizados por autores como [2] se menciona que después de un mapeo desarrollado en Malasia, se encontró que cerca del 18% de los cortes de energía que se habían generado en el país estaban relacionados a vegetación que había tenido un contacto con las líneas de transmisión. Además, se identificaron dos eventos de cortes de energía de grandes proporciones debidos a invasión de vegetación, uno de ellos en el 2003 afectó a Estados Unidos y Canadá con cerca de

50 millones de usuarios que representaban el 11% de la población de ambos países, mientras que para el mismo año en Italia y Suiza cerca de 60 millones de usuarios se quedaron sin suministro de energía [2]. En estudios más recientes, como el de [1] se identificaron los costos que se generaban por 30 minutos de desconexión en una empresa mediana - grande, alcanzando los U\$16.500, y que ascendían a cerca de U\$ 94.000 para una suspensión de 8 horas. Todo este tipo de problemas en la mayoría de los casos debe ser asumida por el transmisor de energía, por lo que es de suma importancia una identificación de los lugares en donde existen este tipo de problemas.

En [1] se mencionan cuáles son los métodos actuales que se tienen para hacer una revisión de las líneas de transmisión, la más habitual de ellas son los recorridos de campo realizados a pie, en donde con ayuda de binoculares se intentan detectar fallas de las líneas, la desventaja de este tipo de patrullaje es que es una labor lenta, tediosa y limitada según las condiciones naturales. Otro de los métodos más usados es la inspección por vuelos en helicóptero en donde un trabajador toma fotografías de las líneas que después son analizadas en oficina, trayendo consigo un proceso muy costoso, con baja precisión debido a la velocidad y con altos riesgos debido a los vuelos que se deben realizar tan cercanos a las líneas. Por último, uno de los métodos que más se ha usado en la actualidad es a través de sensores remotos, que brindan información de manera más automática después de un procesamiento, pero que en general no posee una alta confiabilidad debido a limitaciones en la resolución espacial. Esta limitación significa que los sensores tienen dificultades para distinguir detalles finos en la información recopilada, lo que afecta la precisión de los datos. De desearse mayores precisiones, se incurre en altos costos para la obtención de sensores con una resolución espacial más fina.

Debido a la necesidad de garantizar que las líneas de transmisión de energía no presenten invasión de vegetación, y a su vez de atacar las desventajas que los métodos tradicionales tienen, varios autores como [1] y [3] han propuesto desarrollos que combinan el uso de drones (vehículos aéreos no tripulados) y aprendizaje profundo, buscando procesos más seguros, económicos, flexibles, precisos, rápidos y automáticos.

1.2. Preguntas de investigación

La segmentación de invasión de vegetación en las líneas de transmisión de energía es una tarea habitualmente manual desarrollada en recorridos de campo, que poseen limitantes como: existencia de condiciones naturales adversas, poca eficiencia (tiempos largos para recorridos cortos) y baja confiabilidad debido a que se depende únicamente del criterio del trabajador. Por tal motivo existe la necesidad de implementar estrategias que garanticen eficiencia, confiabilidad, automatización y bajos costos, y que además sea una herramienta escalable. Las preguntas de investigación en la tesis son:

- ¿Cómo se pueden obtener predicciones confiables de invasión de vegetación en líneas de transmisión de energía usando imágenes de drones y Deep Learning en lugar de recorridos de campo?
- ¿Cuál es la mejor configuración de Pipeline para garantizar que las imágenes de drones ingresadas generen la mejor predicción de invasión de vegetación en líneas de transmisión de energía posible?

1.3. Objetivos

1.3.1. Objetivo general

Crear un flujo de trabajo usando imágenes de drone y visión por computador para segmentar áreas de invasión por vegetación a las líneas de transmisión eléctrica.

1.3.2. Objetivos específicos

- Crear un conjunto de datos público de imágenes de drones en donde se identifiquen líneas de transmisión cercanas a vías.
- Implementar estrategias de preparación de datos y de fusión de datos para incorporar información discriminante a los canales disponibles.
- Seleccionar la mejor arquitectura de aprendizaje profundo para identificar la invasión de vegetación.
- Comparar el método propuesto con modelos planteados en el estado del arte.

1.4. Estructura

La tesis se organizará de la siguiente manera, en el Capítulo 2, se desarrollará el marco teórico de referencia, proporcionando el contexto teórico en el que se basa el estudio. En el capítulo 3 se realizará una revisión del estado del arte, abordando los trabajos previos realizados en el área de estudio, describiendo su metodología, resultados y discusiones relevantes en la sección. Posteriormente, en el Capítulo 4, se explicará el proceso de creación del conjunto de datos, detallando cómo se obtuvo y preparó la información necesaria para el desarrollo de la tesis. Avanzando hacia el Capítulo 5, se presentará el procesamiento de los datos, donde se describirán las técnicas y herramientas utilizadas para manipular la información. Luego, en el Capítulo 6, se centrará en la elección de la arquitectura de aprendizaje profundo, exponiendo las razones y fundamentos detrás de la selección de ciertas arquitecturas para el desarrollo del modelo. En el Capítulo 7, se abordará la creación del flujo de automatización, presentando cómo se automatizan ciertos procesos para el desarrollo del proyecto. Finalmente, en el Capítulo 8, se presentarán las conclusiones. El texto concluirá con la sección de Bibliografía, que contendrá todas las fuentes citadas y referenciadas a lo largo del trabajo de tesis.

2. Marco teórico de referencia

Drones

Los drones, también conocidos como UAVs (Unmanned Aerial Vehicles) son herramientas que han aumentado su utilización a nivel mundial, de acuerdo con [3] las ventas de estos han aumentado de 2.5 millones en 2016 a 7 millones en el 2020, un aumento cercano al 180%. El rango de aplicaciones que poseen es amplio, como lo es fotografía, guerra, entretenimiento, rescate, agricultura, entregas o como en este caso, para detección de afectaciones en líneas de transmisión de energía. En la inspección de líneas de transmisión con drones, un equipo con múltiples sensores y cámaras viaja a lo largo de estas para recolectar información e inspeccionar en oficina, normalmente los datos que se obtienen son imágenes ópticas tradicionales y datos de escaneo láser [3]. Las ventajas que poseen estos dispositivos son su bajo costo, baja velocidad y seguridad, además de poder observar más cerca las líneas de transmisión y obtener más detalles de componentes adicionales de las torres [5]. Autores como [1] mencionan que las imágenes de drones presentan un reto en la detección de líneas de transmisión debido a las condiciones de estas, ya que son muy delgadas, y poseen problemas de similaridad de color lo que resulta en problemas para separarlas del fondo de la imagen.

Aprendizaje profundo

El aprendizaje profundo (Deep Learning), tal como es mencionado por [6] permite que los modelos computacionales (redes neuronales) que se componen de múltiples capas de procesamiento aprendan representaciones de datos con múltiples niveles de abstracción. Estos métodos han mejorado drásticamente el estado del arte en el reconocimiento de voz, el reconocimiento de objetos visuales, la detección de objetos y muchos otros dominios, como el descubrimiento de fármacos y la genómica. El aprendizaje profundo descubre estructuras intrincadas en grandes conjuntos de datos mediante el uso del algoritmo de retropropagación para indicar cómo una red neuronal debe cambiar sus parámetros internos que se utilizan para calcular la representación en cada capa a partir de la representación en la capa anterior.

CNN

Como es mencionado por [7] las redes neuronales convolucionales (CNN) fueron desarrolladas para extraer información de imágenes en 2D y 3D ([8]), y su uso especial es para clasificar imágenes, detectar objetos, detectar bordes y segmentar imágenes. Fue inicialmente usada para clasificación de imágenes en función de sus capas para reconocer bordes, patrones, contexto y formas, y a su vez brindando un mapa de características de convolución con dimensiones espaciales más pequeñas y profundas que la imagen original.

Segmentación semántica

La segmentación semántica, como la define [9] es un componente crucial para el entendimiento de las imágenes, la tarea que cumple es asignar una etiqueta única (o categoría) a cada uno de los píxeles en la imagen, lo cual es considerado como un problema de clasificación denso.

Aumentación de datos

La aumentación de datos es una solución al problema de los datos limitados, esta abarca un conjunto de técnicas que mejoran el tamaño y la calidad de los conjuntos de datos de entrenamiento, de modo que se pueden construir mejores modelos de aprendizaje profundo con ellos. Incluye transformaciones geométricas, aumentos del espacio de color, filtros kernel, mezcla de imágenes, borrado aleatorio, aumento del espacio de características y metaaprendizaje. La aumentación de datos puede mejorar el rendimiento de los modelos y expandir conjuntos de información limitados para aprovechar las capacidades de los grandes datos [10].

Fusión de datos

La fusión de datos es una alternativa a las limitaciones computacionales, normalmente los modelos de aprendizaje profundo que trabajan con imágenes poseen tres canales de información (RGB), es por ello que con el uso de fusión de datos se puede añadir información discriminante adicional a los canales disponibles, algunos ejemplos son la altura del objeto, que puede brindar consigo relaciones espaciales [11].

Pipeline

Los *pipelines* son grupos de procesos automatizados, que se aplican sobre la data usando primitivas sobre las funciones si se comparte el mismo tipo semántico y se aplica un solo tipo por categoría. Por ejemplo, en un *pipeline* de datos se ejecuta un *One-Hot Encoder* sobre las columnas categóricas, un *Min-Max Scaler* sobre las numéricas para luego pasar estas columnas a un modelo de clasificación/regresión. Este enfoque permite hacer posible la transferencia de aprendizaje de los *pipelines* entre diferentes conjuntos de datos [12].

Detección de líneas de transmisión

En estas investigaciones los autores buscan determinar mediante imágenes sintéticas o de drones las líneas de transmisión. Autores como [13] utilizaron data sintética y redes neuronales tipo CNN para detectar las líneas de transmisión con los objetivos de lograr una metodología para detectarlos y hacer más seguro el vuelo de drones, para mantenimiento y revisión de campo; uno de los aportes más importantes de esta investigación fue establecer una metodología para crear conjuntos de datos sintéticos, con el fin de suplir la necesidad de conjuntos de datos públicos. Otros autores como [14] usaron drones para establecer una metodología combinando imágenes ópticas convencionales y estéreo-imágenes para identificar las líneas de transmisión y generar alertas cuando existieran obstáculos a +0.5m. A nivel general en estas investigaciones se identifica como un reto de investigación la curvatura que tienen algunas líneas de transmisión, haciendo un poco más complicada su detección, además de la dificultad de identificar estas líneas en imágenes con fondos saturados, ya que es complicado generar la separación de este.

Segmentación de invasión de vegetación:

En estas investigaciones, los autores buscaban identificar los lugares en donde la vegetación estaba muy cerca de las líneas de transmisión, esta cercanía podría ser por crecimiento o por posibilidades de caída de ésta sobre las líneas, la principal diferencia identificada en la literatura es que en estas tareas se identificaba

únicamente vegetación y no otro tipo de obstáculos que pueden existir. Autores como [15] utilizaron imágenes de drones y arquitecturas de aprendizaje profundo como los Transformers [16] para identificar la invasión de vegetación, en este se usa segmentación semántica para identificar los lugares de la imagen en donde se presenta invasión de vegetación, la gran ventaja de este modelo fue la gran precisión que se obtuvo, alcanzado un 98% y presentando un 30% mayor de velocidad frente a soluciones anteriores. En [17] se presentó un método para identificar de manera temprana la invasión de vegetación en las líneas usando imágenes tipo LIDAR obtenidas de drones y modelos de crecimiento de árboles (modelos de Richards), mediante los datos tipo LIDAR se realizaba una extracción de las líneas de transmisión y de los árboles, para después generar rectángulos delimitadores de ambos, y con un algoritmo determinaban cuales de estos árboles se cruzaban después de cierto n años de crecimiento con las líneas de transmisión. Otro de los artículos presentaba una detección de invasión de vegetación apoyándose en la estereoscopia y en un arquitectura de red neuronal tipo Faster R-CNN [18], la propuesta de detección se realiza con sensores ópticos implementados en las torres de energía, que envían imágenes a un procesador de imágenes que usa aprendizaje profundo para identificar árboles y un Hough Transform [19] para identificar las líneas de transmisión, para por último medir la distancia entre la altura de ambos elementos usando estereoscopia, mediante este método se pueden disminuir los costos de detección de invasión de vegetación para zonas altamente boscosas y con un crecimiento alto ya que es una solución que dura cerca de 10 años al implementarse. Por último, uno de los artículos presenta una recopilación de estudios anteriores [20] que identifica arquitecturas útiles para identificar vegetación en imágenes, esto es de suma importancia ya que representa un punto de partida inicial muy útil, en este se identifican arquitecturas que permitieron conducir esta tarea, entre las que destacan U-Net.

3. Revisión sistemática de la literatura

En los últimos años se han realizado diversos estudios en la detección de invasión por vegetación, sin embargo, el grueso de la bibliografía está dividida en dos temáticas principales, una de ellas es la detección de las líneas de transmisión, mientras que el otro grueso de las investigaciones estaba orientada a la segmentación de vegetación, debido a la importancia de ambas tareas para el objetivo general de este estudio se muestra una breve introducción de ambas temáticas.

3.1. Diseño de la Búsqueda

Para el presente trabajo se realiza una revisión sistemática de la literatura [21] que permite combinar los diferentes términos de nuestra búsqueda, con esto disponemos de herramientas como los operadores booleanos, truncamientos, búsqueda por frase y operadores de proximidad. La revisión está enfocada en artículos que ataquen la detección de vegetación en líneas de transmisión apoyadas en técnicas de inteligencia artificial y drones, con el fin de obtener información que sirva como punto de partida y que oriente sobre cómo se ha investigado el tema de interés, y cuáles son los retos que se proponen alrededor de este. Se realizó una búsqueda apoyada de Science Direct para ciertos artículos, y en Scopus en donde la consulta usada es la siguiente:

```
ALL ( ( "Transmission line" OR "Power transmission line" OR "power line" ) AND (
"artificial vision" OR "Computer vision" OR "Deep Learning" OR "Machine Learning"
OR "artificial intelligence" ) AND ( "UAV*" OR "Drone*" OR "Unmanned Aerial
Vehicle" ) AND ( "Vegetation" OR "vegetation" OR "tree" ) AND ( "encroachment"
))
```

3.2. Resultados y discusiones

El estudio de segmentación de invasión por vegetación se ha abordado desde diferentes enfoques y apoyado de distintas técnicas. En la revisión de la literatura se encontraron modelos que basan su trabajo en imágenes satelitales, en imágenes sintéticas y en tiempo más reciente en el uso de imágenes de dron, principalmente apoyadas en técnicas de aprendizaje de máquinas, aprendizaje profundo o técnicas tradicionales. Además, alineado con los objetivos de esta investigación se consultaron referencias en aspectos como la creación de conjuntos de datos y en la creación de flujos de trabajo automático enfocado en GeoAI [22].

En el año 2012 [2] , se llevó a cabo un estudio centrado en recopilar investigaciones previas sobre la detección de invasión por vegetación en líneas eléctricas. Este estudio documentó las interrupciones comunes en la transmisión y distribución de energía eléctrica como una de las principales causas, generando problemas significativos, especialmente en plantas e industrias donde un suministro confiable de energía es fundamental.

Las estadísticas presentadas en este estudio destacan la urgencia de abordar este problema. Por ejemplo, en Malasia, aproximadamente el 18% de los cortes de energía en el país estaban relacionados con la vegetación que había entrado en contacto con

las líneas de transmisión, posicionándose como la tercera causa de interrupciones en el suministro eléctrico a nivel nacional. Estos hallazgos subrayan la necesidad imperante de desarrollar técnicas que aborden eficazmente esta problemática.

En el 2003 Estados Unidos y Canadá con cerca de 50 millones de usuarios que representaban el 11% de la población de ambos países sufrieron cortes de energía debidos a invasión por vegetación en los tendidos eléctricos, mientras que para el mismo año en Italia y Suiza cerca de 60 millones de usuarios se quedaron sin suministro de energía. En estudios más recientes, como el de [1] se identificaron los costos que se generaban por 30 minutos de desconexión en una empresa mediana - grande, alcanzando los U\$16.500, y que ascendían a cerca de U\$ 94.000 para una suspensión de 8 horas.

En el mismo estudio [2] categoriza las fallas debidas a invasión por vegetación como:

- Fallas debido a vegetación que están fuera de los márgenes de seguridad y son lo suficientemente grandes como para hacer contacto con una línea si se caen.
- Fallas por vegetación que están en contacto con un solo conductor primario.
- Fallas debido a vegetación que empujan varios conductores primarios juntos.
- Otras fallas, incluyen aquellas en las que un árbol hace contacto con un solo conductor secundario y aquellas en las que un árbol junta varios conductores secundarios.

En [1] se mencionan los métodos que se tienen para hacer revisión de la invasión en las líneas de transmisión, la más habitual son los recorridos de campo a través de una inspección visual se determina los puntos en donde es necesaria una intervención, presentando como desventaja el tiempo empleado, la dificultad para realizar largos recorridos y problemas relacionados a las condiciones naturales. Además, es habitual la inspección por vuelos en helicóptero en donde se toman fotografías que son analizadas en oficina, trayendo consigo un proceso muy costoso, con baja precisión debido a la velocidad y con altos riesgos debido a los vuelos que se deben realizar cercanos a las líneas. En la actualidad se ha convertido más común el uso de sensores remotos, que brindan información de manera automática después de un procesamiento, sin embargo, no posee una alta confiabilidad debido a las escalas, y que de desearse mayores precisiones se incurren en altos costos.

Debido a la necesidad de poder generar una detección de invasión por vegetación de forma más eficiente [1] condujo una revisión de la literatura en el año 2018 de las oportunidades de aplicar aprendizaje profundo en las tareas de inspección de líneas de transmisión, donde propone que la combinación de estas técnicas con drones puede cumplir múltiples tareas como lo son inspección de componentes, monitoreo de invasión por vegetación, detección de congelamiento y monitoreo de desastres, todas necesarias en las redes de transmisión, garantizando bajos costos, baja velocidad, rapidez y posibilidad de obtención de imágenes con mayores resoluciones. Además, identifica que las imágenes ópticas obtenidas por los drones son la mejor opción para la recolección de información por su facilidad de recolectar, de analizar y por el valor que generan al detectar un amplio rango de fallas comunes y de

componentes. Muestran que la invasión por vegetación es una de las áreas más retadoras y en donde existe menor investigación, recomendando el uso de flujos automáticos que combinen tareas de detección de líneas y tratamiento del “fondo” de la imagen.

Además de las investigaciones generadas con drones se han trabajado imágenes satelitales ([23], [24], [25], [26]), imágenes a partir de cámaras en los postes ([18], [27]) y sensores lidar ([17], [28], [29], [30]). Antes de revisar los artículos enfocados al uso de imágenes de drones y aprendizaje profundo haremos una breve descripción de los aportes generados por las temáticas mencionadas anteriormente.

En [23] los autores identificaron las técnicas usadas para detectar invasión por vegetación usando imágenes satelitales, englobándolas en 4 categorías: método del índice de vegetación, detección basada en objetos, uso de imágenes estereográficas y otras técnicas. Adicionalmente existe un uso reciente de algoritmos de aprendizaje de máquinas combinados con imágenes satelitales, detectando torres de transmisión de energía usando *active learning* y *perceptrones* multi-capas. A su vez encuentran una adopción de las redes neuronales para este tipo de tareas, pero enfocadas principalmente en el uso de drones, en donde se usan redes neuronales convolucionales y YOLO's [31] para establecer la localización de torres de transmisión. En [24] Mediante el uso de imágenes satelitales de alta resolución y algoritmos semi supervisados de aprendizaje de máquinas estableció una metodología de monitoreo de vegetación a lo largo de líneas de transmisión, el algoritmo está compuesto de una primera capa de redes neuronales profundas (FCN) que capta patrones significativos para después entrar a una segunda capa de un modelo supervisado (AdaBoost [32]) que posee la información semántica de los patrones de vegetación de una imagen satelital, dando como resultado un mapa de geolocalización de las amenazas de vegetación que tiene como características principales en la densidad y la proximidad de la invasión de la vegetación. Los autores [26] presentaron un método para detectar la invasión de vegetación en líneas de transmisión de energía eléctrica usando imágenes de satélites aplicando técnicas de estadística y texturización de imágenes para identificar las características más efectivas para aumentar la precisión de clasificación de la máquina de soporte vectorial (SVM [33]). Los resultados mostraron una precisión de detección del 98,3%. Usaron imágenes satelitales de la banda visible debido a su acceso gratuito y en su disponibilidad para diferentes plataformas. Por último en [25] describen un nuevo método para monitorear la línea de corriente eléctrica y la invasión por vegetación a lo largo de ella utilizando imágenes satelitales usando un modelo de aprendizaje profundo (RetinaNet [34]) para detectar la ubicación de las torres de transmisión eléctrica y aplicando un algoritmo de enrutamiento para crear una ruta entre ellas, además de un algoritmo de identificación de corredores para extraer el área de la línea de corriente eléctrica, y por último establecieron un algoritmo de agrupamiento k-means [35] para resaltar las áreas de alta y baja densidad de vegetación.

Relacionado a la detección de invasión por vegetación en redes eléctricas usando cámaras en los postes [18] presentó un marco de detección basado en aprendizaje profundo que utiliza imágenes obtenidas de sensores de visión montados en torres de transmisión de energía. El marco de detección propuesto consta de tres módulos en cascada: (1) detección de regiones de vegetación basada en Faster R-CNN [36], (2) detección de líneas de energía basada en la transformada de Hough [19] y (3) detección de crecimiento de vegetación basada en un algoritmo de estereovisión avanzado. Este último convierte los datos de imagen 2D de la vegetación y las líneas de energía en resultados tridimensionales (3D) de altura y ubicación para obtener localizaciones geográficas precisas. Además en [27] los autores usan una técnica de segmentación de invasión por vegetación con cámaras integradas en los postes de transmisión, las cuales toman información que después es analizada en una estación base, usando métodos de reconocimiento de patrones entre los cuales está PCA [37], se eligen las imágenes aptas para segmentar en el algoritmo establecido, brindando la ubicación, el tamaño y la representación en 2D; con esta información operadores establecen tareas de mantenimiento.

Respecto a los métodos que usan sensores LIDAR [38] menciona que los estudios realizados con esta tecnología permiten obtener información más precisa de la vegetación presente en las imágenes. En [28] usaron sensores LIDAR para detectar y modelar las líneas de energía, utilizando una técnica llamada PL2DM (Detección y Modelado basado en LiDAR de Líneas de Energía) la cual está basada en una arquitectura de segmentación de una nube de puntos que después estima la ubicación de los puntos donde existen líneas y genera los segmentos de estas, este algoritmo es construido basado en funciones matemáticas y el desarrollo está enfocado para detección de obstáculos en tiempo real de líneas de energía, obtienen un 80% de puntos correctamente identificados; una de las limitaciones de este algoritmo es la correcta distinción de las líneas cuando encontraba vegetación. Los autores de [29] proponen un método eficiente para la extracción y clasificación de objetivos tridimensionales de instalaciones de transmisión de energía eléctrica utilizando datos de nube de puntos adquiridos por vehículos aéreos no tripulados. El método implica la construcción de una matriz de hash espacial, la extracción de líneas de transmisión eléctrica y la identificación de torres de transmisión, y la optimización del proceso de extracción. Los resultados experimentales muestran que el método propuesto es capaz de producir una segmentación confiable con una precisión general del 97%. Por su parte, [17] usaron imágenes de LIDAR adquiridas en drones para crear una nube de puntos que permitiera identificar la posición de las líneas eléctricas y de vegetación presente (entregando altura y especie), además proponen combinar esta información con un modelo de crecimiento de los árboles, entregando cuadros delimitadores de la ubicación de la vegetación y de las líneas de acuerdo a la predicción del crecimiento de los árboles. Este proceso es realizado por un flujo automatizado, entran los datos en donde se extrae las líneas y el segmento al que pertenecen y los tamaños de los árboles y su ubicación, para luego generar cuadros delimitadores usando un modelo de crecimiento de Richards que predicen el tamaño a futuro, con estos datos se genera un test de intersección entre el tamaño de los árboles inferidos y las líneas eléctricas. Por último, en [30] los autores se basan en imágenes estéreo de drones y satélite para la monitorización de árboles y vegetación que proporciona una mejor disparidad. Se utiliza una nueva técnica basada en la fusión de la red neuronal convolucional (CNN) y la representación dispersa para manejar regiones sin textura, discontinuidades de profundidad y regiones lisas para

producir un mejor mapa de disparidad que se utiliza para estimar amenazas utilizando la altura y la distancia de la vegetación y los árboles cerca de las líneas y postes de energía. La evaluación experimental mostró una mejora considerable en la estimación de la amenaza de la vegetación con una precisión del 90,3% en comparación con otros métodos.

En lo que respecta al uso de drones con aprendizaje profundo se han concentrado en detección de fallas o componentes en las torres eléctricas, así [3] presenta la arquitectura de tres diseños conceptuales orientados a drones para la detección automática y en tiempo real de fallos en líneas de energía eléctrica utilizando inteligencia artificial, proponen el uso de algoritmos de aprendizaje de profundo, en particular el uso de CNN debido a su buen comportamiento en tareas de reconocimiento de imágenes y de patrones. Además, como se mencionó, en [30] usaban una red neuronal convolucional e imágenes de drones para crear mapas de disparidad.

El referente en términos metodológicos es el trabajo de [15], en donde se explora el uso de vehículos aéreos no tripulados (UAV) para la detección de la invasión de vegetación utilizando una red de transformadores basada en la atención multi-cabeza (VE-DETR). Primero, las imágenes que se recopilan del dron se envían al encoder principal de CNN donde se extraen las características de la imagen y luego esas características de imagen extraídas se alimentan tanto al encoder-decoder del transformer para la predicción de clase como al decoder de CNN. para la predicción de segmentación. Se emplea un módulo de mecanismo de atención de cabezales múltiples, y se alimenta con características codificadas y decodificadas por transformador junto con las características de imagen extraídas de la red troncal de CNN en el decoder de CNN para realizar tareas de segmentación.

4. Segmentación de la invasión por vegetación a líneas de transmisión eléctrica usando aprendizaje profundo en imágenes de drone

4.1. Creación del conjunto de datos

El conjunto de datos llamado VEPL (Vegetation Encroachment in Power Line) [39] se obtuvo a través de una serie de vuelos de drones autónomos, realizados a unos 30 metros de altura del suelo. El área de interés escogida se encuentra en una vía secundaria de Envigado, Colombia, Sudamérica. La elevación sobre el nivel del mar del área es de 2500 metros, y la vegetación predominante es la selva tropical, también conocida como bosque húmedo tropical [40]. Este tipo de vegetación se caracteriza por ser densa y frondosa, con árboles altos y muchas especies de plantas. Similar a lo hecho en [11], donde los autores describieron una metodología para obtener un conjunto de datos emparejados de UAV, que constaba de múltiples pasos, comenzando con la adquisición de imágenes de UAV, la digitalización de objetos en capas para producir las máscaras, después de eso, la rasterización de las capas, y al final, el teselado de todos los rasters. Finalmente, se lleva a cabo la aumentación de datos y se ejecuta la verificación de desequilibrio de clases o máscaras vacías para obtener el conjunto de datos resultante. Las imágenes de VEPL se tomaron a lo largo de una carretera, asegurando la inclusión de líneas eléctricas, que comúnmente se sitúan junto a este tipo de infraestructura. Se recorrió una distancia total de 2,4 kilómetros a lo largo de la vía, se obtuvo un ortomosaico del área recorrida mediante un software fotogramétrico comercial. Este ortomosaico fue rotulado semiautomáticamente en pantalla, mediante la digitalización de tres clases: la clase 1 o vegetación, compuesta por árboles y arbustos altos, con un valor RGB de (0, 255, 0). La clase 2, o líneas eléctricas, compuesta por todas las líneas eléctricas visibles, esto quiere decir que no se infieren cuando están ocultas bajo la vegetación, con un valor RGB de (110, 110, 110), y la clase 0 o de fondo, con un RGB valor de (0, 0, 0). La teselación de imágenes en pares de imágenes-máscaras, con un tamaño de 256×256 , produciendo un total de 65852 ejemplos. Sin embargo, debido a la alta presencia de la clase de fondo solo, era importante hacer una verificación de desequilibrio y eliminar aquellas imágenes-máscaras con más del 90% de fondo [11]. Después de este proceso, el número resultante de pares imagen-máscaras fue de 3566, donde se desarrolló una verificación final para garantizar la presencia de la clase de línea eléctrica en todas las imágenes, por lo que aquellos pares que no tienen ningún píxel de esta clase fueron eliminados. El tamaño resultante del conjunto de datos fue de 532 pares de máscara de imagen. Finalmente, se llevó a cabo la aumentación geométrica y espectral utilizando los 532 ejemplos con el objetivo de mejorar la capacidad de generalización de los modelos de aprendizaje profundo [10]. Los pares totales de imágenes - máscaras obtenidos después de la aumentación geométrica fueron 3724, mientras que 3192 pares fueron la cantidad resultante para la aumentación espectral. La Tabla 1 resume las características de los ortomosaicos y el número total de ejemplos por clase y por ortomosaico. La Figura 1 muestra ejemplos de imágenes y máscaras multiclase correspondientes del conjunto de datos VEPL. El conjunto de datos está compuesto por 4 carpetas, una para los pares de imágenes-máscaras originales, la segunda para los pares de imágenes-máscaras con aumentación geométrica, una tercera para las imágenes-máscaras con aumentación espectral y la carpeta restante para los ortomosaicos originales. y sus máscaras ráster correspondientes, en caso de que los lectores deseen crear un nuevo conjunto de

datos o modificarlo, utilizando, por ejemplo, un tamaño de teselación diferente o un procedimiento de aumentación de datos. Observe que todas las imágenes-máscaras están numeradas en orden ascendente. La Tabla 2 resume las especificaciones del conjunto de datos.


Tabla 1. Características de los ortomosaicos y el número de ejemplos por clase y por ortomosaico (no contiene aumentación de datos).

Ortomosaico	Clase 0 (Background)	Clase 1 (Vegetación)	Clase 2 (Línea eléctricas)	Total
Cols, Filas: 26,898; 35,093 GSD 1.26, Tam.: 2.70 GB Formato: TIFF, Canales: 3 Prof. Pixel: 8 Bit Sistema de coordenadas: GCS_WGS1984	103 ejemplos	115 ejemplos	115 ejemplos	333 ejemplos
Cols, Filas: 42,591; 20,637 GSD 1.06, Tam.: 2.46 GB Formato: TIFF, Canales: 3 Prof. Pixel: 8 Bit Sistema de coordenadas: GCS_WGS1984	155 ejemplos	166 ejemplos	166 ejemplos	487 ejemplos
Cols, Filas: 27,885; 16,436 GSD 0.91, Tam.: 1.28 GB Formato: TIFF, Canales: 3 Prof. Pixel: 8 Bit Sistema de coordenadas: GCS_WGS1984	82 ejemplos	94 ejemplos	94 ejemplos	270 ejemplos
Cols, Filas: 47,780; 41,390 GSD 1.35, Tam.: 5.53 GB Formato: TIFF, Canales: 3 Prof. Pixel: 8 Bit Sistema de coordenadas: GCS_WGS1984	149 ejemplos	157 ejemplos	157 ejemplos	463 ejemplos

Tabla 2. Especificaciones del conjunto de datos VEPL.

Item	Description
Campo de aplicación	Intrusión de vegetación en corredores de líneas de energía
Datos recolectados	Imágenes aéreas
Método para la adquisición	Vuelo de drones
Drone usado	DJI Mavic 2 Pro
Resolución de cámara / Tamaño del sensor	20 Mpx, 1 pulgada CMOS
Software para el procesamiento de datos recolectados y productos	Agisoft Metashape
GSD de los ortomosaicos y DSM obtenidos	0.9 to 1.35 cm/px
Método de etiquetado	Semi-automático en GIS
Producción del conjunto de datos	Scripts en Jupyter Notebook
Lenguaje para scripts	Python 3.8
Software SIG utilizado	ArcGIS 10.8
Número de clases y objetos	3: vegetación, líneas eléctricas, background
Número de ortomosaicos	4
Datos recolectados por	Autores de esta tesis
Año de recolección	2023
Conjunto de datos de segmentación	Multi-clase a color
Información adicional	RGB
Tamaño del conjunto de datos	3.88 Gb comprimido


Formato de la imagen	.jpg
Cantidad de imágenes	El conjunto de datos se divide en 12 imágenes TIF (4 ortomosaicos, DSM y máscara), 532 imágenes después de la teselación, 3192 imágenes (con aumentación espectral) y 3724 (con aumentación geométrico)
Tamaño de imagen-máscara	256 × 256 px
Tamaño promedio de memoria de imagen RGB	16 Mb
Resolución espectral de imagen RGB	3 canales
Resolución radiométrica de imagen	8 bits
Sistema de coordenadas de imagen	WGS1984




(a)



(b)



(c)



(d)

Figura 2. Imagen de VEPL: ejemplo de imagen - máscara del conjunto de datos. (a) Imagen RGB, con un tamaño de 256 × 256. (b) Máscara multietiqueta correspondiente con clase de vegetación (verde), clase de línea eléctrica (gris) y clase de fondo (negro). (c) Imagen RGB

con aumentación de datos geométricos aplicado (RandomRotate90). (d) Imagen RGB con aumentación de datos espectrales aplicado (CLAHE, Apply Contrast Limited Adaptive Histogram Equalization).

4.2. Implementación de Estrategias de Preparación de Datos

La prevalencia de los ortomosaicos de drones está en aumento, debido a su funcionalidad sin esfuerzo, precios asequibles para drones profesionales y de consumo, así como integrales que permiten a los investigadores generar conjuntos de datos valiosos y obtener información significativa [11], [41]. Todos los procesos utilizados para producir el conjunto de datos VEPL se presentan a continuación.

4.2.1. Adquisición y procesamiento de datos

Las imágenes de UAV se adquirieron con un dron DJI Mavic 2 Pro. Los vuelos autónomos se realizaron con una superposición frontal del 85 % y una superposición lateral del 75 % para garantizar la producción de ortomosaicos de alta calidad. Las imágenes individuales, tomadas por el dron, fueron procesadas en el software comercial fotogramétrico Agisoft Metashape [42], obteniendo los ortomosaicos y el modelo digital de superficie (DSM). El flujo de trabajo se basa en [11] y se resume en la Figura 3, que ilustra la adquisición y procesamiento de imágenes para obtener los ortomosaicos y el DSM.




Figura 3. Flujo de trabajo de adquisición y procesamiento de datos de drones, las imágenes se procesan en el software AgiSoft para obtener ortomosaicos de drones y DSM. Adaptado y modificado de [11].

El tamaño de píxel de los ortomosaicos obtenidos está entre 0,9 y 1,3 centímetros, esta medida se denomina *Ground Sample Distance* (GSD), y representa el tamaño de píxel físico de una imagen. Un GSD de 10 cm es igual a decir que un píxel tiene una extensión espacial de 10 centímetros [16]. La Figura 4 hace zoom sobre un ortomosaico y su DSM correspondiente.



(a)



(b)

Figura 4. (a) Acercamiento del ortomosaico de un dron. (b) Ampliación del DSM. Solo se utilizan ortomosaicos para producir el conjunto de datos VEPL, se proporcionan los DSM correspondientes para trabajos futuros. Este ortomosaico tiene un GSD de 1,26 cm/px.

4.2.2. Etiquetado de datos


El proceso de etiquetado de datos se realizó haciendo uso de las herramientas del software ArcGIS. Se creó una capa GIS de polígonos, en formato de archivo de forma (*.shp), digitalizando manualmente cada objeto de vegetación. Esta tarea se realizó a una escala entre 1:20 y 1:50 para todos los ortomosaicos obtenidos, tratando de delinear la mayoría de los detalles del objeto y creando un campo entero llamado "Clase" con un valor asignado de 1. Los corredores de líneas eléctricas se obtuvieron aplicando la herramienta GIS de buffer, con una distancia buffer de 3 centímetros, a las líneas iniciales digitalizadas a mano, generando así polígonos de 6 cm de ancho por línea. Las líneas eléctricas etiquetadas corresponden solo a aquellas líneas que son visibles o perceptibles por el ojo humano. Es decir, se excluyeron deliberadamente los tendidos eléctricos que se ocultan bajo la vegetación. La decisión de no etiquetar las líneas eléctricas ocultas por la vegetación se tomó para evitar confundir a los modelos de aprendizaje profundo. La inclusión de dichos datos inferidos podría introducir ambigüedad y comprometer potencialmente la capacidad del modelo para distinguir con precisión entre las líneas eléctricas y la vegetación. El valor Clase 2 se asignó a los polígonos de líneas eléctricas. La figura 5 muestra una imagen etiquetada, la clase 1 o la vegetación, y la clase 2 o las líneas eléctricas.



Figura 5. Etiquetado de datos en ArcGIS. Corredores de líneas eléctricas (líneas rojas) y clases de vegetación (polígono gris).

La clase de fondo (Clase 0), comprende áreas que no corresponden a la vegetación, ni a los corredores de líneas eléctricas. Los siguientes pasos se realizan automáticamente usando herramientas GIS para obtener una máscara raster con la misma extensión de los ortomosaicos de entrada, este proceso es repetitivo para todos los ortomosaicos disponibles:


- Crear una unión entre polígonos de la clase vegetación y la clase corredor de líneas eléctricas.
- Utilizar una herramienta GIS de Identidad entre el resultado anterior y el área de interés. La salida es una capa de polígono que contiene las 3 clases. Rasteriza la capa anterior usando el campo "Clase".
- Exportar el raster anterior a formato .tiff, con resolución radiométrica de 8 bits. Todo el proceso debe garantizar el uso del mismo sistema de referencia espacial. La figura 6 muestra los pasos de etiquetado y el resultado final del ráster.



(a)



(b)



(c)

Figura 6. Proceso de etiquetado. **(a)** Porción inicial del ortomosaico a etiquetar. **(b)** Unión de vegetación y buffer de corredores de líneas eléctricas. **(c)** Ráster final. La máscara tiene el mismo tamaño, sistema de coordenadas y propiedades que la entrada del ortomosaico.

4.2.3. Teselación de datos y verificación de desequilibrio de clases

El proceso de teselación de datos y el código utilizado también se basan en el flujo de trabajo propuesto en [11]. Cada ortomosaico y la capa ráster de máscara correspondiente se teselan juntos, en pares de imágenes-máscaras de 256×256 píxeles, y se guardan en dos carpetas separadas, RGB y Máscara, en formato png. Todas las imágenes se nombran con números enteros en orden ascendente, inicialmente se obtuvieron 65.852 pares imagen-máscara después del teselado de los cuatro ortomosaicos disponibles.

Los conjuntos de datos para la segmentación semántica definen un fenómeno visual; sin embargo, en el mundo real, los grandes conjuntos de datos no siempre están disponibles para un entrenamiento suficiente de los modelos de aprendizaje profundo. Además, no solo es importante la cantidad de ejemplos de un conjunto de datos, sino también el proceso de adquisición utilizado, los dispositivos y las condiciones de luz empleados, los pasos de etiquetado, entre muchos otros factores. Todo eso puede causar que un conjunto de datos esté sesgado [43]. El entrenamiento de un modelo en un conjunto de datos sesgado tiende a tener un gran rendimiento en el conjunto de datos de entrenamiento, pero no logra generalizar en escenarios de casos reales [44], [45].

Tener una cantidad suficiente de ejemplos de píxeles positivos dentro de una imagen, en comparación con los que pertenecen a la clase negativa, siempre es un desafío. Cuando una de las clases en el conjunto de datos es dominante frente a la otra, se denomina desequilibrio de datos [18]. En el conjunto de datos VEPL, se realiza una verificación de desequilibrio, no solo se preocupa por las instancias positivas, cuando existe la invasión de vegetación, sino también cuando la clase negativa es dominante. Para ello, se eliminaron las imágenes y máscaras correspondientes con más del 90% de clase de fondo, esto evita la presencia desequilibrada de píxeles de esa clase. Este paso es importante para permitir que las redes neuronales se generalicen mejor en la vegetación y en las clases de corredores de líneas eléctricas. Dado que las líneas eléctricas son la clase más pequeña, se eliminaron todas las imágenes que no tienen ningún píxel de esa clase, este paso garantiza que todas las imágenes contengan la clase de corredor de líneas eléctricas y se deshaga de las imágenes donde solo había fondo o vegetación. El número restante de imágenes en el conjunto de datos después de la eliminación fue de 532 imágenes.

Los scripts para la verificación y eliminación de desequilibrios se pueden descargar desde el directorio de GitHub de este documento https://github.com/macanoso/GeoAI/blob/master/Tesellation_Code.ipynb (consultado el 04/05/2023), la Figura 7 muestra el flujo de trabajo utilizado para la teselación y la comprobación de desequilibrio del conjunto de datos.




Figura 7. Flujo de trabajo para teselación de conjuntos de datos y verificación de desequilibrio. Adaptado de [11].

4.2.4. Aumentación de datos

La aumentación de datos es una técnica desarrollada para aumentar la diversidad y el número de ejemplos de un conjunto de datos. La principal diferencia con otras técnicas para evitar el sobreajuste, como el muestreo, la normalización por lotes y el aprendizaje por transferencia, es que la aumentación de datos aborda el sobreajuste desde la raíz del problema, los datos mismos [10], [44], [46]. La aumentación de datos se divide en dos categorías generales:

- Tradicional: las imágenes se transforman utilizando una combinación de transformaciones afines (rotación, reflexión, escalado y corte) y una modificación de color o espectral.
- Sintético: Se basa en modelos de Deep Learning como Generative Adversarial Networks (GANs [47]), donde se realiza la generación no supervisada de imágenes. Una de las redes genera imágenes (el generador) que intenta engañar a otra red (el discriminador) que está entrenada para distinguir las imágenes falsas de las reales. Otras estrategias son los métodos basados en CNN, como el borrado aleatorio [38].

En el conjunto de datos VEPL, si bien no existe una gran diferencia en el número de ejemplos por clase (Tabla 1), sí existe un desequilibrio a nivel de píxel, es decir, en el número total de píxeles para cada clase objetivo. Esto se debe al hecho de que los corredores de líneas eléctricas son polígonos estrechos y rectos frente a los polígonos de área ancha que representan la vegetación o el fondo. Para aumentar la cantidad de ejemplos disponibles en el conjunto de datos y su diversidad, pero también para mitigar el desequilibrio de clases y mejorar la generalización, se realizaron aumentaciones geométricas y espectrales sobre el conjunto de datos VEPL original [10], [41], [48].

- Aumentación geométrica: altera la geometría de la imagen con el objetivo de hacer que las redes neuronales sean independientes de los cambios de posición y orientación del objeto [49]. Puede realizar rotaciones aleatorias, distorsión de cuadrícula, volteo horizontal, cambio de escala y deformación elástica. Implementamos la biblioteca Albumentations para la aumentación geométrica de las imágenes y las máscaras correspondientes del conjunto de datos [44]. El total de pares obtenidos a través de este proceso fue de 3724.
- Aumentación espectral: persigue hacer modelos robustos a cambios de imagen en iluminación y color [49]. Las técnicas de aumentación espectral utilizadas en el conjunto de datos VEPL original fueron Brillo y contraste aleatorios, Cambios de saturación de tono, Filtro de desenfoque gaussiano, Corrección gamma y CLAHE (Ecualización de histograma adaptativo limitado por contraste) [44]. El total de pares de imágenes obtenidos mediante aumentación espectral fue de 3192.

La Figura 8 muestra algunos ejemplos de ambos procedimientos de aumentación.



(a)



(b)

Figura 8. Aumentación de datos. (a) Aumentación geométrica. (b) Aumentación espectral.

4.3. Selección de arquitectura de aprendizaje profundo para segmentar la invasión por vegetación en líneas eléctricas

La selección de una arquitectura adecuada es crucial para abordar eficazmente las tareas de segmentación semántica. En esta sección, profundizamos en dos prominentes arquitecturas de aprendizaje profundo diseñadas para estas tareas. La primera arquitectura que exploramos es U-Net [50], que representa una de las soluciones pioneras para abordar problemas de segmentación semántica. Además, examinamos la arquitectura más reciente propuesta en DeepLab [51]. En la siguiente sección, proporcionamos una explicación más detallada de estas arquitecturas de redes neuronales. Además, destacamos aspectos clave del desarrollo, incluido el uso de pesos pre entrenados. En esta sección se busca comprender y comparar estas arquitecturas, buscando mejorar la comprensión de los modelos de aprendizaje profundo diseñados específicamente para la segmentación semántica.

4.3.1. Exploración de la Arquitectura de Aprendizaje Profundo y Funciones de Pérdida

U-Net: Estructura y Aplicaciones en Procesamiento de Imágenes

La arquitectura U-Net se propuso originalmente en 2015 en [50], y en un principio la investigación se centró en la segmentación de imágenes biomédicas. Consiste en una

ruta de codificador y decodificador, donde la ruta del codificador (llamada "contracting" por los autores) tiene la arquitectura de una red neuronal convolucional (CNN) que captura el contexto, y una ruta de decodificador (llamada "expanding") que permite una ubicación precisa. El uso típico de las CNN es en tareas de clasificación, pero en muchos desafíos de aprendizaje profundo, la salida deseada debe incluir la localización píxel por píxel de cada clase [50]. En el caso del conjunto de datos propuesto en este documento, una salida con clasificación y localización es obligatoria debido a la necesidad de identificar la ubicación del crecimiento de vegetación en los corredores de líneas eléctricas.

El paso del codificador en este proceso implica la aplicación de dos convoluciones consecutivas de 3x3, seguidas de una función de activación ReLU (unidad lineal rectificadora) y una operación de max pooling de 2x2 con un "stride" de 2. Este proceso de reducción de tamaño duplica el número de canales de características. Por otro lado, el paso del decodificador incluye una operación de upsampling en el mapa de características, seguida de una convolución de 2x2 que reduce a la mitad el número de canales de características. El mapa de características resultante se concatena con el mapa de características recortado correspondiente de la ruta de codificación. A continuación, se aplican dos convoluciones de 3x3, cada una seguida de una activación ReLU. El paso de recorte es necesario para tener en cuenta la pérdida de píxeles de borde que ocurre durante cada convolución. Finalmente, se emplea una capa convolucional de 1x1 para asignar cada vector de características de 64 componentes al número deseado de clases. En conjunto, la red consta de un total de 23 capas convolucionales [50]. En la Figura 2 se presenta la arquitectura U-Net:




Figura 9. Arquitectura U-Net (ejemplo para una resolución de 32x32 píxeles). Cada cuadro azul corresponde a un mapa de características de múltiples canales. El número de canales se indica en la parte superior del cuadro. El tamaño xy se proporciona en el borde inferior izquierdo del cuadro. Los cuadros blancos representan mapas de características copiados. Las flechas indican las diferentes operaciones. Fuente: Adaptado de [50].

Se han implementado múltiples variantes de U-Net como *backbone* (base) en GeoAI, especialmente en imágenes satelitales. En [52], los autores propusieron ResUNet-a, que combina una nueva función de pérdida basada en la función de pérdida de Dice

[53] para la tarea de segmentación semántica de imágenes aéreas de alta resolución. ResUNet-a incorpora un *backbone* usando UNet con conexiones residuales, convoluciones *atrous*, agrupación jerárquica de escenas y inferencia multitarea. Además, en [54], se propone un nuevo método de detección de cambios basado en la arquitectura UNet++ para segmentación semántica. Este enfoque aprovecha una estructura eficiente codificador-decodificador para generar mapas de cambios de alta precisión a partir de pares de imágenes co-registradas. La fusión de múltiples salidas laterales en diferentes niveles semánticos produce un mapa de cambios final con una precisión superior, superando a otros métodos de vanguardia en conjuntos de datos de imágenes satelitales de muy alta resolución.

Finalmente, en [55], los autores propusieron RCNN-UNet, un modelo de aprendizaje profundo para la extracción de información de carreteras a partir de imágenes aéreas. Este modelo elimina errores de propagación, aprovecha el contexto espacial y las características de bajo nivel, y utiliza el aprendizaje multitarea para la detección de carreteras y la extracción de líneas centrales.

DeepLab: Un Enfoque Avanzado para Segmentación Semántica

En [51], los autores enfatizan en primer lugar la efectividad de la convolución *atrous*, que implica convolución con filtros aumentados. Esta técnica permite un control explícito sobre la resolución en la que se calculan las respuestas de características dentro de las redes neuronales convolucionales profundas (DCNNs). La convolución *atrous* permite la incorporación de un contexto más amplio sin aumentar el número de parámetros o la complejidad computacional.

En segundo lugar, los autores proponen el agrupamiento piramidal espacial con convolución *atrous* (ASPP) para lograr una segmentación robusta de objetos en múltiples escalas. ASPP aplica filtros con tasas de muestreo y campos de visión efectivos variables al mapa de características convolucionales entrante, capturando así objetos y contexto de imagen a diferentes escalas.

En tercer lugar, los autores mejoran la localización de los límites de los objetos mediante la combinación de métodos de las DCNN y modelos gráficos probabilísticos. Si bien la combinación común de max-pooling y reducción de tamaño en las DCNN proporciona invarianza, a menudo compromete la precisión de la localización. Para abordar este problema, los autores integran las respuestas de la última capa de DCNN con un Campo Aleatorio Condicional completamente conectado (CRF). Este enfoque de fusión, demostrado mediante análisis cualitativos y cuantitativos, mejora significativamente el rendimiento de la localización.

Implementación de Transfer Learning para atacar el desbalance de datos

La dependencia de los datos es uno de los problemas más graves en el aprendizaje profundo debido a la necesidad de un entrenamiento masivo, ya que se requiere una gran cantidad de datos para comprender los patrones de los datos. La recopilación de datos es compleja y costosa, lo que dificulta enormemente la creación de un conjunto de datos anotados de alta calidad a gran escala [56].

El aprendizaje por transferencia es una técnica valiosa en el aprendizaje automático para abordar el desafío de datos de entrenamiento limitados. Su objetivo es aprovechar el conocimiento de un dominio fuente a un dominio objetivo, superando la suposición de que los datos de entrenamiento y prueba deben ser independientes e idénticamente distribuidos (i.i.d.). Este enfoque ha demostrado ser muy beneficioso para dominios con datos de entrenamiento insuficientes, lo que permite mejoras notables en su rendimiento [56].

Para la arquitectura de aprendizaje profundo se utiliza en esta investigación a VGG-16 como pesos pre entrenados. Algunos autores, como en [57], han utilizado VGG-16 e Inception para obtener modelos U-Net precisos para la segmentación de imágenes, específicamente como codificadores. Además, los autores de [58] utilizan las capacidades de aprendizaje por transferencia de FCN para el mapeo de barrios marginales en varias imágenes satelitales, obteniendo información sobre estructuras urbanas a pequeña escala, como parches de barrios marginales, incluso en imágenes satelitales de resolución decamétrica. En otros estudios, como en [59], se utiliza VGG16 sin la capa superior como codificador para el modelo de detección de grietas para inspeccionar grietas en pavimentos de concreto, pavimentos asfálticos y puentes. De manera similar, en [60], los autores implementan el aprendizaje por transferencia entre diferentes tipos de cultivos, lo que reduce los tiempos de entrenamiento en hasta un 80%.

Función de pérdida implementada en el entrenamiento

La elección de la función de pérdida en la tarea de segmentación semántica puede afectar fuertemente el proceso de aprendizaje, y la selección es primordial debido a los problemas de desequilibrio frecuentes en este tipo de tarea. Para modelos de clasificación, la función de pérdida más utilizada es la pérdida de entropía cruzada, y para modelos de regresión, las más comunes son L1 y L2. Para la segmentación semántica, las funciones de pérdida más utilizadas son la entropía cruzada categórica y la similitud de Dice [61]. Es común combinar funciones de pérdida y utilizar esquemas ponderados para manejar el desequilibrio, debido a que la gran mayoría de los problemas involucran una clase minoritaria y un fondo de alta presencia, el uso de pesos puede ayudar a prestar más atención a la clase minoritaria [61].

La *Focal loss* [34] es una de las soluciones recientes para la segmentación semántica. Los autores propusieron una solución para abordar el desequilibrio de clases al reconfigurar la pérdida de entropía cruzada de manera que disminuya el peso de los ejemplos bien clasificados, reduciendo así la pérdida relativa para los píxeles bien clasificados y poniendo más énfasis en aquellos mal clasificados y difíciles [61].

Los autores de [61] realizan una revisión de las funciones de pérdida en arquitecturas existentes para la segmentación semántica. Algunas de ellas, como la pérdida logística multimodal en FCN. En DeepLab, los autores utilizan como función de pérdida la suma de términos de entropía cruzada para cada posición espacial en el mapa de salida de CNN. En PSPNet se implementó con dos funciones de pérdida, una para la rama principal que utiliza la pérdida de entropía cruzada para entrenar el clasificador final y otra después de la cuarta etapa, ambas con un equilibrio ponderado. Finalmente, mencionan el uso de la pérdida de Diferencia de Gradiente

en SegmPred, diseñada para mejorar los resultados al penalizar los desajustes de alta frecuencia, como los errores a lo largo de los bordes del objeto.

Se han desarrollado múltiples funciones de pérdida en el campo médico con el propósito de la segmentación semántica. Una de estas funciones es conocida como pérdida de Tversky [62], que está diseñada específicamente para la segmentación de imágenes en aplicaciones de imágenes médicas, particularmente para segmentar lesiones. En estos casos, el número de voxels que representan las lesiones suele ser significativamente menor que el número de voxels que representan las no-lesiones. Los autores del estudio sugieren una función de pérdida generalizada basada en el índice de Tversky, con el objetivo de abordar el problema de los datos desbalanceados y lograr un equilibrio óptimo entre precisión y recall durante el entrenamiento de redes neuronales convolucionales profundas totalmente tridimensionales.

4.3.2. Estrategia de Entrenamiento para la arquitectura de aprendizaje profundo

Para la estrategia de entrenamiento, tomamos decisiones basadas en el tipo de tarea, los datos disponibles y las soluciones actuales. Inicialmente, como se mencionó antes, el conjunto de datos VEPL [63] consiste en tres clases: vegetación, líneas eléctricas y fondo. Dado que nuestro objetivo es identificar el crecimiento de vegetación en las líneas eléctricas, nuestra red neuronal necesita identificar principalmente las clases de vegetación y líneas eléctricas. Sin embargo, existe una diferencia significativa en el número de píxeles entre estas clases. Cuando intentamos entrenar la red utilizando las tres clases, fue difícil identificar con precisión las líneas eléctricas debido a su geometría lineal, lo que resultó en un número relativamente pequeño de píxeles en comparación con las otras clases. En consecuencia, adoptamos la siguiente estrategia basada en el trabajo realizado por los autores en [64]:

- Las tres clases están presentes en cada imagen del conjunto de datos. Por lo tanto, decidimos crear dos conjuntos de datos basados en el conjunto de datos VEPL. Un conjunto de datos contenía las clases de vegetación y fondo, mientras que el otro contenía la clase de líneas eléctricas-vegetación. Este enfoque transformó el entrenamiento de la red neuronal de un problema de clasificación de varias clases a uno binario.
- Utilizamos funciones de pérdida personalizadas para el entrenamiento, específicamente la función de pérdida de Tversky. Esta función produjo mejores resultados en comparación con las funciones de pérdida tradicionales, ya que puso más énfasis en las clases minoritarias. Tanto las clases de vegetación como de líneas eléctricas tienen una presencia menor que la clase de fondo.
- Empleamos las arquitecturas U-Net y DeepLab, considerando pesos preentrenados para mejorar las capacidades de generalización de la red neuronal.
- Las métricas de evaluación que utilizamos fueron específicamente adaptadas para tareas de segmentación semántica.

4.3.3. Resultados de la etapa de entrenamiento

Como se mencionó anteriormente, esta solución implica la necesidad de convertir el problema de segmentación semántica multiclase en un problema de segmentación binaria. La razón fue que la segmentación semántica en este contexto es notablemente compleja debido a las características de las clases involucradas y la disparidad del total de píxeles entre clases. Para abordar estos desafíos, presentamos estratégicamente una variedad de adaptaciones de capacitación, incluida la decisión de seleccionar dos conjuntos de datos distintos al conjunto original de datos VEPL [39]. Esta distinción fue vital ya que la vegetación y las líneas eléctricas exigieron un enfoque dedicado. En consecuencia, este proceso produce dos conjuntos de datos distintos: uno que abarca la vegetación y el fondo, y otro que se enfoca en las líneas eléctricas y el fondo. Esta transformación simplificó la tarea en un desafío de segmentación binaria, lo que permitió que la red se concentrará en los aspectos esenciales de cada clase.

Al enfrentar el problema del desbalance del total de píxeles entre las clases, adoptamos funciones de pérdida personalizadas durante el entrenamiento, específicamente la función de pérdida de Tversky [62]. A diferencia de las funciones de pérdida convencionales, la pérdida de Tversky se ajusta con precisión para priorizar las clases minoritarias, como las líneas eléctricas, que tienen una presencia de píxeles comparativamente menor en las imágenes.

Con respecto a la arquitectura de redes neuronales, exploramos tres enfoques distintos: U-Net [50], U-Net con un codificador VGG-16 [50], [57], [59] y DeepLab [51]. Cada arquitectura introdujo atributos únicos para una segmentación semántica precisa.

Además, diversificamos meticulosamente la composición del conjunto de datos, incorporando conjuntos de datos originales y aumentados. La aumentación de datos abarcó transformaciones geométricas y espectrales, lo que permitió que la red neuronal mejorará su adaptabilidad a los desafíos del mundo real.

En resumen, se llevaron a cabo experimentos con 36 modelos diferentes (18 para el conjunto de datos de fondo-vegetación y 18 para el conjunto de datos de fondo-línea eléctrica), variando la composición del conjunto de datos, la arquitectura de la red neuronal y la función de pérdida. Estas variaciones se basaron en la constitución del backbone (U-Net, U-Net con VGG-16 y DeepLab), el tipo de datos utilizados (sin aumentación, con aumentación espectral o aumentación geométrica) y el tipo de función de pérdida (pérdida de Tversky y entropía cruzada binaria). Cada red neuronal se configuró según referencias específicas, siguiendo el enfoque recomendado en el caso de U-Net [50] y DeepLab [51], con ajustes mínimos como el tamaño de entrada de datos y el uso de dropout de datos. Las siguientes son las diferentes variaciones mencionadas:

- **Composición del conjunto de datos:** utilizamos tanto el conjunto de datos original como conjuntos de datos aumentados. Estas aumentaciones abarcaron transformaciones geométricas y espectrales, introduciendo así una diversidad integral en el proceso de entrenamiento.

- **Arquitectura de red neuronal:** U-Net, U-Net con codificador VGG-16 y DeepLab.
- **Función de pérdida:** la pérdida abarcaba tanto la pérdida de Tversky como la entropía cruzada binaria.

Es importante destacar que no se realizó una búsqueda exhaustiva de hiperparámetros debido a la obtención de resultados satisfactorios con las configuraciones seleccionadas, además de limitaciones tecnológicas relacionadas con el GPU. Este enfoque integral culminó en el entrenamiento de 36 redes neuronales, mejorando nuestra capacidad para detectar con precisión la invasión de vegetación en las líneas eléctricas.

Transformamos estratégicamente la tarea en un desafío de segmentación binaria para abordar las complejidades planteadas por las características de clase y las diferencias en el recuento de píxeles. Esto implicó crear dos conjuntos de datos enfocados, emplear funciones de pérdida personalizadas como la pérdida de Tversky, explorar diversas arquitecturas de redes neuronales y aprovechar los datos aumentados. Este enfoque produjo el entrenamiento de 36 redes, refinando nuestra capacidad para detectar con precisión la invasión de vegetación en las líneas eléctricas.

4.3.4. Evaluación del rendimiento de las arquitecturas entrenadas para la segmentación semántica.

A continuación, mostramos el rendimiento de las 36 redes neuronales entrenadas, basadas en [64], evaluando su precisión, entre otras métricas relacionadas con la segmentación semántica. Además, comparamos los resultados obtenidos utilizando diferentes conjuntos de datos, técnicas de aumentación, arquitecturas de redes neuronales y funciones de pérdida. Este análisis proporciona una comprensión completa de la eficacia de varias configuraciones para abordar la tarea de segmentación. Todas las redes neuronales se entrenaron utilizando una GPU NVIDIA T4(x2) en notebooks de Kaggle. En la Tabla 3 y 4, se presentan los resultados de la precisión de entrenamiento y validación para ambas clases.

Tabla 3. Máxima precisión en entrenamiento para todas las redes neuronales.

Clase	Conjunto de datos	Precisión en Entrenamiento					
		DeepLab		Unet		Unet+vgg encoder	
		BCE	Tversky	BCE	Tversky	BCE	Tversky
Línea Eléctrica	Sin aumentación	-	-	0,820	0,674	0,689	0,511
	Aumentación						
	Geométrica	0,976	0,969	0,968	0,820	0,969	0,861
	Aumentación Espectral	0,946	0,906	0,965	0,749	0,972	0,975
Vegetación	Sin aumentación	-	-	0,850	0,801	0,876	0,833
	Aumentación						
	Geométrica	0,950	0,907	0,879	0,850	0,897	0,858
	Aumentación Espectral	0,987	0,955	0,846	0,770	0,911	0,835

Tabla 4. Máxima precisión en validación para todas las redes neuronales.

Clase	Conjunto de datos	Precisión en Validación					
		DeepLab		Unet		Unet+vgg encoder	
		BCE	Tversky	BCE	Tversky	BCE	Tversky
Línea Eléctrica	Sin aumentación	-	-	0,914	0,776	0,738	0,616
	Aumentación						
	Geométrica	0,981	0,977	0,981	0,945	0,981	0,948
	Aumentación Espectral	0,968	0,938	0,982	0,890	0,982	0,981
Vegetación	Sin aumentación	-	-	0,861	0,841	0,905	0,867
	Aumentación						
	Geométrica	0,879	0,902	0,873	0,832	0,872	0,880
	Aumentación Espectral	0,874	0,873	0,833	0,799	0,882	0,858

* BCE – Binary CrossEntropy

Como podemos ver, el uso de aumentación de datos (geométrica o espectral) conduce a mejores rendimientos en el entrenamiento y la validación, también para el conjunto de datos original (sin aumentación) podemos ver que DeepLab no tiene resultados debido a la baja cantidad de ejemplos de imágenes y la complejidad de esta arquitectura. Para la clase de vegetación podemos ver un mejor desempeño en el conjunto de datos con aumentación geométrica, mostrando consistencia tanto en la fase de entrenamiento como en los conjuntos de validación, para la aumentación geométrica la mejor arquitectura fue U-Net con codificador VGG-16 y la mejor función de pérdida fue Tversky, debido al buen desempeño y los resultados similares tanto en entrenamiento como en validación se muestra que no hay *overfitting* o *underfitting*. Para la clase de línea eléctrica, el mejor conjunto de datos también es el que tiene aumentación geométrica, pero en este caso con la arquitectura DeepLab. También incluimos los resultados del criterio de intersección sobre unión (IoU), una métrica popular para la tarea de segmentación [65], IoU es el valor promedio de la intersección de la predicción y la verdad del terreno sobre su unión del conjunto de imágenes completo [66].

Cuando se trata de segmentación semántica, generalmente es preferible usar IoU como una métrica de evaluación en lugar de precisión. IoU es una métrica más adecuada para la segmentación semántica porque tiene en cuenta la precisión espacial y la localización de objetos, lo que proporciona una evaluación más significativa del rendimiento del modelo. En las Tablas 5 y 6, se presentan los resultados del IoU de entrenamiento y validación para ambas clases.

Tabla 5. Máximo IoU en entrenamiento para todas las redes neuronales.

Clase	Conjunto de datos	IoU en Entrenamiento					
		DeepLab		Unet		Unet+vgg encoder	
		BCE	Tversky	BCE	Tversky	BCE	Tversky
Línea Eléctrica	Sin aumentación	-	-	0,054	0,061	0,040	0,059
	Aumentación						
	Geométrica	0,310	0,450	0,069	0,107	0,077	0,129
	Aumentación Espectral	0,062	0,175	0,060	0,090	0,083	0,506
Vegetación	Sin aumentación	-	-	0,605	0,597	0,619	0,562
	Aumentación						
	Geométrica	0,842	0,805	0,681	0,718	0,712	0,743
	Aumentación Espectral	0,950	0,890	0,621	0,654	0,730	0,723

Tabla 6. Máximo IoU en validación para todas las redes neuronales.

Clase	Conjunto de datos	IoU en Validación					
		DeepLab		Unet		Unet+vgg encoder	
		BCE	Tversky	BCE	Tversky	BCE	Tversky
Línea Eléctrica	Sin aumentación	-	-	0,046	0,060	0,035	0,050
	Aumentación						
	Geométrica	0,140	0,221	0,024	0,065	0,029	0,073
	Aumentación Espectral	0,025	0,070	0,025	0,055	0,028	0,235
Vegetación	Sin aumentación	-	-	0,754	0,680	0,816	0,649
	Aumentación						
	Geométrica	0,764	0,824	0,716	0,768	0,719	0,779
	Aumentación Espectral	0,815	0,795	0,666	0,754	0,758	0,800

Siguiendo el mismo análisis usando IoU, podemos ver un mejor desempeño en la clase de vegetación usando la aumentación espectral pero con un poco de sobreajuste para algunas configuraciones, por otro lado, para la aumentación geométrica podemos ver un desempeño general igual tanto en entrenamiento como en validación. Para la clase de línea eléctrica, el IoU tienen un descenso drástico si los comparamos con la métrica de precisión, por lo que se requiere el uso de IoU en la tarea de segmentación semántica, más aún en conjuntos de datos de alto desequilibrio, en este caso para la clase de línea eléctrica, los mejores resultados son los que usan aumentación (geométrica como espectral), utilizando DeepLab y U-Net con codificador VGG-16.

Luego usamos todos los modelos para medir el IoU sobre los datos de prueba (conjunto de datos original) para seleccionar la mejor combinación de aumentación, arquitectura y pérdida para ambas clases, en la Tabla 7 podemos ver los resultados:

Tabla 7. IoU para todos los modelos sobre los datos de prueba.

Clase	Conjunto de Datos	IoU					
		DeepLab		Unet		Unet+vgg encoder	
		BCE	Tversky	BCE	Tversky	BCE	Tversky
Línea Eléctrica	Sin aumentación	-	-	0,504	0,427	0,344	0,295
	Aumentación	0,593	0,639	0,515	0,490	0,575	0,523
	Geométrica						
	Aumentación Espectral	0,514	0,548	0,517	0,494	0,534	0,625
Vegetación	Sin aumentación	-	-	0,687	0,624	0,740	0,318
	Aumentación	0,759	0,726	0,733	0,632	0,752	0,698
	Geométrica						
	Aumentación Espectral	0,737	0,759	0,717	0,607	0,771	0,656

* BCE – Binary CrossEntropy

En los resultados obtenidos, la aumentación de datos juega un papel crucial para mejorar el rendimiento de los modelos en ambas clases. La métrica IoU (intersección sobre unión) se utiliza para evaluar la precisión de la segmentación, y se observa que la aumentación de datos mejora constantemente los valores de IoU para las clases de vegetación y línea eléctrica.

Para la clase de vegetación, el modelo entrenado con el conjunto de datos de aumentación espectral, empleando una U-Net con codificador VGG-16 y pérdida de entropía cruzada binaria, logra el IoU más alto de 0,77. Este resultado sugiere que utilizar aumentación espectral ayuda a capturar la variabilidad en los tipos de vegetación, lo que lleva a una segmentación más precisa.

Por otro lado, la clase de línea eléctrica se beneficia significativamente del uso de la función de pérdida de Tversky debido al alto desequilibrio entre píxeles en esta clase. El modelo entrenado con el conjunto de datos de aumentación geométrico, empleando DeepLab y la pérdida de Tversky, alcanza un IoU de hasta 0,64. La pérdida de Tversky aborda efectivamente el problema del desequilibrio de clases, lo que resulta en un mejor desempeño de segmentación para los corredores de líneas eléctricas.

Estos hallazgos indican que se necesitan diferentes estrategias para optimizar los modelos de segmentación para cada clase, mostrando la efectividad de la arquitectura propuesta y la importancia de las funciones de pérdida elegidas. Estos son los mejores modelos para ambas clases:

- **Clase de vegetación:** Modelo entrenado con el conjunto de datos de aumentación espectral, utilizando U-Net con codificador VGG-16 y pérdida de entropía cruzada binaria, logrando hasta 0.77 IoU.
- **Clase de líneas eléctricas:** Modelo entrenado con el conjunto de datos de aumentación geométrica, utilizando DeepLab y pérdida de Tversky, logrando hasta 0.64 IoU.

5. Creación de flujo de automatización de segmentación de vegetación en líneas eléctricas

Utilizando las redes neuronales con mejores resultados para ambas clases presentadas en la última sección presentamos una poderosa fusión de redes neuronales para mejorar la invasión de la vegetación en las líneas eléctricas llamada VEPL-Net (Vegetation Encroachment in Power Line Corridors Network). Creamos un script en Python para generar predicciones. Presentamos el flujo de trabajo de las predicciones en la Figura 10.








Figura 10. Flujo de trabajo propuesto para VEPL-Net.

Nuestro flujo de trabajo toma una imagen como entrada para predecir la invasión de vegetación en las líneas de energía. Utilizando la mejor arquitectura obtenida para cada clase (vegetación y líneas de energía), se realizan predicciones separadas para cada clase. Posteriormente, se realiza una superposición entre las dos imágenes de predicción. Este paso final genera una alerta que indica las áreas donde ocurre la invasión de vegetación. Como se mencionó, la ventaja de este enfoque radica en la capacidad de generar predicciones más precisas para cada clase, considerando sus significativas variaciones geométricas.

En la Figura 11, podemos ver varios ejemplos de imágenes de entrada y el resultado final con las predicciones y la advertencia de invasión de vegetación.








Figura 11. Ejemplos de imágenes de entrada y el resultado final con predicciones y advertencia de invasión por vegetación.

Las predicciones obtenidas muestran un excelente rendimiento del modelo para capturar ambas clases, especialmente la clase de líneas de energía, a pesar de su alto desequilibrio, presenta una predicción sólida que conduce a una detección de invasión de vegetación altamente precisa.

6. Conclusiones

El trabajo realizado entre la creación del conjunto de datos y la selección de la mejor arquitectura de aprendizaje profundo para obtener el flujo automático ha resultado en un avance significativo en el monitoreo de la invasión de vegetación en corredores de líneas eléctricas. La creación del conjunto de datos VEPL, que consta de 3192 pares de imágenes y máscaras después de la aumentación espectral, y 3724 pares de imágenes y máscaras después de la aumentación geométrica, ha permitido el desarrollo de la arquitectura VEPL-NET, un modelo de aprendizaje profundo entrenado en ortomosaicos de drones aéreos de alta resolución.

VEPL-NET demuestra un buen rendimiento en la segmentación semántica, en la clase de vegetación, la aplicación de la aumentación espectral junto con una U-Net con codificador VGG-16 y pérdida de entropía cruzada binaria logró un puntaje de IoU de 0.77. Mientras tanto, la clase de líneas de energía obtuvo beneficios significativos de la función de pérdida de Tversky, que abordó eficazmente el desequilibrio de clases a nivel de píxeles inherente a esta categoría. El uso de un conjunto de datos de aumentación geométrica en conjunto con DeepLab y la pérdida de Tversky condujo a un IoU de hasta 0.64.

La integración de técnicas de aprendizaje profundo con drones de consumo comercial ha demostrado ser una solución rentable y eficiente para el monitoreo de corredores de líneas eléctricas. Este enfoque ofrece una mayor resolución espacial, facilidad de adquisición y datos actualizados en comparación con las imágenes de satélite tradicionales y los enfoques LiDAR. La arquitectura VEPL-NET, adaptada a las características específicas de cada clase, ha demostrado su potencial para identificar, definir y medir con precisión la invasión de vegetación, facilitando el mantenimiento efectivo y el desarrollo de estrategias de mitigación.

En general, el trabajo realizado ha abierto el camino para una solución novedosa y práctica para el monitoreo de la invasión de vegetación en corredores de líneas eléctricas. Los hallazgos sugieren que investigaciones y mejoras adicionales de estas técnicas ofrecen perspectivas prometedoras para abordar desafíos similares en diferentes países, lo que contribuirá a mejorar la confiabilidad del suministro eléctrico y mitigar las pérdidas económicas causadas por la invasión de vegetación.

Referencias

- [1] V. N. Nguyen, R. Jenssen, and D. Roverso, "Automatic autonomous vision-based power line inspection: A review of current status and the potential role of deep learning," *Int. J. Electr. Power Energy Syst.*, vol. 99, pp. 107–120, Jul. 2018, doi: 10.1016/j.ijepes.2017.12.016.
- [2] J. Ahmad, A. S. Malik, L. Xia, and N. Ashikin, "Vegetation encroachment monitoring for transmission lines right-of-ways: A survey," *Electr. Power Syst. Res.*, vol. 95, pp. 339–352, Feb. 2013, doi: 10.1016/j.epsr.2012.07.015.
- [3] M. Korki, N. D. Shankar, R. Naymeshbhai Shah, S. M. Waseem, and S. Hodges, "Automatic Fault Detection of Power Lines using Unmanned Aerial Vehicle (UAV)," in *2019 1st International Conference on Unmanned Vehicle Systems-Oman (UVS)*, Feb. 2019, pp. 1–6. doi: 10.1109/UVS.2019.8658283.
- [4] Y. Zhang, X. Yuan, W. Li, and S. Chen, "Automatic power line inspection using UAV images," *Remote Sens.*, vol. 9, no. 8, 2017, doi: 10.3390/rs9080824.
- [5] D. Li and X. Wang, "The Future Application of Transmission Line Automatic Monitoring and Deep Learning Technology Based on Vision," in *2019 IEEE 4th International Conference on Cloud Computing and Big Data Analysis (ICCCBDA)*, Apr. 2019, pp. 131–137. doi: 10.1109/ICCCBDA.2019.8725702.
- [6] Y. Lecun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015, doi: 10.1038/nature14539.
- [7] I. Maduako *et al.*, "Deep learning for component fault detection in electricity transmission lines," *J. Big Data*, vol. 9, no. 1, 2022, doi: 10.1186/s40537-022-00630-2.
- [8] B. Zhang, L. Zhao, and X. Zhang, "Three-dimensional convolutional neural network model for tree species classification using airborne hyperspectral images," *Remote Sens. Environ.*, vol. 247, 2020, doi: 10.1016/j.rse.2020.111938.
- [9] G. Lin, A. Milan, C. Shen, and I. Reid, "RefineNet: Multi-path Refinement Networks for High-Resolution Semantic Segmentation," in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Jul. 2017, pp. 5168–5177. doi: 10.1109/CVPR.2017.549.
- [10] C. Shorten and T. M. Khoshgoftaar, "A survey on Image Data Augmentation for Deep Learning," *J. Big Data*, vol. 6, no. 1, p. 60, Jul. 2019, doi: 10.1186/s40537-019-0197-0.
- [11] J. R. Ballesteros, G. Sanchez-Torres, and J. W. Branch-Bedoya, "A GIS Pipeline to Produce GeoAI Datasets from Drone Overhead Imagery," *ISPRS Int. J. Geo-Inf.*, vol. 11, no. 10, Art. no. 10, Oct. 2022, doi: 10.3390/ijgi11100508.
- [12] Z. Shang *et al.*, "Democratizing data science through interactive curation of ML pipelines," presented at the Proceedings of the ACM SIGMOD International Conference on Management of Data, 2019, pp. 1171–1188. doi: 10.1145/3299869.3319863.
- [13] R. Madaan, D. Maturana, and S. Scherer, "Wire detection using synthetic data and dilated convolutional networks for unmanned aerial vehicles," in *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, Sep. 2017, pp. 3487–3494. doi: 10.1109/IROS.2017.8206190.
- [14] Y. Zhang, X. Yuan, Y. Fang, and S. Chen, "UAV low altitude photogrammetry for power line inspection," *ISPRS Int. J. Geo-Inf.*, vol. 6, no. 1, 2017, doi: 10.3390/ijgi6010014.
- [15] S. Vemula and M. Frye, "Multi-head Attention Based Transformers for Vegetation Encroachment Over Powerline Corridors using UAV," in *2021 IEEE/AIAA 40th Digital Avionics Systems Conference (DASC)*, Oct. 2021, pp. 1–5. doi: 10.1109/DASC52595.2021.9594293.
- [16] A. Vaswani *et al.*, "Attention is all you need," presented at the Advances in Neural Information Processing Systems, 2017, pp. 5999–6009.
- [17] Y. Chen, J. Lin, and X. Liao, "Early detection of tree encroachment in high voltage

powerline corridor using growth model and UAV-borne LiDAR,” *Int. J. Appl. Earth Obs. Geoinformation*, vol. 108, p. 102740, Apr. 2022, doi: 10.1016/j.jag.2022.102740.

[18] S. Rong, L. He, L. Du, Z. Li, and S. Yu, “Intelligent Detection of Vegetation Encroachment of Power Lines With Advanced Stereovision,” *IEEE Trans. Power Deliv.*, vol. 36, no. 6, pp. 3477–3485, Dec. 2021, doi: 10.1109/TPWRD.2020.3043433.

[19] D. G. Lowe, “Distinctive image features from scale-invariant keypoints,” *Int. J. Comput. Vis.*, vol. 60, no. 2, pp. 91–110, 2004, doi: 10.1023/B:VISI.0000029664.99615.94.

[20] K. Sikorska-Lukasiewicz, “Methods of automatic vegetation encroachment detection for high voltage power lines,” presented at the Proceedings of SPIE - The International Society for Optical Engineering, 2020. doi: 10.1117/12.2565756.

[21] PubMed, “PubMed User Guide,” PubMed. Accessed: Aug. 15, 2023. [Online]. Available: <https://pubmed.ncbi.nlm.nih.gov/help/>

[22] T. Vopham, J. E. Hart, F. Laden, and Y.-Y. Chiang, “Emerging trends in geospatial artificial intelligence (geoAI): Potential applications for environmental epidemiology,” *Environ. Health Glob. Access Sci. Source*, vol. 17, no. 1, 2018, doi: 10.1186/s12940-018-0386-x.

[23] F. M. E. Haroun, S. N. M. Deros, and N. M. Din, “A Review of Vegetation Encroachment Detection in Power Transmission Lines using Optical Sensing Satellite Imagery,” *Int. J. Adv. Trends Comput. Sci. Eng.*, vol. 9, no. 1.4, pp. 618–624, Sep. 2020, doi: 10.30534/ijatcse/2020/8691.42020.

[24] M. Gazzea, M. Pacevicius, D. O. Dammann, A. Sapronova, T. M. Lunde, and R. Arghandeh, “Automated Power Lines Vegetation Monitoring Using High-Resolution Satellite Imagery,” *IEEE Trans. Power Deliv.*, vol. 37, no. 1, pp. 308–316, 2022, doi: 10.1109/TPWRD.2021.3059307.

[25] F. M. E. Haroun, S. N. M. Deros, and N. M. Din, “Detection and Monitoring of Power Line Corridor from Satellite Imagery Using RetinaNet and K-Mean Clustering,” *IEEE Access*, 2021, doi: 10.1109/ACCESS.2021.3106550.

[26] F. Mahdi Elsiddig Haroun, S. N. Mohamed Deros, M. Z. Bin Baharuddin, and N. Md Din, “Detection of Vegetation Encroachment in Power Transmission Line Corridor from Satellite Imagery Using Support Vector Machine: A Features Analysis Approach,” *Energies*, vol. 14, no. 12, p. 3393, Jan. 2021, doi: 10.3390/en14123393.

[27] J. Ahmad, A. S. Malik, M. F. Abdullah, N. Kamel, and L. Xia, “A novel method for vegetation encroachment monitoring of transmission lines using a single 2D camera,” *Pattern Anal. Appl.*, vol. 18, no. 2, pp. 419–440, May 2015, doi: 10.1007/s10044-014-0391-9.

[28] F. Azevedo *et al.*, “LiDAR-based real-time detection and modeling of power lines for unmanned aerial vehicles,” *Sens. Switz.*, vol. 19, no. 8, 2019, doi: 10.3390/s19081812.

[29] R. Zhang, B. Yang, W. Xiao, F. Liang, Y. Liu, and Z. Wang, “Automatic extraction of high-voltage power transmission objects from UAV Lidar point clouds,” *Remote Sens.*, vol. 11, no. 22, 2019, doi: 10.3390/rs11222600.

[30] A. Qayyum, I. Razzak, A. S. Malik, and S. Anwar, “Fusion of CNN and sparse representation for threat estimation near power lines and poles infrastructure using aerial stereo imagery,” *Technol. Forecast. Soc. Change*, vol. 168, p. 120762, Jul. 2021, doi: 10.1016/j.techfore.2021.120762.

[31] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” presented at the Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2016, pp. 779–788. doi: 10.1109/CVPR.2016.91.

[32] Y. Freund and R. Schapire, “Experiments with a New Boosting Algorithm,” presented at the International Conference on Machine Learning, Jul. 1996. Accessed: Jan. 09, 2024. [Online]. Available: <https://cseweb.ucsd.edu/~yfreund/papers/boostingexperiments.pdf>

[33] M. Aizerman, E. Braverman, and L. Rozonoer, “Theoretical foundation of potential

- functions method in pattern recognition,” 1964. Accessed: Jan. 09, 2024. [Online]. Available: <https://cs.uwaterloo.ca/~y328yu/classics/kernel.pdf>
- [34] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal Loss for Dense Object Detection.” arXiv, Feb. 07, 2018. doi: 10.48550/arXiv.1708.02002.
- [35] K. McGarigal, S. Stafford, and S. Cushman, “Cluster Analysis,” in *Multivariate Statistics for Wildlife and Ecology Research*, K. McGarigal, S. Stafford, and S. Cushman, Eds., New York, NY: Springer, 2000, pp. 81–128. doi: 10.1007/978-1-4612-1288-1_3.
- [36] S. Ren, K. He, R. Girshick, and J. Sun, “Faster R-CNN: Towards real-time object detection with region proposal networks,” presented at the Advances in Neural Information Processing Systems, 2015, pp. 91–99.
- [37] K. Pearson, “LIII. On lines and planes of closest fit to systems of points in space,” *Lond. Edinb. Dublin Philos. Mag. J. Sci.*, vol. 2, no. 11, pp. 559–572, Nov. 1901, doi: 10.1080/14786440109462720.
- [38] X. Liu, X. Miao, H. Jiang, and J. Chen, “Data analysis in visual power line inspection: An in-depth review of deep learning for component detection and fault diagnosis,” *Annu. Rev. Control*, vol. 50, pp. 253–277, Jan. 2020, doi: 10.1016/j.arcontrol.2020.09.002.
- [39] M. Cano-Solis, J. R. Ballesteros, and J. W. Branch-Bedoya, “VEPL Dataset: A Vegetation Encroachment in Power Line Corridors Dataset for Semantic Segmentation of Drone Aerial Orthomosaics,” *Data*, vol. 8, no. 8, Art. no. 8, Aug. 2023, doi: 10.3390/data8080128.
- [40] Z. Restrepo, S. Botero, S. González-Caro, C. Ortiz-Yusty, and E. Alvarez-Davila, *Guía de flora y fauna del sistema local de área protegidas de Envigado (Colombia)*. Medellín: Editorial Jardín Botánico de Medellín, 2018.
- [41] J. R. Ballesteros, G. Sanchez-Torres, and J. W. Branch-Bedoya, “HAGDAVS: Height-Augmented Geo-Located Dataset for Detection and Semantic Segmentation of Vehicles in Drone Aerial Orthomosaics,” *Data*, vol. 7, no. 4, Art. no. 4, Apr. 2022, doi: 10.3390/data7040050.
- [42] “Agisoft Metashape: Agisoft Metashape.” Accessed: Apr. 02, 2023. [Online]. Available: <https://www.agisoft.com/>
- [43] A. Torralba and A. A. Efros, “Unbiased look at dataset bias,” presented at the Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2011, pp. 1521–1528. doi: 10.1109/CVPR.2011.5995347.
- [44] A. Buslaev, V. I. Iglovikov, E. Khvedchenya, A. Parinov, M. Druzhinin, and A. A. Kalinin, “Albumentations: Fast and flexible image augmentations,” *Inf. Switz.*, vol. 11, no. 2, 2020, doi: 10.3390/info11020125.
- [45] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization,” presented at the Proceedings of the IEEE International Conference on Computer Vision, 2017, pp. 618–626. doi: 10.1109/ICCV.2017.74.
- [46] E. D. Cubuk, B. Zoph, D. Mane, V. Vasudevan, and Q. V. Le, “Autoaugment: Learning augmentation strategies from data,” presented at the Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2019, pp. 113–123. doi: 10.1109/CVPR.2019.00020.
- [47] I. J. Goodfellow *et al.*, “Generative Adversarial Networks,” arXiv.org. Accessed: Jan. 09, 2024. [Online]. Available: <https://arxiv.org/abs/1406.2661v1>
- [48] A. Mikołajczyk and M. Grochowski, “Data augmentation for improving deep learning in image classification problem,” presented at the 2018 International Interdisciplinary PhD Workshop, IIPHDW 2018, 2018, pp. 117–122. doi: 10.1109/IIPHDW.2018.8388338.
- [49] L. Taylor and G. Nitschke, “Improving Deep Learning with Generic Data Augmentation,” presented at the Proceedings of the 2018 IEEE Symposium Series on

Computational Intelligence, SSCI 2018, 2019, pp. 1542–1547. doi: 10.1109/SSCI.2018.8628742.

[50] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation.” arXiv, May 18, 2015. doi: 10.48550/arXiv.1505.04597.

[51] L.-C. Chen, G. Papandreou, I. Kokkinos, K. Murphy, and A. L. Yuille, “DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs.” arXiv, May 11, 2017. Accessed: May 13, 2023. [Online]. Available: <http://arxiv.org/abs/1606.00915>

[52] F. I. Diakogiannis, F. Waldner, P. Caccetta, and C. Wu, “ResUNet-a: A deep learning framework for semantic segmentation of remotely sensed data,” *ISPRS J. Photogramm. Remote Sens.*, vol. 162, pp. 94–114, 2020, doi: 10.1016/j.isprsjprs.2020.01.013.

[53] C. H. Sudre, W. Li, T. Vercauteren, S. Ourselin, and M. J. Cardoso, “Generalised dice overlap as a deep learning loss function for highly unbalanced segmentations,” *Lect. Notes Comput. Sci. Subser. Lect. Notes Artif. Intell. Lect. Notes Bioinforma.*, vol. 10553 LNCS, pp. 240–248, 2017, doi: 10.1007/978-3-319-67558-9_28.

[54] D. Peng, Y. Zhang, and H. Guan, “End-to-end change detection for high resolution satellite images using improved UNet++,” *Remote Sens.*, vol. 11, no. 11, 2019, doi: 10.3390/rs11111382.

[55] X. Yang, X. Li, Y. Ye, R. Y. K. Lau, X. Zhang, and X. Huang, “Road Detection and Centerline Extraction Via Deep Recurrent Convolutional Neural Network U-Net,” *IEEE Trans. Geosci. Remote Sens.*, vol. 57, no. 9, pp. 7209–7220, Sep. 2019, doi: 10.1109/TGRS.2019.2912301.

[56] C. Tan, F. Sun, T. Kong, W. Zhang, C. Yang, and C. Liu, “A Survey on Deep Transfer Learning,” in *Artificial Neural Networks and Machine Learning – ICANN 2018*, V. Kůrková, Y. Manolopoulos, B. Hammer, L. Iliadis, and I. Maglogiannis, Eds., in Lecture Notes in Computer Science. Cham: Springer International Publishing, 2018, pp. 270–279. doi: 10.1007/978-3-030-01424-7_27.

[57] R. Giorgiani do Nascimento and F. Viana, “Satellite Image Classification and Segmentation with Transfer Learning,” in *AIAA Scitech 2020 Forum*, in AIAA SciTech Forum., American Institute of Aeronautics and Astronautics, 2020. doi: 10.2514/6.2020-1864.

[58] M. Wurm, T. Stark, X. X. Zhu, M. Weigand, and H. Taubenböck, “Semantic segmentation of slums in satellite images using transfer learning on fully convolutional neural networks,” *ISPRS J. Photogramm. Remote Sens.*, vol. 150, pp. 59–69, 2019, doi: 10.1016/j.isprsjprs.2019.02.006.

[59] T. Chen *et al.*, “Pavement crack detection and recognition using the architecture of segNet,” *J. Ind. Inf. Integr.*, vol. 18, 2020, doi: 10.1016/j.jii.2020.100144.

[60] P. Bosilj, E. Aptoula, T. Duckett, and G. Cielniak, “Transfer learning between crop types for semantic segmentation of crops versus weeds in precision agriculture,” *J. Field Robot.*, vol. 37, no. 1, pp. 7–19, 2020, doi: 10.1002/rob.21869.

[61] A. Garcia-Garcia, S. Orts-Escolano, S. Oprea, V. Villena-Martinez, P. Martinez-Gonzalez, and J. Garcia-Rodriguez, “A survey on deep learning techniques for image and video semantic segmentation,” *Appl. Soft Comput.*, vol. 70, pp. 41–65, Sep. 2018, doi: 10.1016/j.asoc.2018.05.018.

[62] S. S. M. Salehi, D. Erdogmus, and A. Gholipour, “Tversky loss function for image segmentation using 3D fully convolutional deep networks.” arXiv, Jun. 18, 2017. doi: 10.48550/arXiv.1706.05721.

[63] M. Cano-Solis, J. R. Ballesteros, and J. W. Branch, “VEPL dataset: A Vegetation Encroachment in Power Line Corridors Dataset for Semantic Segmentation in Drone Aerial Orthomosaics”, Accessed: May 10, 2023. [Online]. Available: <https://zenodo.org/record/7800234/preview/ORTHOMOSAICS-DSM-MASK.zip>

- [64] M. Cano-Solis, J. R. Ballesteros, and G. Sanchez-Torres, "VEPL-Net: A Deep Learning Ensemble for Automatic Segmentation of Vegetation Encroachment in Power Line Corridors Using UAV Imagery," *ISPRS Int. J. Geo-Inf.*, vol. 12, no. 11, Art. no. 11, Nov. 2023, doi: 10.3390/ijgi12110454.
- [65] H. L. Yang, J. Yuan, D. Lunga, M. Laverdiere, A. Rose, and B. Bhaduri, "Building Extraction at Scale Using Convolutional Neural Network: Mapping of the United States," *IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens.*, vol. 11, no. 8, pp. 2600–2614, 2018, doi: 10.1109/JSTARS.2018.2835377.
- [66] Q. Zhu, C. Liao, H. Hu, X. Mei, and H. Li, "MAP-Net: Multiple Attending Path Neural Network for Building Footprint Extraction from Remote Sensed Imagery," *IEEE Trans. Geosci. Remote Sens.*, vol. 59, no. 7, pp. 6169–6181, 2021, doi: 10.1109/TGRS.2020.3026051.