



Método de autoaprendizaje basado en Machine Learning aplicado a la dieta de un individuo con Colitis Ulcerativa. Caso de estudio: Paciente Juan Pablo Aguirre Martínez

Juan Pablo Aguirre Martínez

Universidad Nacional de Colombia
Facultad de Minas, Departamento de Ciencias de la Computación y de la Decisión
Medellín, Colombia
2025

Método de autoaprendizaje basado en Machine Learning Aplicado a la dieta de un individuo con Colitis Ulcerativa. Caso de estudio: Paciente Juan Pablo Aguirre Martínez

Juan Pablo Aguirre Martínez

Tesis presentada como requisito parcial para optar al título de:

Magister en Ingeniería – Analítica

Director (a):

Ph.D. Albeiro Espinosa Bedoya

Línea de Investigación:

Profundización

Grupo de Investigación:

Calidad de Software

Universidad Nacional de Colombia

Facultad de Minas, Departamento de Ciencias de la Computación y de la Decisión

Medellín, Colombia

2025

Nos pasamos la vida esperando que pase algo... Y lo único que pasa es la vida. Con agradecimiento de corazón a mis padres, hermanos, amigos, mentores, compañeros, quienes me han apoyado y enseñado el valor de los momentos. Esta también, una muestra de respeto hacia todas las personas que sufren de Enfermedad Inflamatoria Intestinal: no dejen de luchar ni de buscar la fuerza para sobreponerse ante los obstáculos de la vida. En lugar de decir 'no puedo', pregúntate '¿cómo puedo lograrlo?'.

Agradecimientos

Una mención especial a la Universidad Nacional de Colombia, mi Alma Mater, que brinda oportunidades invaluableles de crecimiento a todas las personas, sin distinción de estrato social, raza, color u origen.

Igualmente, mi profunda gratitud al docente Ph.D. Albeiro Espinosa Bedoya por su invaluable apoyo, paciencia y orientación académica durante el desarrollo de este proyecto. Su guía fue luz esencial en los momentos de dificultad.

Resumen

Método de autoaprendizaje basado en Machine Learning Aplicado a la dieta de un individuo con Colitis Ulcerativa. Caso de estudio: Paciente Juan Pablo Aguirre Martínez

La Colitis Ulcerativa (*CU*), es una Enfermedad Inflamatoria Intestinal (*EII*), crónica que afecta a aproximadamente 1 de cada 1000 personas en el mundo. Esta condición autoinmune provoca inflamación y úlceras en el colon, desencadenando síntomas como diarrea, sangrado, dolor y fatiga, reduciendo significativamente la calidad de vida. La severidad puede oscilar entre leve a grave, e incluso puede ser potencialmente mortal. Si bien no existe una cura, la nutrición personalizada es clave en el manejo de los síntomas. Este trabajo propone un método basado en técnicas de autoaprendizaje y *Machine Learning* para ajustar la alimentación de individuos con *CU*, tomando como caso de estudio al paciente Juan Pablo Aguirre Martínez. La justificación de este radica en la falta de literatura previa sobre la aplicación de sistemas de *Machine Learning* a la dieta de personas con *CU*.

La metodología incluye la construcción de un conjunto de datos, la revisión y evaluación de técnicas de *Machine Learning*. Precisamente, se consideró la capacidad del modelo para procesar datos temporales y aprender de manera continua, lo que llevó a la elección del modelo *LSTM*.

Se espera que el método propuesto contribuya al desarrollo de una herramienta innovadora que mejore la calidad de vida de personas con *CU* y fomente la exploración de nuevas soluciones en el ámbito de la medicina.

Palabras clave: Colitis Ulcerativa, Machine Learning, Método de Autoaprendizaje, Aprendizaje no supervisado, aprendizaje supervisado, Alimentación, Nutrición.

Abstract

Self-Learning Method Based on Machine Learning Applied to the Diet of an Individual with Ulcerative Colitis. Case Study: Patient Juan Pablo Aguirre Martínez

Ulcerative Colitis (*UC*) is a chronic Inflammatory Bowel Disease (*IBD*) affecting approximately 1 in 1000 people worldwide. This autoimmune condition causes inflammation and ulcers in the colon, triggering symptoms such as diarrhea, bleeding, pain, and fatigue, significantly reducing the patient's quality of life. The severity of the disease can range from mild to critical, and in extreme cases, it may even become life-threatening. Although there is no cure, personalized nutrition plays a key role in symptom management.

This study proposes a method based on self-learning techniques and *Machine Learning* to adjust the diet of individuals with *UC*, using patient Juan Pablo Aguirre Martínez as a case study. The justification for this research lies in the lack of prior literature on the application of *Machine Learning* systems to the diet of individuals with *UC*.

The methodology includes the construction of a dataset, as well as the review and evaluation of *Machine Learning* techniques. Specifically, the model's ability to process temporal data and continuously learn was considered, leading to the selection of the *LSTM* model.

The proposed method aims to develop an innovative tool that enhances the quality of life for individuals with *UC* while fostering the exploration of novel solutions in medicine.

Keywords: Ulcerative Colitis, Machine Learning, Self-Learning Method, Unsupervised Learning, Supervised Learning, Diet, Nutrition.

Contenido

	Pág.
Resumen	VII
Lista de figuras.....	X
Lista de tablas	XI
Lista de Símbolos y abreviaturas.....	XII
1. Introducción	13
1.1 Planteamiento del problema.....	13
1.2 Justificación.....	14
1.3 Objetivos	15
1.3.1 Objetivo general.....	15
1.3.2 Objetivos específicos.....	15
1.4 Metodología	16
1.5 Alcances del Trabajo.....	17
2. Marco teórico.....	19
3. Revisión sistemática de literatura.....	21
3.1 Planeando la revisión	22
3.1.1 Preguntas de investigación	22
3.2 Realizando la revisión	23
3.2.1 Identificación de las fuentes de datos	23
3.2.2 Estrategias de búsqueda	23
3.2.3 Criterios de elegibilidad.....	24
3.3 Resultados de la revisión	25
3.4 Antecedentes y discusiones	27
4. Método de autoaprendizaje basado en Machine Learning Aplicado a la dieta de un individuo con Colitis Ulcerativa.....	31
4.1 Desarrollo del conjunto de datos	31
4.1.1 Definición de la sintomatología	38
4.2 Método de autoaprendizaje basado en Machine Learning.....	39
4.2.1 Proceso de normalización.....	41
4.2.2 Balanceo de clases.....	41
4.2.3 Reducción de dimensionalidad	43
4.2.4 Modelos de Machine Learning	45
4.2.5 Resultados.....	51

4.3	Discusión y validación del método	57
4.3.1	Comparación de modelos.....	57
4.3.2	Elección del modelo y validación del método	58
5.	Conclusiones y recomendaciones	61
5.1	Conclusiones	61
5.2	Recomendaciones	63
A.	Anexo: Código Fuente.....	65
	Bibliografía	67

Lista de figuras

	Pág.
Figura 1: <i>Flujo de proceso en la RSL.</i>	26
Figura 2: <i>Diagrama de ingesta.</i>	32
Figura 3: <i>Números de elementos consumidos en la dieta.</i>	36
Figura 4: <i>Distribución de la sintomatología previa al balanceo.</i>	42
Figura 5: <i>Distribución de la sintomatología posterior al balanceo.</i>	42
Figura 6: <i>Gráfico de componentes y varianza explicada acumulada.</i>	44
Figura 7: <i>Arquitectura modelos clásicos.</i>	47
Figura 8: <i>Historial de optimización de hiperparámetros.</i>	48
Figura 9: <i>Importancias de hiperparámetros.</i>	48
Figura 10: <i>Función de pérdida XGBoost.</i>	52
Figura 11: <i>Función de pérdida LSTM.</i>	52
Figura 12: <i>Exactitud Modelos clásicos.</i>	53
Figura 13: <i>Exactitud XGBoost.</i>	54
Figura 14: <i>Función de Exactitud LSTM.</i>	54
Figura 15: <i>Curva ROC Modelos clásicos.</i>	55
Figura 16: <i>Curva ROC XGboost.</i>	56
Figura 17: <i>Curva ROC LSTM.</i>	56
Figura 18: <i>Comparación cualitativa de los modelos.</i>	58

Lista de tablas

	Pág.
Tabla 1-1: <i>Descripción de la metodología.</i>	16
Tabla 3-1: <i>Preguntas y objetivos de investigación.</i>	22
Tabla 3-2: <i>Fuentes de datos.</i>	23
Tabla 3-3: <i>Palabras claves.</i>	23
Tabla 3-4: <i>Cadenas y frases de búsqueda.</i>	24
Tabla 3-5: <i>Criterios de inclusión.</i>	25
Tabla 3-6: <i>Resultados de la revisión.</i>	25
Tabla 4-1: <i>Carbohidratos.</i>	33
Tabla 4-2: <i>Bebidas.</i>	33
Tabla 4-3: <i>Medicamentos.</i>	34
Tabla 4-4: <i>Frutas.</i>	34
Tabla 4-5: <i>Proteínas.</i>	35
Tabla 4-6: <i>Suplementos.</i>	35
Tabla 4-7: <i>Grasas.</i>	35
Tabla 4-8: <i>Hongos.</i>	35
Tabla 4-9: <i>Vegetales.</i>	35
Tabla 4-10: <i>Correlación de elementos consumidos.</i>	36
Tabla 4-11: <i>Indicadores sintomáticos.</i>	37
Tabla 4-12: <i>Escala de Bristol.</i>	38
Tabla 4-13: <i>Técnicas utilizadas.</i>	40
Tabla 4-14: <i>Parametrización de modelos clásicos.</i>	46

Lista de Símbolos y abreviaturas

Símbolos con letras latinas

Símbolo	Término	Unidad SI	Definición
y	Sintomatología	bit	$y \in \{0,1\}$

Superíndices

Superíndice	Término
n	Exponente, potencia

Abreviaturas

Abreviatura	Término
<i>UC, CU</i>	Ulcerative Colitis, Colitis Ulcerativa o Ulcerosa
<i>ML</i>	Machine Learning, Aprendizaje de Máquinas
<i>IBD, EII</i>	Inflammatory Bowel Disease, Enfermedad Inflamatoria Intestinal
<i>RSL</i>	Revisión Sistemática de Literatura
<i>SMOTE</i>	Synthetic Minority Over-sampling Technique, Técnica de Sobremuestreo de Minorías Sintéticas
<i>PCA</i>	Principal Component Analysis, Análisis de Componentes Principales
<i>SVM</i>	Support Vector Machine, Máquinas de Vectores de Soporte
<i>KNN</i>	K-Nearest Neighbors, K Vecinos Más Cercanos
<i>NB</i>	Naive Bayes
<i>RF</i>	Random Forest, Bosque Aleatorio
<i>XGBoost</i>	Extreme Gradient Boosting, Potenciación de Gradiente Extremo
<i>LSTM</i>	Long Short-Term Memory, Memoria a Largo y Corto Plazo
<i>RNN</i>	Recurrent Neural Network, Red Neuronal Recurrente
<i>AUC</i>	Área Under the Curve, Área Bajo la Curva
<i>ROC</i>	Receiver Operating Characteristic, Curva Característica de Operación del Receptor

1. Introducción

1.1 Planteamiento del problema

La Colitis Ulcerativa es una enfermedad inflamatoria crónica intestinal que afecta el colon y al recto, causando inflamación y úlceras en su revestimiento. Esta, se considera como una enfermedad autoinmune, en la que el sistema inmunológico del cuerpo ataca las células sanas del colon y el recto (Danese & Fiocchi, 2011). Hoy en día, la Colitis Ulcerativa afecta aproximadamente 7 millones de personas en el mundo (World IBD Day, 2022). La sintomatología puede incluir diarrea, sangrado, dolor abdominal, fiebre, fatiga y pérdida de peso. Además, puede variar de leve grave (Caron et al., 2023), y en algunos casos puede ser potencialmente mortal (Kaplan, 2015). Para resaltar, no se conoce una causa exacta, sin embargo, se cree que hay una combinación de factores genéticos, ambientales e inmunológicos que pueden contribuir al desarrollo de esta (Khor et al., 2011).

Un método de autoaprendizaje con *Machine Learning* es un algoritmo de aprendizaje automático que puede instruirse y mejorar a partir de un conjunto de datos. Así, partiendo de la oportunidad de que el autoaprendizaje podría utilizarse como una herramienta para abordar la sintomatología presentada por la enfermedad de la Colitis Ulcerativa, se encuentra que existen múltiples sistemas de *Machine Learning* aplicados en distintas disciplinas, no obstante, no se cuenta con investigación de estos adaptados a la nutrición y mucho menos en las personas con enfermedades inflamatorias intestinales como la Colitis Ulcerativa, según se analizó en la revisión del estado del arte.

Por otra parte, existen diversas fuentes científicas, las cuales concluyen que una nutrición adecuada y personalizada, puede ayudar a aliviar la sintomatología, reducir el relapso de los pacientes con esta enfermedad. Según Keshteli et al. (2019), se ha realizado una revisión de intervenciones dietéticas controladas aleatorizadas para examinar la relación entre la dieta en la patogénesis y el manejo de la Colitis Ulcerosa. Adicionalmente, en un

estudio prospectivo de cohorte realizado por Jowett et al. (2004), investigó la influencia de los factores dietéticos en la evolución clínica de la enfermedad. Asimismo, Burke et al. (1997), enfatizaron en su artículo que la nutrición desempeña un papel relevante en el tratamiento de esta. En consecuencia, todos estos autores sugieren que ciertos factores nutricionales pueden tener un impacto significativo en el curso clínico de la enfermedad.

1.2 Justificación

Actualmente, la enfermedad inflamatoria intestinal (*EII*) denominada Colitis Ulcerativa (*CU*), afecta aproximadamente 7 millones de personas en el mundo (World IBD Day, 2022). El impacto en los individuos que la padecen es bastante alto, presentando severas sintomatologías crónicas como diarrea, sangrado, dolor abdominal, fiebre, fatiga y pérdida de peso (Kaplan, 2015). Esto, puede llegar a tener un efecto devastador en el entorno social, laboral y en la salud mental del paciente.

El papel de la dieta es de alta importancia en la enfermedad inflamatoria intestinal, que incluye a la Colitis Ulcerativa. Así, una dieta adecuada e individualizada puede ser beneficiosa y fundamental para el tratamiento de la *CU* (De Castro et al., 2021).

Con el auge del desarrollo de la Inteligencia Artificial, el uso de técnicas de *Machine Learning* en diversas áreas se ha vuelto cada vez más popular. Se alude al método autoaprendizaje con *Machine Learning* como un algoritmo de aprendizaje automático que puede instruirse y mejorar a partir de un conjunto de datos (Alpaydin, 2010). Por ejemplo, se encuentran aplicaciones para la clasificación de imágenes hiperespectrales (Dopido et al., 2013), programas de ajedrez evolutivo (Fogel et al., 2004), redes neuro-sinápticas basadas en óptica (Feldmann et al., 2019), sistemas de recomendación por medio del control de la nutrición de individuos (Cunha & Duarte, 2022), sistemas de conducción energéticamente eficiente (Qi et al., 2019), reconstrucción de estructuras neuronales del cerebro (H. Chen et al., 2015), detección de noticias falsas en redes sociales Li et al. (2022), modelo de educación personalizada para estudiantes (Pant et al., 2017). Yendo más allá, en el campo médico durante 2017, Wickramasinghe et al. presentaron una investigación para buscar un plan de dieta adecuado para pacientes con Enfermedad Renal Crónica (*CKD*), según los niveles de potasio en la sangre. Cabe señalar, la salud es

una de las áreas con mayor crecimiento a nivel mundial, esta se considera rica en información, pero a menudo carece de conocimiento valioso. Por ello, las técnicas de minería de datos y aprendizaje de máquinas se han venido implementando para mejorar la toma de decisiones de los profesionales competentes, específicamente en nutrición, al definir si un paciente necesita una atención especializada (Reis et al., 2017). En cuanto a esto, se han propuesto sistemas para mejorar la salud de pacientes con enfermedades crónicas, en función de parámetros de salud e informes médicos se recomiendan planes de dieta para mejorar estos parámetros usando algoritmos de árboles de clasificación (Mogaveera et al., 2021). Igualmente, Connor (2019), describe como el aprendizaje automático puede ayudar a los anestesiólogos a tomar decisiones y a la resolución de preguntas clínicas, así, llevar la anestesiología hacia un descubrimiento asistido por el aprendizaje de máquinas.

Por consiguiente, aplicar el método de autoaprendizaje basado en *Machine Learning* a la dieta de un individuo con Colitis Ulcerativa representa una oportunidad, la cual podría generar un instrumento en pro de la mejora en la calidad de vida de las personas que diariamente conviven con esta condición. Lo anterior, a partir de aprender de las reacciones del paciente a los alimentos que ingesta y, por ende, ajustar su consumo.

1.3 Objetivos

1.3.1 Objetivo general

Desarrollar un método para ajustar la alimentación personalizada de individuos con Colitis Ulcerativa basado en técnicas de autoaprendizaje por *Machine Learning*.

1.3.2 Objetivos específicos

1. Construir el conjunto de datos de alimentación, con las variables nutricionales y sintomatológicas.
2. Proponer un método fundamentado en técnicas de autoaprendizaje en *Machine Learning* a partir de las identificadas en la literatura.
3. Validar el método de autoaprendizaje propuesto con los datos de prueba para el caso de estudio.

1.4 Metodología

Para llevar a cabo este proyecto, es necesario la construcción de un conjunto de datos de alimentación, con las variables nutricionales y fisiológicas, por esta razón, se recolectarán los datos singulares del individuo que conformarán el grupo.

Luego, al analizar exhaustivamente las técnicas más importantes de *Machine Learning* encontradas en la literatura enfocadas en autoaprendizaje, se seleccionará la que se considere la más adecuada para el caso de condición presentada.

Por último, se procederá a separar los datos en un conjunto de entrenamiento y otro de prueba para validar el método de autoaprendizaje propuesto con estos, para presentar un informe con los análisis, resultados y la proposición.

Tabla 1-1: Descripción de la metodología.

Objetivos	Actividades	Indicadores
Construir el conjunto de datos de alimentación, con las variables nutricionales y sintomatológicas.	1. Consultar y extraer el conjunto de datos general de alimentos con sus características nutricionales. 2. Limpieza del grupo de datos. 3. Construir el conjunto de datos individualizado para el caso de estudio con las variables sintomatológicas por alimento.	Conjunto de datos completo y listo para ser cargado.
Proponer un método a partir del análisis de las técnicas más relevantes de Machine Learning enfocadas en autoaprendizaje identificadas en la literatura.	1. Revisión de la literatura. 2. Numeración de las metodologías utilizadas en la literatura. 3. Análisis de las metodologías. 4. Selección y consigna por ajuste de la técnica que permita una mayor interacción de las variables.	Método de autoaprendizaje.
Validar el método de autoaprendizaje propuesto con los datos de prueba para el caso de estudio.	1. Preprocesamiento y división del conjunto de datos de entrenamiento y prueba. 2. Entrenamiento del modelo y predicción para el conjunto de validación. 3. Cálculo de métricas, es decir, precisión y exactitud del modelo. 4. Creación de informe con el compendio del desarrollo.	+ Predicción del modelo. + Métricas de precisión y exactitud. + Informe compendio.

1.5 Alcances del Trabajo

Este trabajo desarrollará un método de autoaprendizaje basado en *Machine Learning* Aplicado a la dieta de un individuo con Colitis Ulcerativa, según la revisión de literatura realizada no existe un trabajo similar aplicado al mismo caso por lo que no existe material para revisar y comparar resultados. A partir de esto, se pretende desarrollar el conjunto de datos base aplicado al caso de estudio, adicionalmente, el método el cual contiene el modelo. Finalmente, la predicción usando el modelo y las métricas diligenciadas en un informe compendio.

2. Marco teórico

Colitis Ulcerativa

Es una enfermedad inflamatoria intestinal crónica, esta se caracteriza por la inflamación, ulceración de la mucosa del colon y el recto. Esta enfermedad autoinmune puede afectar a cualquier persona, sin importar su edad. Además, tiene un amplio espectro de síntomas, incluyendo diarrea, cólicos, fiebre, fatiga, sangrado rectal y pérdida de peso (Danese & Fiocchi, 2011).

Esta enfermedad inflamatoria intestinal (*EII*), junto con la enfermedad de Crohn son bastantes comunes, y su prevalencia está aumentando en todo el mundo (Kaplan, 2015). Según la organización Mundial de la Salud la *CU* afecta a aproximadamente 7 millones de personas en todo el mundo (World IBD Day, 2022).

Cabe señalar, no se conoce causa exacta, pero se cree que hay una combinación de factores genéticos, ambientales e inmunológicos que pueden contribuir al desarrollo de esta (Khor et al., 2011).

Asimismo, existen diversas alternativas terapéuticas orientadas al manejo integral de esta enfermedad, cuyo objetivo fundamental es controlar la inflamación activa, inducir la remisión y prevenir futuros brotes. Dentro de los tratamientos farmacológicos más comúnmente empleados, se encuentran los medicamentos antiinflamatorios, tales como los aminosalicilatos (mesalazina), para casos leves a moderados; corticosteroides empleados principalmente durante episodios agudos o exacerbaciones de la enfermedad; e inmunosupresores como la azatioprina o mercaptopurina, que buscan mantener una remisión sostenida a largo plazo. Por otro lado, las terapias biológicas como infliximab, adalimumab, golimumab o vedolizumab representan una opción avanzada, al ser anticuerpos monoclonales, que son proteínas especiales creadas en laboratorio, las cuales

neutralizan las moléculas implicadas en el proceso inflamatorio y controlan la enfermedad, especialmente en pacientes con respuesta insuficiente a terapias convencionales (Feuerstein & Cheifetz, 2014). En situaciones particulares, cuando el tratamiento farmacológico no es eficaz y surgen complicaciones significativas como hemorragias severas, perforación o displasia de alto grado, podría considerarse una intervención quirúrgica, siendo la colectomía parcial o total una de las alternativas más frecuentes y efectivas (Magro et al., 2017). Para finalizar, los factores dietéticos específicos, el manejo adecuado del estrés y cambios en el estilo de vida son fundamentales en los pacientes que padecen esta condición.

Alimentación

Se refiere al proceso de proporcionar al organismo los nutrientes necesarios a través del consumo de alimentos. Es un acto voluntario que implica elegir, preparar e ingerir alimentos que posteriormente serán digeridos y utilizados por el cuerpo. Una alimentación equilibrada y adecuada contribuye significativamente a la prevención de enfermedades, promueve una buena salud gastrointestinal y fortalece el sistema inmunológico.

Según, De Castro et al. (2021), una alimentación adecuada y bien estructurada es esencial para una salud integral del sistema gastrointestinal, reducir el riesgo, la gravedad y hasta prevenir *EII*. Por el contrario, una alimentación deficiente, desequilibrada o basada en alimentos procesados, con altos niveles de grasas saturadas, azúcares refinados y aditivos químicos, puede aumentar la inflamación intestinal, deteriorar la función inmunológica y predisponer al organismo a diversas patologías gastrointestinales.

Nutrición

Es la ciencia interdisciplinar que estudia cómo los alimentos que se consumen afectan la salud y el bienestar del cuerpo humano. Va más allá del acto voluntario de alimentarse, ya que se centra en cómo el cuerpo procesa, utiliza y aprovecha los nutrientes contenidos en los alimentos para mantener funciones vitales, crecer, reparar tejidos y prevenir enfermedades. Diversos estudios han encontrado una relación directa entre la nutrición y el desarrollo o manejo de la enfermedad inflamatoria intestinal (De Castro et al., 2021). Una buena nutrición permite mantener una microbiota intestinal equilibrada, fortalece la barrera intestinal y reduce la inflamación crónica asociada a estas enfermedades.

3. Revisión sistemática de literatura

En los últimos años, los avances en medicina y tecnología han sido significativos. Sin embargo, hasta la fecha no se han encontrado estudios ni artículos que apliquen técnicas de autoaprendizaje (*self-learning*), a la dieta de personas con Colitis Ulcerativa. A pesar de esta ausencia específica en la literatura, se ha observado el uso de técnicas de *Machine Learning* en diversos campos, lo que ofrece una base de referencia.

Ante la falta de investigaciones específicas, se ha buscado explorar literatura relevante para identificar enfoques que puedan adaptarse a este contexto. Este análisis tiene como objetivo sentar los cimientos para este desarrollo.

Por lo tanto, se ha llevado a cabo un proceso de revisión sistemática de la literatura (*RSL*), siguiendo las pautas para la realización de revisiones sistemáticas de literatura en software (Kitchenham & Charters, 2007), y la declaración *PRISMA* (Page et al., 2021), con las adaptaciones y ajustes pertinentes según las limitaciones ya mencionadas.

3.1 Planeando la revisión

3.1.1 Preguntas de investigación

Se establecieron cuatro preguntas de investigación de acuerdo con los recursos que se iban encontrando. Estas son:

Tabla 3-1: Preguntas y objetivos de investigación.

Índice	Pregunta de investigación	Objetivo
I	¿Cuál es la viabilidad y posibles enfoques para aplicar técnicas de autoaprendizaje en la sintomatología aplicada a la dieta para personas con CU, considerando la evidencia del uso de <i>Machine Learning</i> ?	Explorar la factibilidad de utilizar metodologías de autoaprendizaje para revisar la sintomatología adaptada a la ingesta de pacientes con Colitis Ulcerativa.
II	¿Cuál es el panorama general de las investigaciones sobre el concepto de autoaprendizaje en el ámbito de aprendizaje de máquinas?	Identificar y examinar los principales enfoques, tendencias, presentes en la literatura científica que aborda de manera conjunta técnicas de aprendizaje de máquinas aplicadas al autoaprendizaje.
III	¿Cuál es el espectro de aplicaciones de aprendizaje de máquinas en campos de la nutrición, la medicina?	Reconocer y analizar las diversas aplicaciones de Machine Learning en la investigación y práctica relacionadas con la salud.
IV	¿Qué conceptos, nociones de aprendizaje de máquinas, medicina, áreas relacionadas deben estar claros durante el desarrollo de este trabajo?	Establecer, entender y mencionar con claridad las múltiples ideas empleadas en este documento.

3.2 Realizando la revisión

3.2.1 Identificación de las fuentes de datos

La RSL se concretó haciendo uso de todos los recursos, librerías o plataformas digitales disponibles, los cuales reúnen una amplia cantidad de publicaciones científicas a nivel mundial en múltiples disciplinas.

Tabla 3-2: *Fuentes de datos.*

Fuente	Tipo	URL
<i>Scopus</i>	Base de datos bibliográfica multidisciplinaria.	https://www.scopus.com/
<i>IEEE Xplore</i>	Repositorio digital especializado en ingeniería y tecnología.	https://ieeexplore.ieee.org/
<i>NIH – National Library of Medicine</i>	Base de datos biomédica y de salud.	https://pubmed.ncbi.nlm.nih.gov/
<i>ResearchGate</i>	Red académica y repositorio de publicaciones.	https://www.researchgate.net/
<i>NEJM – The New England Journal of Medicine</i>	Revista científica especializada en medicina y ciencias de la salud.	https://www.nejm.org/
<i>Nature Journal</i>	Revista científica multidisciplinaria de alto impacto.	https://www.nature.com/

3.2.2 Estrategias de búsqueda

La estrategia de búsqueda definida permite filtrar la información disponible en los recursos de datos de tal manera que se acerque a las preguntas de investigación. Esta, incluyó términos o palabras, frases, cadenas para consultar en dichas plataformas.

Tabla 3-3: *Palabras claves.*

Palabra clave	Término similar
<i>Ulcerative Colitis</i>	Colitis Ulcerativa o Ulcerosa
<i>Machine Learning</i>	Aprendizaje de Máquinas
<i>Self-learning</i>	Autoaprendizaje
<i>Nutrition</i>	Nutrición - alimentación
<i>Research</i>	Investigación

Seguidamente, se disponen unas cadenas y frases para cada pregunta. Así:

Tabla 3-4: Cadenas y frases de búsqueda.

Pregunta	Tipo	Descripción
I	Cadena	ALL (("Ulcerative Colitis" OR "Inflammatory bowel disease" OR "Crohn's disease") AND ("Recommender system" OR "Food Recommendations") AND ("Artificial vision" OR "Computer vision" OR "Deep learning" OR "Machine Learning" OR "Artificial Intelligence") AND ("Food" OR "Diet" OR "Nutrition"))
II	Cadena	TITLE ("self-learning") AND TITLE-ABS-KEY ("Machine Learning") Machine Learning in nutrition, Machine Learning and nutrition, Machine Learning algorithms and Medicine, Machine Learning algorithms and health, dietary prediction using Machine Learning, optimizing nutrition using Machine Learning, Machine Learning in Ulcerative Colitis, etc.
III, IV	Frase	

Es preciso mencionar, las cadenas de búsqueda se utilizaron en *Scopus*, mientras que en las otras plataformas se emplearon frases y palabras claves. Adicionalmente, para obtener definiciones, justificaciones y nociones generalizadas de Colitis Ulcerativa se consultaron *The New England Journal of Medicine* y *Nature Journal*, etc.

3.2.3 Criterios de elegibilidad

En este escenario, se eligen los documentos que en términos generales responden a las preguntas de investigación bajo ciertos criterios de inclusión o exclusión. Por esta razón, se abarcan los textos que abordan las áreas de aplicación, herramientas tecnológicas, técnicas, métodos y algoritmos. Partiendo de esta proposición, se detallan los criterios de selección:

- ✓ **Idioma:** español, inglés.
- ✓ **Rango de fecha:** publicaciones del año 2000 en adelante.
- ✓ **Área temática:** ciencias de la computación, ingeniería, medicina.
- ✓ **Tipo de documento:** artículo, artículo de conferencia, capítulo de libro, revisión.
- ✓ **Tipo de fuente:** revista, libro, actas de congreso.

Por añadidura, conforme con Kitchenham & Charters (2007), los trabajos se pueden seleccionar por título y resumen.

Tabla 3-5: *Criterios de inclusión.*

Pregunta	Descripción de criterio
I, II	✓ Se encuentran las palabras de la cadena cumpliendo los mismos condicionales, ya sea en el título o en el resumen.
	✓ Cuenta con más de 30 citaciones.
	✓ Implementa la frase o las palabras que la conforman en el texto del título o el resumen.
III, IV	✓ Cuenta con las palabras claves en el título o en el resumen.

Se subraya que la cantidad de citaciones se considera un factor notable, y esto filtra una gran cantidad de recursos de forma inmediata.

De lo más relevante, es evaluar la calidad, especificidad, enfoque de los objetivos, problemática y contribución de cada documento. Por eso, se revisó que la relación, aunque general, fuera clara. Puntualmente, para la selección definitiva se revisó a mayor profundidad los textos incluidos para revisar presentaban especificidad sobre las técnicas, definiciones utilizadas en el resumen y si incluían las palabras clave a lo largo de estos.

3.3 Resultados de la revisión


La búsqueda se hizo durante los años 2023, 2024. Se hallaron 457 artículos, de los cuales se incluyeron 83 de acuerdo con los criterios, descartando 374. Finalmente, se revisó la calidad, especificidad y claridad de los artículos incluidos, dejando así un total de 33 artículos seleccionados y 424 artículos excluidos.

Tabla 3-6: *Resultados de la revisión.*

Pregunta	Fuente	Encontrados	Incluidos	Seleccionados
I	Scopus	10	3	1
II	Scopus	298	30	7
III, IV	Otras	149	50	25
			Total	33

En resumen, se expone un diagrama de flujo que representa el proceso de *RSL* descrito:

Figura 1: Flujo de proceso en la *RSL*.



3.4 Antecedentes y discusiones

La Colitis Ulcerativa (*CU*) es una enfermedad inflamatoria intestinal crónica que afecta a aproximadamente 7 millones de personas en todo el mundo, según la Organización Mundial de la Salud (World IBD Day, 2022). Esta enfermedad se caracteriza por la presencia de úlceras, sangrado y cólicos (Danese & Fiocchi, 2011). La importancia de la dieta y la nutrición en la *CU* y otras enfermedades inflamatorias intestinales es crucial. Una dieta rica en fibra, frutas, verduras y ácidos grasos como el omega-3 puede ser beneficiosa para individuos con *CU*, mientras que una alimentación rica en grasas saturadas, carnes rojas, alimentos procesados y productos lácteos puede empeorar la enfermedad. Es importante tener en cuenta que la individualización de la dieta es fundamental para el tratamiento de la *CU* (De Castro et al., 2021).

En la actualidad, el uso de técnicas de *Machine Learning* abarca diversas áreas de aplicación como la educación, finanzas, seguridad, marketing, salud y nutrición. El autoaprendizaje se refiere a la capacidad de los sistemas de aprendizaje automático para mejorar y adaptarse por sí mismos (Alpaydin, 2010). Varios autores han propuesto métodos de autoaprendizaje en diferentes áreas de aplicación. Por ejemplo, Dopido et al. (2013), propusieron un método de autoaprendizaje semisupervisado para la clasificación de imágenes hiperespectrales basado en un algoritmo de agrupamiento que se ajusta a datos no etiquetados y utiliza un conjunto de datos etiquetados para guiar el proceso de aprendizaje. Fogel et al. (2004), presentan un programa de ajedrez en el cual se aplica un método de autoaprendizaje evolutivo, mejorando su rendimiento de juego a lo largo del tiempo. Feldmann et al. (2019), exponen un enfoque de redes neuro-sinápticas con capacidad de autoaprendizaje basadas en la óptica para la simulación de actividad neural; Cunha & Duarte (2022), describen un sistema de control de nutrición que funciona para múltiples dispositivos, el cual utiliza sensores para medir diferentes parámetros y un dispositivo móvil para analizar los datos y generar recomendaciones personalizadas.

En el área de la conducción energéticamente eficiente, Qi et al. (2019), propusieron un sistema de control basado en aprendizaje por refuerzo profundo para mejorar la eficiencia energética de los vehículos, utilizando datos de velocidad a través de la interacción entre el vehículo y el tránsito. H. Chen et al. (2015), exhiben un método de autoaprendizaje basado en neuronas para reconstruir la estructura neuronal de los cerebros usando

aprendizaje no supervisado. En contraste, en el ámbito de la detección de noticias falsas, Li et al. (2022), proponen un método de autoaprendizaje semisupervisado para detectar noticias falsas en redes sociales con la extracción profunda de características de los datos. Además, Pant et al. (2017), desarrollan un sistema de educación personalizada que utiliza un algoritmo de aprendizaje por refuerzo para adaptarse a las necesidades de aprendizaje de cada estudiante. Por otra parte, aplicado al sector salud se ha visto crecimiento notable en áreas como el reconocimiento de imagen y procesamiento de lenguaje natural, pero estas aplicaciones se han desempeñado mejor en tareas únicas donde se requiere una precisión alta. Con respecto a la ingesta de alimentos, Khan et al. (2019), llevaron a cabo un resumen de perfil completo de nutrición mediante un análisis comparativo centrado en la optimización utilizando un sistema de recomendaciones con algoritmos de aprendizaje automático.

Sumado a esto, Triantafyllidis & Tsanas (2019), tuvieron como objetivo revisar la literatura sobre el uso de aprendizaje automático en intervenciones de salud digital en situaciones de la vida real. Este estudio identificó ocho intervenciones que incorporaron algoritmos de aprendizaje automático en entornos de investigación en la vida real. Estas intervenciones abordaron diversas áreas, como la predicción y gestión de la depresión, el reconocimiento para personas con discapacidades del habla, la autoeficacia en la pérdida de peso, la detección de cambios en la condición biopsicosocial de pacientes con múltiples patologías, la gestión del estrés, el tratamiento del dolor de miembro fantasma, la cesación del tabaquismo y la nutrición personalizada. En esta dirección, Panagoulas et al. (2021), destacan el uso de metodologías de aprendizaje automático para crear una tabla de evaluación integral de los biomarcadores nutricionales. Además, se investiga un método de predicción optimizado para el índice de masa corporal (*IMC*), con el objetivo de descubrir patrones dietéticos.

En 2021, C. Lee et al., aborda la importancia de considerar no solo aspectos nutricionales, sino también la composición de los alimentos en la planificación de dietas. Por esto, propusieron la utilización de aprendizaje automático para identificar patrones implícitos en los datos de dietas reales y aplicarlos en la generación de dietas mediante un algoritmo denominado como "*Teacher-forced Reinforce*". En el caso de la automatización de robótica de procesos (*RPA*), el autor Vasireddy (2020), menciona cómo la automatización y la

inteligencia artificial están transformando la industria de la alimentación y el estilo de vida, brindando recomendaciones personalizadas de dietas de manera eficiente y rápida. En 2022, Kirk et al., abordan el creciente desafío de analizar datos cada vez más complejos y de alta dimensión en la medicina, la falta de comprensión en aprendizaje automático por parte de los expertos en nutrición, lo que limita su utilización y su potencial.

En consecuencia, presentan un recurso para facilitar el uso de este, explicando el concepto, proporcionando ejemplos de aplicaciones y describiendo un marco para guiar a los investigadores interesados en integrar esta técnica a su trabajo. En este contexto, el uso de técnicas de autoaprendizaje en *Machine Learning* pueden ser una propuesta como una herramienta útil para la gestión personalizada de la dieta en individuos con *CU* y así, mejorar su calidad de vida, es decir, la técnica podría ser aplicada a la dieta individualizada de un paciente con Colitis Ulcerosa, aprendiendo de las reacciones de este a los alimentos que consume y ajustando su dieta.


4. Método de autoaprendizaje basado en Machine Learning Aplicado a la dieta de un individuo con Colitis Ulcerativa

El desarrollo de este trabajo incluyó varias etapas, desde la ingesta, preprocesamiento de datos hasta la construcción, entrenamiento y evaluación del modelo. A continuación, se describen detalladamente los procesos implementados.

4.1 Desarrollo del conjunto de datos

Para la creación del conjunto de datos en base a la justificación del trabajo se partió desde la premisa de relacionar la ingesta de alimentos con la sintomatología observada. Así, se desarrolló un *dataset* tabular, en formato .csv que incluye 94 columnas y 1596 filas de datos, recolectadas durante 266 días por Juan Pablo Aguirre Martínez, paciente diagnosticado con Colitis Ulcerativa desde hace aproximadamente 8 años. Para garantizar la consistencia en la recolección de datos, se establecieron porciones estándar para los alimentos. Estas porciones, al ser pesadas, se aproximan a números enteros y se mantuvieron constantes a lo largo del período de registro de la información. Las columnas relacionadas con la ingesta se han organizado en categorías específicas personalizadas, que incluyen proteínas, verduras, frutas, hongos, carbohidratos, bebidas y suplementos. Como se muestra en la Figura 2, para su completa visualización se recomienda revisar el Anexo A en la carpeta de imágenes.

Figura 2: *Diagrama de ingesta.*



Entre los ítems registrados se incluyen:

Tabla 4-1: *Carbohidratos.*

Carbohidrato
Arroz
Pasta de arroz
Harina de arroz
Pasta de lenteja rosada
Arepa de maíz
Pan de Sagú
Papa capira
Papa criolla
Galleta de almendra + arroz
Galletas de avena sin gluten
Galleta de arroz + maní
Snacks de maíz sabor limón (Choclitos)
Bocaditos veganos de alverja (banano + cacao)
Harina de arroz + jugo de naranja + arándanos + banano + stevia
Palitos de arroz con ajonjolí
Galletas de arroz con amapola, stevia, miel y arándanos
Helado de limón
Harina de arroz + harina de almendra + jugo de naranja + arándanos + stevia
Helado de almendra
Oblea de amaranto + stevia
Pan con queso
Tostada de maíz horneada
Galleta de arroz con manzana y calabaza
Pan con gluten de harina de trigo
Pan ciabatta sin gluten

Tabla 4-2: *Bebidas.*

Bebida
Jugo de naranja
Jugo de mandarina
Jugo de mora
Jugo de guanábana + lichi
Jugo de lulo
Frappé de arándanos
Jugo de guayaba + guaraná
Leche de almendras (stevia)
Limón + agua + stevia [0.45mL]
Agua
Té verde
Té verde + jugo de naranja + gelatina
Té negro + bayas + gelatina

Limonada de mango y fruto del dragón
Limonada de fresa y acai
Paleta de mango biche
Té negro + limón + gelatina de lichi
Té Rooibos de Ganoderma Lucidum + limón
Bebida de aloe sin azúcar
Jugo de mango y limón
Jugo de mandarina y fresa
Jugo de fresa
Pedialyte

Tabla 4-3: *Medicamentos.*

Medicamento
Infliximab
Prednisona
Azatioprina
Dexametasona
Mesalazina
Ácido fólico
Trimebutina
Loperamida
Hioscina
Tramadol
Albendazol
Acetaminofén

Tabla 4-4: *Frutas.*

Fruta
Tomate
Aceituna
Plátano maduro
Banano
Calabaza
Dátiles
Fresa
Lichi
Mandarina
Kiwi
Arándanos

Tabla 4-5: *Proteínas.*

Proteína
Huevo
Guisante
Lenteja Rosa
Almendra
Garbanzo
Proteína vegana en polvo (garbanzo + arroz + stevia)

Tabla 4-6: *Suplementos.*

Suplemento
Probióticos (billones)
Gomitas de complejo B
Aceite de cáñamo (CBD)
Ganoderma Lucidum
Omega 3

Tabla 4-7: *Grasas.*

Grasa
Aceite de oliva
Aceite de coco
Lecitina de soya

Tabla 4-8: *Hongos.*


Champiñón
Champiñón Blanco
Champiñón Orellana

Tabla 4-9: *Vegetales.*

Vegetal
Zanahoria

Todos estos se observan en la Figura 2: *Diagrama de ingesta.* y fueron registrados en unidades de gramos, miligramos y mililitros. A continuación, se muestra la cuenta de elementos consumidos por tipo.

Figura 3: *Números de elementos consumidos en la dieta.*



Aparte de ello, se realizó un análisis de correlación con el objetivo de identificar asociaciones de alta relevancia. Esta exploración sugiere que ciertos alimentos y componentes nutricionales tienden a estar relacionados en los patrones de consumo o en sus efectos en el organismo. En otras palabras, estos elementos se consumieron frecuentemente de manera simultánea, lo que permite observar las preferencias del individuo.

Tabla 4-10: *Correlación de elementos consumidos.*

Variable A	Variable B	Correlación
Tomate	Champiñón blanco	0.9528
Proteína vegana (garbanzo + arroz + arveja + stevia)	Leche de almendras (stevia)	0.9526
Tomate	Oliva	0.9439
Zanahoria	Papa criolla	0.9268
Oliva	Champiñón blanco	0.9184
Proteína vegana (garbanzo + arroz + arveja + stevia)	Arándanos	0.9092
Calabaza	Zanahoria	0.8895
Arándanos	Leche de almendras (stevia)	0.8864
Proteína vegana (garbanzo + arroz + arveja + stevia)	Banano	0.8794
Papa capira	Papa criolla	0.8758
Calabaza	Papa criolla	0.8757

Banano	Leche de almendras (stevia)	0.8719
Zanahoria	Papa capira	0.8400
Tomate	Pasta de arroz	0.8236
Banano	Arándanos	0.8210
Lecitina de soya	Galleta de arroz con almendras	0.8151
Champiñón blanco	Pasta de arroz	0.7944
Arroz	Jugo de naranja	0.7925
Calabaza	Papa capira	0.7798
Arroz	Mesalazina	0.7789
Oliva	Pasta de arroz	0.7786
Arepa de maíz	Juego de naranja	0.7725
Arepa de maíz	Mesalazina	0.7637
Jugo de naranja	Mesalazina	0.7619
Arroz	Arepa de maíz	0.7243
Azatioprina	Mesalazina	0.7165

Por otro lado, la sintomatología registrada se categorizó de la siguiente manera: sangrado, presencia de mucosidad, gases y distensión, calambres o dolor, todos evaluados en una escala de 0 a 5. Así mismo, se incluye la forma de las heces según la escala de Bristol, que varía de 1 a 7 (Danese & Fiocchi, 2011).

Tabla 4-11: *Indicadores sintomáticos.*

Síntoma	Escala	Descripción (Ejemplo)
Sangrado	0- 5	0 = Sin sangrado, 5 = Sangrado muy grave
Mucosidad	0- 5	0 = No Presente, 5 = Muy presente
Gases	0- 5	0 = Sin Gases, 5 = Gases severos
Distensión, calambres o dolor	0- 5	0 = Sin dolor, 5 = Dolor muy intenso
Forma de heces (Bristol)	1- 7	1 = Heces muy duras, 7 = Heces líquidas

Valga la redundancia, estas escalas fueron definidas de manera cuantitativa, donde cero representa ausencia de síntomas sentidos o identificados por el individuo de estudio y cinco indica una condición muy aguda. La única excepción es la Escala de Forma de Heces de Bristol, desarrollada por Lewis & Heaton (1997), en la Universidad de Bristol, Reino Unido.

Tabla 4-12: *Escala de Bristol.*

Tipo		Descripción
1		Pedazos duros, separados como nueces (estreñimiento)
2		Con forma de salchicha, pero grumosa, gruesa (compuesta de fragmentos)
3		Con forma de salchicha, pero con grietas en la superficie
4		Con forma de salchicha o serpiente, pero lisa y suave
5		Trozos pastosos con bordes bien definidos
6		Pedazos blandos y esponjosos con bordes irregulares
7		Acuosa, sin pedazos sólidos, totalmente líquida

Adicionalmente, el conjunto de datos incluyó una columna con las fechas de registro, sin embargo, esta no fue utilizada en el modelado debido a que los datos ya estaban organizados cronológicamente. Se realizó una exploración preliminar mediante la visualización de las primeras filas y el análisis de la estructura general del *DataFrame*. Luego, se verificó la integridad, es decir, se revisó cuidadosamente que no existieran datos nulos o errores de digitación. Finalmente, las columnas que no contenían datos o eran redundantes fueron eliminadas del conjunto, dejando solo las variables significativas.

4.1.1 Definición de la sintomatología

En congruencia con la cantidad de datos disponibles y con el objetivo de reducir el sesgo del método, se decidió trabajar la variable objetivo, es decir, la sintomatología como una variable binaria. Esto significa que se asignó el valor de uno para indicar la presencia de síntomas y el valor de cero para la ausencia de estos. A partir de esta simplificación, la sintomatología se redefinió como la presencia de al menos uno de los siguientes síntomas, según los criterios establecidos:

1. Distensión - Calambres - Dolor (0-5): si el valor es mayor a 0.
2. Presencia de Mucosidad (0-5): si el valor es mayor a 0.
3. Sangrado (0-5): si el valor es mayor a 0.
4. Gases (0-5): si el valor es mayor a 2.
5. Escala de Forma de Heces de Bristol (1-7): si el valor es mayor o igual a 6.

Se considera que un individuo presenta síntomas (valor 1), si cumple al menos una de estas condiciones. En caso de no cumplir con ninguna, se clasifica como ausencia de síntomas (valor 0).

Posteriormente, se eliminaron las columnas previamente detalladas que se utilizaban para definir los síntomas en el conjunto de datos original. A continuación, se introdujo una nueva columna denominada 'Sintomatología'. Esta columna contiene la variable dependiente o variable objetivo (y), que indica la presencia o ausencia de síntomas según la clasificación ya establecida.

4.2 Método de autoaprendizaje basado en Machine Learning

La selección de técnicas de *Machine Learning* en este estudio comenzó desde cero y está profundamente influenciada por las investigaciones recientes cuya esencia se comparte entre *Machine Learning* y medicina en su mayoría. En ellas, se destaca su eficacia en estos campos, cómo se mencionó en el estado del arte; empero, hay semejanza en el objeto o la esencia más no en el fondo ni en la forma. Por ello, no hay una comparación directa con las fuentes, ni uso de arquitecturas. Más allá, su lectura y análisis permitió dar idea de los modelos usados última y comúnmente en estos campos. A partir de estos, emergió la lista de posibles herramientas que posteriormente se emplearon en este trabajo, como se ejemplifica en la siguiente tabla.

Tabla 4-13: *Técnicas utilizadas.*

Nombre del estudio	Técnica de Machine Learning mencionada
I. Artificial Intelligence and Machine Learning in Anesthesiology (Connor, 2019)	Logistic Regression
II. Semisupervised Self-Learning for Hyperspectral Image Classification (Dopido et al., 2013)	
I. Optimizing Nutrition using Machine Learning Algorithms-a Comparative Analysis (Khan et al., 2019)	
II. A systematic literature review and classification of knowledge discovery in traditional medicine (Arji et al., 2019)	SVM
III. Dietary prediction for patients with Chronic Kidney Disease (CKD) by considering blood potassium level using machine learning algorithms (Wickramasinghe et al., 2017)	
IV. Machine Learning in Nutritional Follow-up Research (Reis et al., 2017)	
V. Semisupervised Self-Learning for Hyperspectral Image Classification (Dopido et al., 2013)	Naive Bayes
I. Applications of Machine Learning in Real-Life Digital Health Interventions: Review of the Literature (Triantafyllidis & Tsanas, 2019)	
II. Dietary prediction for patients with Chronic Kidney Disease (CKD) by considering blood potassium level using machine learning algorithms (Wickramasinghe et al., 2017)	
I. Machine Learning in Nutrition Research (Kirk et al., 2022)	Random Forest
II. Optimizing Nutrition using Machine Learning Algorithms-a Comparative Analysis (Khan et al., 2019)	
III. A systematic literature review and classification of knowledge discovery in traditional medicine (Arji et al., 2019)	
IV. Self-Learning Random Forests Model for Mapping Groundwater Yield in Data-Scarce Areas (Sameen et al., 2019)	KNN
I. Optimizing Nutrition using Machine Learning Algorithms-a Comparative Analysis (Khan et al., 2019)	
I. Machine Learning in Nutrition Research (Kirk et al., 2022)	
I. Machine Learning in Nutrition Research (Kirk et al., 2022)	PCA
II. Optimizing Nutrition using Machine Learning Algorithms-a Comparative Analysis (Khan et al., 2019)	XGBoost
I. A novel self-learning semi-supervised deep learning network to detect fake news on social media (Li et al., 2022)	RNN - LSTM
II. Deep reinforcement learning enabled self-learning control for energy efficient driving (Qi et al., 2019)	
III. Artificial Intelligence and Machine Learning in Anesthesiology (Connor, 2019)	

Estos precedentes en la literatura no solo refuerzan la validez de las elecciones estratégicas, más aún, alinean el trabajo con las tendencias actuales en la aplicación de *Machine Learning* para optimizar intervenciones relacionadas con la salud.

Asimismo, se tenían varios desafíos, primero, se trabajó con una cantidad limitada de datos, consistiendo en un total de 1596 observaciones, lo cual representa una restricción

significativa para el modelo. Segundo, la relación entre la alimentación y la manifestación de síntomas no es lineal ni directa. Según Y. Y. Lee et al. (2014), una comida puede influir en el estado del individuo durante un período de hasta 73 horas, aproximadamente 3 días. En este contexto, las entradas se registraron en 6 franjas horarias durante el día, correspondientes a desayuno, almuerzo, algo, cena y merienda. Cada entrada en estas franjas contiene registros de la sintomatología manifestada, si la hubiere, permitiendo así monitorizar la influencia a lo largo del tiempo. Cuarto, en cuanto a la variable objetivo, que en este caso es la sintomatología, se observó un desequilibrio significativo de clases particularmente marcado en la clase minoritaria. Para abordar este desequilibrio, se aplicó la técnica *SMOTE* (Chawla et al., 2002), seleccionada con el objetivo de obtener mejores resultados.


4.2.1 Proceso de normalización

Para asegurar la compatibilidad con el modelo, se realizó la normalización de las variables independientes tanto del conjunto de entrenamiento como de prueba. Esto se logró mediante el uso de *MinMaxScaler*, integrado en el *pipeline* de procesamiento (Pedregosa et al., 2012). El *MinMaxScaler* transforma los datos para que se ajusten a un rango de 0 a 1, garantizando así que todas las características contribuyan equitativamente al aprendizaje del modelo sin sesgo por diferencias de escala (Géron, 2017). Además, se cuidó de mantener los índices de cada instancia en los conjuntos de entrenamiento y prueba durante el proceso de escalado. Esto es crucial para preservar la correspondencia exacta entre los datos y sus etiquetas, evitando cualquier desalineación que pueda afectar adversamente la interpretación del modelo y la validez de las predicciones.

4.2.2 Balanceo de clases


La variable objetivo presentaba un desequilibrio significativo entre las clases, como se detalla más adelante.

Figura 4: *Distribución de la sintomatología previa al balanceo.*



En respuesta al desequilibrio significativo entre las clases observado en la variable objetivo, se implementó una técnica de sobre muestreo clásica: *SMOTE* (Synthetic Minority Over-sampling Technique), propuesto por Chawla et al. (2002). Este método no solo replica las muestras existentes de la clase minoritaria, sino que también genera nuevas muestras sintéticas. Al hacerlo, *SMOTE* contribuye desde el *pipeline* a crear un conjunto de datos más equilibrado (Lemaitre et al., 2016).

Figura 5: *Distribución de la sintomatología posterior al balanceo.*



4.2.3 Reducción de dimensionalidad


a. Análisis de Componentes Principales (PCA) y su aplicación en los modelos clásicos

- **Definición y objetivo del Análisis de Componentes Principales (Principal Component Analysis):** el *PCA*, es una técnica de aprendizaje no supervisado utilizada para la reducción de dimensionalidad. Esta técnica transforma un conjunto de variables originales, en un nuevo conjunto de variables que son linealmente independientes entre sí, conocidas como componentes principales. La meta principal del *PCA* es reducir la cantidad de variables, conservando al mismo tiempo la mayor cantidad de información posible en términos de variabilidad de los datos. Esta reducción no solo simplifica el análisis, sino que también puede mejorar el rendimiento y la eficiencia computacional de otros algoritmos de *Machine Learning* (Jolliffe, 1990).

- **Aplicación en modelos clásicos:** En el desarrollo de los modelos clásicos como regresión logística, *SVM*, *NB*, *KNN* y *Random Forest*, se implementó el *PCA* para mejorar los modelos. El *PCA* es particularmente beneficioso en contextos donde la multicolinealidad entre las variables puede afectar negativamente el rendimiento del modelo. Al reducir el número de variables, este no solo ayuda a mitigar este problema, sino que también mejora la eficiencia computacional.

Para integrar eficazmente el *PCA*, primero, se calculó la varianza explicada por cada componente. Este paso es crucial para entender cuánta información original se puede conservar durante el proceso de reducción de dimensionalidad. Por ende, se realizó un análisis de la varianza acumulada explicada en función del número de componentes principales. En base a este análisis se determina que aproximadamente 75 componentes eran óptimos para conservar una cantidad sustancial de la información original, ver Figura 6.

Figura 6: Gráfico de componentes y varianza explicada acumulada.



Una vez determinado el número adecuado de componentes, se incorporó el *PCA* directamente en el *pipeline* de cada modelo clásico. Esta integración asegura que todas las entradas al modelo fueran transformaciones lineales de las variables originales que reflejan las direcciones de máxima varianza. Al hacer esto, cada modelo pudo operar sobre un espacio de características más simplificado y representativo.

b. Justificación de la exclusión de PCA en XGBoost y LSTM

- **XGBoost:** preservación de la estructura de datos, a saber, *XGBoost* maneja bien las grandes dimensiones y puede capturar interacciones complejas entre las variables. La aplicación del *PCA* podría eliminar estas interacciones, ignorando la complejidad del *dataset* reduciendo la capacidad del modelo. *XGBoost* proporciona métricas sobre la importancia de las características, no obstante, estas se pueden perder o distorsionar al transformar los datos con *PCA*.
- **LSTM:** dependencia temporal, esto es, donde las relaciones temporales y el orden de los eventos son cruciales, la aplicación del *PCA* distorsionaría estas relaciones temporales. *LSTM* necesita mantener la estructura original de la secuencia de tiempo para modelar efectivamente. Se denota, el *PCA* es una técnica lineal que puede no ser adecuada para *datasets* donde las relaciones entre variables no son lineales.

4.2.4 Modelos de Machine Learning

a. Métodos clásicos

- **Regresión Logística:** es un método estadístico para modelar la probabilidad de ocurrencia de un evento, mediante una variable dependiente categórica, generalmente binaria. Esta técnica utiliza la función logística, también, conocida como sigmoide, para vincular la probabilidad de la variable dependiente, que representa la probabilidad de la presencia o ausencia de una característica, con un conjunto de variables independientes. Esta técnica se utiliza para la clasificación binaria y es efectiva cuando las variables predictoras están linealmente relacionadas con el logaritmo de las probabilidades (Peng et al., 2002).
- **SVM (Support Vector Machine):** las Máquinas de Vectores de Soporte, son un conjunto de métodos de aprendizaje supervisado utilizados para la clasificación y regresión. En la clasificación, el objetivo es encontrar un hiperplano en un espacio N-dimensional (N: número de características), que clasifique claramente las clases de datos. Las SVM buscan el hiperplano que tenga la máxima distancia a los puntos de datos más cercanos de cualquier clase, conocidos como vectores de soporte. Este margen maximizado proporciona cierta robustez frente a errores de clasificación y sobreajuste (Rezvani et al., 2024).
- **KNN (K-Nearest Neighbors):** el algoritmo de aprendizaje K Vecinos Más Cercanos no hace suposiciones explícitas sobre la forma del modelo subyacente. En KNN, la clasificación de una muestra se realiza identificando los K ejemplos más cercanos en el conjunto de entrenamiento (los K vecinos más cercanos), realizando una votación mayoritaria sobre su etiqueta. De igual forma, en regresión, el valor predicho es el promedio de los valores de los K vecinos más cercanos. Este método es útil cuando la relación entre las variables es intrincadamente no lineal; pese a que puede ser computacionalmente costoso, su rendimiento puede degradarse con el aumento de la dimensión del espacio (Cunningham & Delany, 2020).
- **NB (Naive Bayes):** el clasificador de *Naive Bayes* se fundamenta en el teorema de Bayes y asume independencia entre los predictores. A pesar de su simplicidad y la suposición de independencia, *Naive Bayes* ha demostrado ser efectivo en muchas situaciones reales, especialmente en tareas de clasificación de texto. Este proceso calcula la probabilidad de cada clase y la probabilidad condicional de cada clase

dado un vector de características de entrada, luego, utiliza estas probabilidades para clasificar nuevas instancias con la clase de mayor probabilidad posterior (Vikramkumar et al., 2014).

- **RF (Random Forest):** el Bosque Aleatorio es un algoritmo de aprendizaje supervisado que usa un conjunto de árboles de decisión para realizar clasificaciones o regresiones. Cada árbol en el bosque es construido a partir de una muestra aleatoria de los datos de entrenamiento (*bootstrap sampling*, muestreo con reemplazo), y para dividir los nodos, se selecciona un subconjunto aleatorio de las características. En tanto, la predicción final se realiza mediante votación mayoritaria en el caso de clasificación o promedio en el caso de regresión. Este método es efectivo debido a su capacidad para reducir la varianza sin aumentar considerablemente el sesgo (Louppe, 2014).


Para los modelos anteriormente mencionados (Regresión Logística, SVM, KNN, NB, RF), se aplicó *GridSearchCV* para optimizar sus hiperparámetros en el pipeline. Esta técnica permite automatizar el proceso de selección del mejor conjunto de parámetros. Esta herramienta de la biblioteca de *Scikit-Learn* (Pedregosa et al., 2012), realiza una búsqueda exhaustiva sobre un rango especificado de valores de hiperparámetros y evalúa el rendimiento de cada combinación mediante validación cruzada, para identificar la configuración que ofrece mejores resultados (Liashchynskiy & Liashchynskiy, 2019). Primero, establece un estimador, esto es, el modelo que se quiere optimizar. Segundo, se define la grilla de parámetros, así, se definen los hiperparámetros. Tercero, se puede elegir la métrica de evaluación para medir el rendimiento de cada combinación de hiperparámetros. Cuarto, la validación cruzada para asegurar que la evaluación de los hiperparámetros sea robusta y adecuada (GeeksforGeeks, 2024b).

Tabla 4-14: *Parametrización de modelos clásicos.*

Modelo	Parámetros	Validación Cruzada
Regresión Logística	{'classifier__C': [0.1, 1, 10, 100]}	5
SVM	{'classifier__C': [0.1, 1, 10, 100], 'classifier__gamma': [0.1, 1, 10, 100]}	5
KNN	{'classifier__n_neighbors': [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]}	5
NB	No tiene hiperparámetros.	5
RF	{'classifier__n_estimators': [100, 200, 300, 400, 500]}	5

Acto seguido, se expone una generalización de la arquitectura implementada en los modelos clásicos.

Figura 7: *Arquitectura modelos clásicos.*



b. Métodos avanzados

- **XGBoost (*Extreme Gradient Boosting*)**: la Potenciación de Gradiente Extremo, es un algoritmo de aprendizaje basado en *boosting* de árboles de decisiones. Se distingue por su eficiencia computacional y efectividad en una amplia gama de tareas de predicción, mejorando la precisión de los modelos mediante la minimización de la función de pérdida y la regulación de sobreajuste. Esta cuenta con instrumentos como el *tree pruning* (poda de árboles), donde los árboles se cortan durante el crecimiento en lugar de después de haber alcanzado su tamaño máximo. A diferencia de otros algoritmos, este incluye mecanismos de regularización como L1 o *Lasso regression* (Muthukrishnan & Rohini, 2016), y L2 o *Ridge regression* (Liu & Dobriban, 2019), que ayudan a prevenir el sobreajuste, además de optimizar funciones de pérdida que potencia la generalización de los modelos. Una de las características clave de XGBoost es su habilidad para tratar valores faltantes automáticamente, debido a que aprende la dirección más

beneficiosa para los datos. Del mismo modo, cuenta con flexibilidad para personalizar la función de pérdida ajustándose a las necesidades específicas (T. Chen & Guestrin, 2016). Aquí, se entrena el modelo utilizando una función automatizada que integra *Optuna*, una biblioteca de optimización de hiperparámetros basada en técnicas de búsqueda bayesiana y estrategias de muestreo. Esto permite identificar eficientemente la combinación más adecuada de hiperparámetros, mejorando la calidad del modelo sin requerir de una extensa búsqueda manual, lo que optimiza el proceso (Akiba et al., 2019). De este proceso podemos visualizar un estudio con el historial de parametrización y su importancia en las siguientes figuras.

Figura 8: *Historial de optimización de hiperparámetros.*





Figura 9: *Importancias de hiperparámetros.*



A posteriori, se entrena el modelo con el mejor grupo de parámetros logrados por la automatización y se generan las métricas correspondientes. Es menester señalar, este modelo no cuenta con una arquitectura adicional a lo ya mencionado antes.

- **LSTM (*Long Short-Term Memory*):** en vista de que una comida no está asociada a un solo grupo de síntomas, sino que esta influye hasta en un período de 73 horas y que este rango puede variar (Nandhra et al., 2023), en otras palabras, la digestión de los alimentos tiene casi ese período de duración. Por último, se implementó un modelo de redes neuronales recurrentes de tipo *LSTM* (Hochreiter & Schmidhuber, 1997), para abordar tanto el problema de la temporalidad, como el de clasificación binaria. Es digno destacar, las *LSTM* son un tipo de red neuronal recurrente (*RNN*), diseñada para manejar dependencias a largo plazo en datos secuenciales, siendo este el único modelo que cumple con capacidad para considerar múltiples entradas y manejar dependencias temporales. A diferencia de los modelos clásicos que procesan entradas de manera individual (uno a uno), las *LSTM* introducen una celda de memoria que actúa como un contenedor capaz de almacenar información durante un período prologando y relaciona eventos actuales con entradas pasadas, facilitando el autoaprendizaje. Estas, abordan problemas comunes en las *RNN* tradicionales, como el desvanecimiento del gradiente (Staudemeyer & Morris, 2019). Una *LSTM* se conforma de una celda de memoria y tres compuertas:
 - I. Compuerta de entrada: modera la cantidad de nueva información que se almacena en la celda de memoria.
 - II. Compuerta de olvido: establece qué información de la celda de memoria debe ser removida.
 - III. Compuerta de salida: decide qué información de la celda de memoria se utiliza para generar la salida en un momento dado.

Además, la *LSTM* mantiene un estado oculto, que actúa como la memoria a corto plazo de la red. Este estado oculto se actualiza en función de la entrada, el estado oculto anterior y el estado actual de la celda. Así, estos elementos permiten que las *LSTM* manejen información relevante durante largos periodos de tiempo, lo que las hace adecuadas para tareas como el reconocimiento de voz, la traducción automática y el análisis de series temporales (GeeksforGeeks, 2024a). Se diseñó una arquitectura de modelo *LSTM* en la que se incluyeron capas bidireccionales para capturar ambas direcciones de las secuencias temporales. La estructura es la siguiente:

- I. Entrada: Una capa configurada para recibir tensores de dimensiones compatibles. Para ello, se definió una función para obtener el tensor a la

cual se le ingresa un arreglo de tamaño N por F cantidades de características, un aporte con instantes de tiempo consecutivos de la serie de tiempo, en este caso se definió como 18 ya que cada día cuenta con 6 puntos de datos organizados cronológicamente, es decir, se da un total aproximado de 3 días que equivalen a casi las 73 horas que se mencionaron anteriormente.

II. Capas *LSTM*: estas se distribuyeron así:

- Una primera capa bidireccional con 512 unidades y regularización L2 o *Ridge Regression* (Liu & Dobriban, 2019), se conoce como *weight decay*, penalizando los pesos grandes mejorando la generalización para prevenir el sobreajuste.
- Una segunda capa unidireccional con 256 unidades, también con regularización L2.
- Una tercera capa bidireccional con 128 unidades.
- Una capa final *LSTM* con 64 unidades sin retorno de secuencia.

III. Capas densas: una capa densa de 32 unidades con función de activación *ReLU* y una capa de salida con una función de activación sigmoide para realizar la clasificación binaria.

El modelo fue compilado utilizando el optimizador Adam (Kingma & Ba, 2014), con una tasa de aprendizaje inicial de 0.0005. Se utilizó como función de pérdida la entropía cruzada binaria, métricas como la exactitud y el *AUC*. Este, fue entrenado utilizando un conjunto de datos de entrenamiento y prueba. Se hizo uso de herramientas para optimizar el proceso de entrenamiento, cómo:

- I. Estrategia de detección temprana: se usó la función *EarlyStopping* (Bai et al., 2021), para finalizar el entrenamiento cuando la pérdida en el conjunto de validación dejó mejorar durante 5 épocas.
- II. Reducción dinámica de la tasa de aprendizaje: *ReduceLROnPlateau* (Abadi et al., 2016), ajustó la tasa de aprendizaje en función del rendimiento del conjunto.
- III. Programación de la tasa de aprendizaje: se determinó una función personalizada para reducir la tasa de aprendizaje después de 35 épocas.

Paralelamente, para estar seguros de los resultados que se estaban obteniendo y de que la arquitectura era la adecuada, se llevó a cabo un trabajo manual de probar

varias arquitecturas, unas un poco más reducidas, otras más robustas. Así mismo, se hizo un proceso de optimización de hiperparámetros utilizando *Keras* (Chollet & others, 2015), con el objetivo de estar seguros y de mejorar el rendimiento del modelo LSTM. Se probaron diferentes configuraciones para la cantidad de capas, unidades en cada capa, tasas de aprendizaje y funciones de activación. Eso se realizó por medio de *keras_tuner*, implementando una función personalizada que recorría diferentes combinaciones de hiperparámetros dentro de la arquitectura del modelo para encontrar otra mejor configuración posible.

Sin embargo, los mejores resultados obtenidos no mostraron una mejora significativa en comparación con la configuración fija que ya se había definido. A pesar del ajuste fino, el mejor modelo obtenido con el aumento generaba un total de 5'075'429 parámetros, de los cuales 1'691'809 eran entrenables, mientras que el modelo original contenía 4'235'585 parámetros, todos ellos entrenables. En consecuencia, la arquitectura planteada ya era adecuada y aumentar la complejidad o refinamiento del modelo no se tradujo en un avance relevante.

4.2.5 Resultados

Luego de completar los entrenamientos, se evaluaron los modelos con el conjunto de prueba, las métricas obtenidas incluyeron:

1. **Pérdida:** representa el error promedio entre las predicciones del modelo y las etiquetas reales. Un valor bajo de pérdida indica que el modelo se ajusta apropiadamente a los datos. En el gráfico se muestra la evolución del error en los conjuntos de entrenamiento y validación. Una diferencia notable entre ambas curvas evoca un sobreajuste, mientras que una pérdida elevada en ambos conjuntos puede indicar que el modelo no está aprendiendo adecuadamente.
- **Métodos clásicos:** no se cuenta con la función de pérdida de estos modelos.

- Métodos Avanzados:

Figura 10: *Función de pérdida | XGBoost.*






Figura 11: *Función de pérdida | LSTM.*



2. Exactitud: esta métrica es utilizada para medir la proporción de predicciones correctas por un modelo sobre el total de muestras evaluadas, es decir, la suma de los verdaderos positivos más los verdaderos negativos todo esto sobre el total de muestras. Si la exactitud de entrenamiento sigue aumentando, pero la validación se estanca o disminuye, puede indicar sobreajuste. Esta métrica es clave, aunque debe complementarse con otras.

- Métodos clásicos:

Figura 12: *Exactitud | Modelos clásicos.*



- Métodos Avanzados:

Figura 13: *Exactitud | XGBoost.*






Figura 14: *Función de Exactitud | LSTM.*



3. AUC-ROC: Área bajo la curva ROC, mide la capacidad del modelo para distinguir entre las clases. Muestra la relación entre la tasa de verdaderos positivos y la tasa de falsos positivos a medida que cambia el umbral de decisión. Es notable, un valor de AUC cercano a 1 indica una alta capacidad discriminativa, i.e., diferencia todas las clases perfectamente. En el caso de la curva ROC, un modelo óptimo se acercará a la esquina superior izquierda del gráfico, mientras que un modelo con bajo rendimiento mostrará una curva cercana a la diagonal, indicando una clasificación aleatoria o al azar.

- Métodos clásicos:

Figura 15: Curva ROC | Modelos clásicos.



- Métodos Avanzados:

Figura 16: Curva ROC | XGboost.





Figura 17: Curva ROC | LSTM.



4.3 Discusión y validación del método

4.3.1 Comparación de modelos

Para comparar los modelos, se consideran los siguientes criterios:

- I. Rendimiento en la clasificación binaria: se refiere a si el modelo funciona para este tipo de clasificación y es efectivo. Para un AUC de 0.5 se considera el modelo como aleatorio y 1 si es un modelo que clasifica perfectamente.
- II. Autoaprendizaje: determina si el modelo puede mejorar y adaptarse continuamente a partir de nuevos datos sin ser explícitamente reprogramado
- III. Sobreajuste: se evalúa si el modelo memoriza detalles específicos del conjunto de entrenamiento en lugar de aprender patrones generalizables para hacer las predicciones.
- IV. Manejo de la temporalidad: se revisa la habilidad del modelo para incorporar y aprender de secuencias de datos. Este criterio es fundamental dado que las entradas anteriores influyen en las predicciones futuras. En este contexto, donde la sintomatología (y), depende de las entradas de las últimas 73 horas, tiempo que puede durar la digestión; es crucial elegir el modelo que pueda capturar estas dependencias a largo plazo.

Para mantener una terminología uniforme en la comparación, se emplea una escala de cualitativa, esta es la estructura:

- Nulo: el modelo no cumple en lo absoluto.
- Bajo: desempeño pobre o inadecuado.
- Medio: desempeño moderado o parcialmente adecuado.
- Alto: buen desempeño o adecuado.

Para el sobreajuste una calificación más alta indica un problema mayor. "Alta" significa que hay una diferencia igual o superior al 15% entre los rendimientos en los conjuntos de entrenamiento y validación, lo cual indica un nivel que impacta negativamente. "Media" refleja una diferencia entre 5% y 10%, indicando un sobreajuste moderado. "Baja" muestra una diferencia menor al 5%, y "Nula" con una diferencia de 0%, indica ausencia total de sobreajuste, que es lo ideal para la generalización del modelo.

A continuación, se observa una comparación cualitativa de los modelos.

Figura 18: Comparación cualitativa de los modelos.

Criterio Modelo	Manejo de la temporalidad	Rendimiento en clasificación binaria	Autoaprendizaje	Sobreajuste
Regresión Logística	Nulo	Medio	Nulo	Medio
SVM	Nulo	Medio	Nulo	Alto
KNN	Nulo	Medio	Nulo	Alto
Naive Bayes	Nulo	Bajo	Nulo	Bajo
Bosque Aleatorio	Nulo	Medio	Nulo	Alto
XGBoost	Nulo	Medio	Nulo	Alto
LSTM	Alto	Medio	Alto	Medio

Generalidades que se observan: los modelos analizados cuentan con un rendimiento moderado, especialmente, el *Naive Bayes* destacándose negativamente por su exactitud de predicciones relativamente baja. Asimismo, todos los modelos exhiben en cierta medida sobreajuste, lo que podría comprometer su eficacia. Un aspecto preocupante es que la calidad de la clasificación de varios modelos se aproxima a la aleatoriedad, indicando azar.

4.3.2 Elección del modelo y validación del método

Este proyecto comenzó desde conceptos fundamentales, avanzando progresivamente a través de diversas técnicas, en orden de complejidad, según lo contemplado en el estado del arte. A lo largo del mismo, se identificaron y enfrentaron varios desafíos, lo que enriqueció el proceso de desarrollo.

Existen dos puntos claves para la selección del modelo. Primero, el manejo de la temporalidad es fundamental, dado que entender que la ingesta de alimentos y la aparición posterior de síntomas en un individuo no están directamente correlacionadas en tiempo inmediato, sino que un síntoma puede ser la consecuencia acumulativa de varios elementos consumidos en un lapso de hasta tres días. Segundo, en este trabajo se ha priorizado de manera enfática escoger una técnica con autoaprendizaje, esto es, la habilidad del sistema para aprender y mejorar continuamente a partir de nuevos datos sin intervención externa. Por definición, solo *LSTM* siendo una *RNN* aplica autoaprendizaje.

Por este motivo, el modelo seleccionado es el *LSTM*. Si bien, más allá de la selección del modelo se visualizan todas las métricas resultantes, estas no son excelentes o las deseadas, creando una oportunidad para trabajos futuros.

No se puede ignorar el compendio de técnicas y herramientas que definen el método. Esto comprende el formato de los datos, las librerías de programación, los procesos de estandarización y normalización de datos, el balanceo de clases, la optimización de hiperparámetros, el *LSTM*, la arquitectura definida y las métricas resultantes.

Es muy relevante y notorio resaltar que este desarrollo es posible gracias a librerías e instrumentos de uso libre y código abierto, tales como:

- ✓ *Scikit-Learn* (Pedregosa et al., 2012).
- ✓ *Imbalanced-Learn* (Lemaitre et al., 2016).
- ✓ *Keras* (Chollet & others, 2015).
- ✓ *TensorFlow* (Abadi et al., 2016).

Por último, la integración de estos recursos de *software* libre no solo facilita la implementación de técnicas avanzadas, más aún asegura la replicabilidad y la transparencia en la validación del método.

5. Conclusiones y recomendaciones

5.1 Conclusiones

Este trabajo propone un método cimentado en técnicas de autoaprendizaje y *Machine Learning* para predecir la sintomatología en base a la ingesta de personas con Colitis Ulcerativa. Para ello, se construyó un conjunto de datos específico y se evaluaron diversos modelos de *Machine Learning*. Entre estos, se priorizó la capacidad del modelo para procesar datos secuenciales y aprender de manera continua, lo que llevó a la elección del modelo *Long Short-Term Memory (LSTM)*.

El análisis comparativo demostró que los otros modelos de clasificación, como la regresión logística, *SVM*, *Naive Bayes*, *KNN*, *Random Forest* y *XGBoost*, presentan limitaciones en este contexto. Estos enfoques procesan los datos de manera aislada, sin considerar la relación secuencial entre eventos, lo que impide capturar la compleja interacción entre la dieta y la manifestación de síntomas en pacientes con *CU*. Por el contrario, el modelo *LSTM*, a través de su arquitectura de memoria, permite analizar patrones temporales y reflejar el efecto acumulativo de los alimentos en la sintomatología a lo largo del tiempo.

Para comprobar qué modelo de Machine Learning era el más adecuado para este tipo de casos, se hizo un análisis, primero, del dilema que se enfrentaba, es decir, las preguntas, algoritmos que teníamos resolver. Segundo al tener a la mano tantas herramientas de Aprendizaje de Máquinas, se trabajó con todas ellas para saber dónde estábamos con lo que teníamos y hacia donde íbamos. Por ende, se permitió vivir esta misión desde distintos enfoques que cultivan muchos aprendizajes.

Si bien los resultados logrados de cierta manera respaldan el *LSTM* en la representación de relaciones temporales, existen limitaciones que deben ser consideradas. Una de las principales dificultades radica en la cantidad de los datos disponibles. La recolección de

información nutricional y de síntomas en un paciente con *CU* es un proceso complejo, condicionado por la variabilidad interindividual del reporte. La implementación del modelo *LSTM* demostró ser algo efectiva en la clasificación binaria del problema planteado, alcanzando solo métricas satisfactorias en el conjunto de prueba. Verbigracia, el *AUC* durante la validación consiguió un valor que raspaba por el 0.5 lo que quiere decir que el modelo raya en una clasificación aleatoria. No obstante, la cantidad de datos disponibles (1596 muestras con 81 características), resultaría ser el factor delimitante que más afectó la competencia del método.

La evaluación del modelo se realizó utilizando un conjunto de datos específico, lo que limita su extrapolación a otros contextos. Por tanto, la validación externa con diferentes grupos de pacientes y entornos clínicos sería fundamental para determinar la robustez del enfoque propuesto y su aplicabilidad real.

La construcción del conjunto de datos fue algo muy retador porque primero la alimentación de la persona de estudio se tuvo que medir y registrar durante 266 días, la expectativa era hacerlo durante el año completo, pero no se logró por cuestiones de salud del paciente. Segundo, mantener el régimen similar de alimentación exacto e ir introduciendo alimentos que se creen podrían generar sintomatología es algo riesgoso, generar una recaída grave en la enfermedad puede hacer que se toque suspender el registro, tratar con medicamentos más fuertes para alcanzar remisión y esto, puede alterar los resultados. Por esa razón, se contaba con una cantidad no tan grande de datos, en otras palabras, no el conjunto que se deseaba para obtener mejores resultados.

A pesar de aplicar recursos como el preprocesamiento, balanceo de clases, optimización de hiperparámetros, variación de arquitectura, los modelos presentaron signos evidentes de sobreajuste. Esto se observó en un rendimiento superior de la exactitud por parte del conjunto de entrenamiento en comparación con el de validación, lo que sugiere que generaron algo de sobre aprendizaje de casos específicos.

A partir de contemplar la complejidad de desarrollo del método en términos del modelo y la cantidad mínima razonable de datos para aplicar a una clasificación binaria. En consecuencia, se diría que 1500 o 2000 muestras por clase, podría ser una buena aproximación para un total de mínimo 4000 o 5000 para tener modelos más consistentes.

Más aún, en el suceso de que se tengan más clases, por ejemplo, cuatro o cinco clases, hablaríamos de 10000 referencias. Así, siempre va a ser óptimo tener más datos de calidad.

Para mejorar el desempeño y reducir el sobreajuste, se podrían inspeccionar las siguientes alternativas:

- ✓ Aumentar la cantidad de datos hasta tener un número de muestras valioso que alivie la generación del modelo.
- ✓ Refinar más el diseño de la arquitectura del modelo, la regularización.
- ✓ Buscar más alternativas para hacer aumento de datos, técnicas innovadoras que permitan gestar nuevas muestras sintéticas.

En suma, basados en plus minusve mil datos de entrenamiento, el modelo logró resultados prometedores. Igualmente, se reconoce el factor crítico de la cantidad de datos que debilita el rendimiento del sistema y del trabajo.

Se contribuye al creciente uso del *Machine Learning* en el campo de la salud. El método podría complementar las estrategias de tratamiento clínico convencionales. De hecho, ofrece la posibilidad de desarrollar sistemas de recomendación automática acotados al manejo de la *CU*.

5.2 Recomendaciones

De manera personal, se espera retomar el desarrollo del conjunto de datos cuando el estado de salud de la persona de estudio sea más estable, cuente con más herramientas y tiempo para seguir con esta tarea.

En líneas generales, lo logrado en este compendio es un punto de partida para diversas oportunidades futuras: ampliación del conjunto de datos, es decir, mayor número de pacientes con variabilidad dietética, exploración de arquitecturas híbridas involucrando nuevos avances y evaluación en entornos clínicos controlados para validar su eficacia en la práctica real.

A través de este trabajo, se invita a la comunidad médica e informática especializada a fortalecer la colaboración interdisciplinaria, integrando todas las nuevas tecnologías,

fomentando la curiosidad científica. Solo mediante un esfuerzo conjunto se podría desarrollar, escalar y llevar a excelente término este tipo de proyectos.

A. Anexo: Código Fuente

El repositorio denominado *UNAL_JPAM_Tesis_Master_Repo*, contiene los datos, scripts y algoritmos utilizados en este trabajo. Se encuentra disponible en GitHub en el siguiente enlace: https://github.com/JPAM0898/UNAL_JPAM_Tesis_Master_Repo.git.

Bibliografía

- Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., Corrado, G. S., Davis, A., Dean, J., Devin, M., Ghemawat, S., Goodfellow, I., Harp, A., Irving, G., Isard, M., Jia, Y., Jozefowicz, R., Kaiser, L., Kudlur, M., ... Zheng, X. (2016). *TensorFlow: Large-Scale Machine Learning on Heterogeneous Distributed Systems*. <https://doi.org/10.5281/zenodo.4724125>
- Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). *Optuna: A Next-generation Hyperparameter Optimization Framework*. <https://arxiv.org/abs/1907.10902>
- Alpaydin, Ethem. (2010). *Introduction to Machine Learning (Adaptive Computation and Machine Learning)* (T. Dietterich, C. Bishop, D. Heckerman, M. Jordan, & M. Kearns, Eds.; Second Edition). MIT Press, The. <https://www.amazon.com/Introduction-Machine-Learning-Adaptive-Computation/dp/026201243X>
- Arji, G., Safdari, R., Rezaeizadeh, H., Abbassian, A., Mokhtaran, M., & Hossein Ayati, M. (2019). A systematic literature review and classification of knowledge discovery in traditional medicine. *Computer Methods and Programs in Biomedicine*, 168, 39–57. <https://doi.org/10.1016/j.cmpb.2018.10.017>
- Bai, Y., Yang, E., Han, B., Yang, Y., Li, J., Mao, Y., Niu, G., & Liu, T. (2021). *Understanding and Improving Early Stopping for Learning with Noisy Labels*. <https://arxiv.org/abs/2106.15853>
- Burke, A., Lichtenstein, G. R., & Rombeau, J. L. (1997). 10 Nutrition and ulcerative colitis. *Baillière's Clinical Gastroenterology*, 11(1), 153–174. [https://doi.org/10.1016/S0950-3528\(97\)90059-2](https://doi.org/10.1016/S0950-3528(97)90059-2)
- Caron, B., Jairath, V., D'Amico, F., Al Awadhi, S., Dignass, A., Hart, A. L., Kobayashi, T., Kotze, P. G., Magro, F., Siegmund, B., Paridaens, K., Danese, S., & Peyrin-Biroulet, L. (2023). International Consensus on Definition of Mild-to-Moderate Ulcerative Colitis Disease Activity in Adult Patients. *Medicina (Lithuania)*, 59(1), 183. <https://doi.org/10.3390/MEDICINA59010183/S1>
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal Of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>

- Chen, H., Xiao, H., Liu, T., & Peng, H. (2015). SmartTracing: self-learning-based Neuron reconstruction. *Brain Informatics*, 2(3), 135–144. <https://doi.org/10.1007/S40708-015-0018-Y>
- Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. <https://doi.org/10.1145/2939672.2939785>
- Chollet, F., & others. (2015). *Keras*. <https://keras.io/>
- Connor, C. W. (2019). Artificial Intelligence and Machine Learning in Anesthesiology. *Anesthesiology*, 131(6), 1346–1359. <https://doi.org/10.1097/ALN.0000000000002694>
- Cunha, C. A. S., & Duarte, R. P. (2022). Multi-Device Nutrition Control. *Sensors* 2022, Vol. 22, Page 2617, 22(7), 2617. <https://doi.org/10.3390/S22072617>
- Cunningham, P., & Delany, S. J. (2020). *k-Nearest Neighbour Classifiers: 2nd Edition (with Python examples)*. <https://doi.org/10.1145/3459665>
- Danese, S., & Fiocchi, C. (2011). Ulcerative Colitis. *New England Journal of Medicine*, 365(18), 1713–1725. <https://doi.org/10.1056/NEJMRA1102942>
- De Castro, M. M., Pascoal, L. B., Steigleder, K. M., De Lourdes Setsuko Ayrizono, M., Milanski, M., Leal, R. F., Siqueira, B. P., & Corona, L. P. (2021). Role of diet and nutrition in inflammatory bowel disease. *World Journal of Experimental Medicine*, 11(1), 1–16. <https://doi.org/10.5493/wjem.v11.i1.1>
- Dopido, I., Li, J., Marpu, P. R., Plaza, A., Bioucas Dias, J. M., & Benediktsson, J. A. (2013). Semisupervised self-learning for hyperspectral image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 51(7), 4032–4044. <https://doi.org/10.1109/TGRS.2012.2228275>
- Feldmann, J., Youngblood, N., Wright, C. D., Bhaskaran, H., & Pernice, W. H. P. (2019). All-optical spiking neurosynaptic networks with self-learning capabilities. *Nature* 2019 569:7755, 569(7755), 208–214. <https://doi.org/10.1038/s41586-019-1157-8>
- Feuerstein, J. D., & Cheifetz, A. S. (2014). Ulcerative Colitis. *Mayo Clinic Proceedings*, 89(11), 1553–1563. <https://doi.org/10.1016/j.mayocp.2014.07.002>
- Fogel, D. B., Hays, T. J., Hahn, S. L., & Quon, J. (2004). A self-learning evolutionary chess program. *Proceedings of the IEEE*, 92(12), 1947–1954. <https://doi.org/10.1109/JPROC.2004.837633>
- GeeksforGeeks. (2024a, junio 10). *Deep Learning | Introduction to Long Short-Term Memory (LSTM)*. <https://www.geeksforgeeks.org/deep-learning-introduction-to-long-short-term-memory/>

- GeeksforGeeks. (2024b, julio 19). *Performing Feature Selection with GridSearchCV in Sklearn*. <https://www.geeksforgeeks.org/performing-feature-selection-with-gridsearchcv-in-sklearn/>
- Géron, A. (2017). *Hands-On Machine Learning with Scikit-Learn and TensorFlow* (1a ed.). O'Reilly Media, Inc. <https://www.amazon.com/Hands-Machine-Learning-Scikit-Learn-TensorFlow/dp/1492032646>
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Jolliffe, I. T. (1990). PRINCIPAL COMPONENT ANALYSIS: A BEGINNER'S GUIDE — I. Introduction and application. *Weather*, 45(10), 375–382. <https://doi.org/10.1002/j.1477-8696.1990.tb05558.x>
- Jowett, S. L., Seal, C. J., Pearce, M. S., Phillips, E., Gregory, W., Barton, J. R., & Welfare, M. R. (2004). Influence of dietary factors on the clinical course of ulcerative colitis: a prospective cohort study. *Gut*, 53(10), 1479–1484. <https://doi.org/10.1136/GUT.2003.024828>
- Kaplan, G. G. (2015). The global burden of IBD: from 2015 to 2025. *Nature Reviews Gastroenterology & Hepatology* 2015 12:12, 12(12), 720–727. <https://doi.org/10.1038/nrgastro.2015.150>
- Keshteli, A. H., Madsen, K. L., & Dieleman, L. A. (2019). Diet in the Pathogenesis and Management of Ulcerative Colitis; A Review of Randomized Controlled Dietary Interventions. *Nutrients* 2019, Vol. 11, Page 1498, 11(7), 1498. <https://doi.org/10.3390/NU11071498>
- Khan, A., Deshpande, S., & Tripathy, A. K. (2019). Optimizing Nutrition using Machine Learning Algorithms-a Comparative Analysis. *2019 International Conference on Nascent Technologies in Engineering, ICNTE 2019 - Proceedings*, 1–4. <https://doi.org/10.1109/ICNTE44896.2019.8946091>
- Khor, B., Gardet, A., & Xavier, R. J. (2011). Genetics and pathogenesis of inflammatory bowel disease. *Nature* 2011 474:7351, 474(7351), 307–317. <https://doi.org/10.1038/nature10209>
- Kingma, D. P., & Ba, J. (2014). *Adam: A Method for Stochastic Optimization*. <https://arxiv.org/abs/1412.6980>
- Kirk, D., Kok, E., Tufano, M., Tekinerdogan, B., Feskens, E. J. M., & Camps, G. (2022). Machine Learning in Nutrition Research. *Advances in Nutrition*, 13(6), 2573–2589. <https://doi.org/10.1093/ADVANCES/NMAC103>

- Kitchenham, B., & Charters, S. (2007). *Guidelines for performing Systematic Literature Reviews in Software Engineering*. 2.
https://www.researchgate.net/publication/302924724_Guidelines_for_performing_Systematic_Literature_Reviews_in_Software_Engineering
- Lee, C., Kim, S., Lim, C., Kim, J., Kim, Y., & Jung, M. (2021). Diet Planning with Machine Learning: Teacher-forced REINFORCE for Composition Compliance with Nutrition Enhancement. *Proceedings of the Association for Computing Machinery SIGKDD International Conference on Knowledge Discovery and Data Mining*, 3150–3160.
<https://doi.org/10.1145/3447548.3467201>
- Lee, Y. Y., Erdogan, A., & Rao, S. S. C. (2014). How to Assess Regional and Whole Gut Transit Time With Wireless Motility Capsule. *Journal of Neurogastroenterology and Motility*, 20(2), 265–270. <https://doi.org/10.5056/jnm.2014.20.2.265>
- Lemaitre, G., Nogueira, F., & Aridas, C. K. (2016). *Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning*.
<https://arxiv.org/abs/1609.06570>
- Lewis, S. J., & Heaton, K. W. (1997). Stool Form Scale as a Useful Guide to Intestinal Transit Time. *Scandinavian Journal of Gastroenterology*, 32(9), 920–924.
<https://doi.org/10.3109/00365529709011203>
- Li, X., Lu, P., Hu, L., Wang, X. G., & Lu, L. (2022). A novel self-learning semi-supervised deep learning network to detect fake news on social media. *Multimedia Tools and Applications*, 81(14), 19341–19349. <https://doi.org/10.1007/S11042-021-11065-X>
- Liashchynskyi, P., & Liashchynskyi, P. (2019). *Grid Search, Random Search, Genetic Algorithm: A Big Comparison for NAS*. <https://arxiv.org/abs/1912.06059>
- Liu, S., & Dobriban, E. (2019). *Ridge Regression: Structure, Cross-Validation, and Sketching*. <https://arxiv.org/abs/1910.02373>
- Louppe, G. (2014). *Understanding Random Forests: From Theory to Practice*.
<https://arxiv.org/abs/1407.7502>
- Magro, F., Gionchetti, P., Eliakim, R., Ardizzone, S., Armuzzi, A., Barreiro-de Acosta, M., Burisch, J., Gecse, K. B., Hart, A. L., Hindryckx, P., Langner, C., Limdi, J. K., Pellino, G., Zagórowicz, E., Raine, T., Harbord, M., & Rieder, F. (2017). Third European Evidence-based Consensus on Diagnosis and Management of Ulcerative Colitis. Part 1: Definitions, Diagnosis, Extra-intestinal Manifestations, Pregnancy, Cancer Surveillance, Surgery, and Ileo-anal Pouch Disorders. *Journal of Crohn's and Colitis*, 11(6), 649–670. <https://doi.org/10.1093/ecco-jcc/jjx008>
- Mogaveera, D., Mathur, V., & Waghela, S. (2021). E-Health Monitoring System with Diet and Fitness Recommendation using Machine Learning. *Proceedings of the 6th*

- International Conference on Inventive Computation Technologies, ICICT 2021*, 694–700. <https://doi.org/10.1109/ICICT50816.2021.9358605>
- Muthukrishnan, R., & Rohini, R. (2016). LASSO: A feature selection technique in predictive modeling for machine learning. *2016 IEEE International Conference on Advances in Computer Applications (ICACA)*, 18–20. <https://doi.org/10.1109/ICACA.2016.7887916>
- Nandhra, G. K., Chaichanavichkij, P., Birch, M., & Scott, S. M. (2023). Gastrointestinal Transit Times in Health as Determined Using Ingestible Capsule Systems: A Systematic Review. *Journal of Clinical Medicine*, 12(16), 5272. <https://doi.org/10.3390/jcm12165272>
- Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., Shamseer, L., Tetzlaff, J. M., Akl, E. A., Brennan, S. E., Chou, R., Glanville, J., Grimshaw, J. M., Hróbjartsson, A., Lalu, M. M., Li, T., Loder, E. W., Mayo-Wilson, E., McDonald, S., ... Alonso-Fernández, S. (2021). Declaración PRISMA 2020: una guía actualizada para la publicación de revisiones sistemáticas. *Revista Española de Cardiología*, 74(9), 790–799. <https://doi.org/10.1016/j.recesp.2021.06.016>
- Panagoulas, D. P., Sotiropoulos, D. N., & Tsihrintzis, G. A. (2021). Nutritional biomarkers and machine learning for personalized nutrition applications and health optimization. *Intelligent Decision Technologies*, 15(4), 645–653. <https://doi.org/10.3233/IDT-210233>
- Pant, V., Bhasin, S., & Jain, S. (2017). Self-Learning system for personalized E-Learning. *2017 International Conference on Emerging Trends in Computing and Communication Technologies, ICETCCT 2017, 2018-January*, 1–6. <https://doi.org/10.1109/ICETCCT.2017.8280344>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Müller, A., Nothman, J., Louppe, G., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2012). *Scikit-learn: Machine Learning in Python*. <https://arxiv.org/abs/1201.0490>
- Peng, C.-Y. J., Lee, K. L., & Ingersoll, G. M. (2002). An Introduction to Logistic Regression Analysis and Reporting. *The Journal of Educational Research*, 96(1), 3–14. <https://doi.org/10.1080/00220670209598786>
- Qi, X., Luo, Y., Wu, G., Boriboonsomsin, K., & Barth, M. (2019). Deep reinforcement learning enabled self-learning control for energy efficient driving. *Transportation Research Part C: Emerging Technologies*, 99, 67–81. <https://doi.org/10.1016/J.TRC.2018.12.018>

- Reis, R., Peixoto, H., Machado, J., & Abelha, A. (2017). Machine Learning in Nutritional Follow-up Research. *Open Computer Science*, 7(1), 41–45.
<https://doi.org/10.1515/COMP-2017-0008/MACHINEREADABLECITATION/RIS>
- Rezvani, S., Pourpanah, F., Lim, C. P., & Wu, Q. M. J. (2024). Methods for class-imbalanced learning with support vector machines: a review and an empirical evaluation. *Soft Computing*, 28(20), 11873–11894. <https://doi.org/10.1007/s00500-024-09931-5>
- Sameen, M. I., Pradhan, B., & Lee, S. (2019). Self-Learning Random Forests Model for Mapping Groundwater Yield in Data-Scarce Areas. *Natural Resources Research*, 28(3), 757–775. <https://doi.org/10.1007/s11053-018-9416-1>
- Staudemeyer, R. C., & Morris, E. R. (2019). *Understanding LSTM -- a tutorial into Long Short-Term Memory Recurrent Neural Networks*. <https://arxiv.org/abs/1909.09586>
- Triantafyllidis, A. K., & Tsanas, A. (2019). Applications of Machine Learning in real-life digital health interventions: Review of the literature. *Journal of Medical Internet Research*, 21(4), e12286. <https://doi.org/10.2196/12286>
- Vasireddy, P. (2020). An Autonomous Diet Recommendation Bot Using Intelligent Automation. *Proceedings of the International Conference on Intelligent Computing and Control Systems, ICICCS 2020*, 449–454.
<https://doi.org/10.1109/ICICCS48265.2020.9121120>
- Vikramkumar, B. V., & Trilochan. (2014). *Bayes and Naive Bayes Classifier*.
<https://arxiv.org/abs/1404.0933>
- Wickramasinghe, M. P. N. M., Perera, D. M., & Kahandawaarachchi, K. A. D. C. P. (2017). Dietary prediction for patients with Chronic Kidney Disease (CKD) by considering blood potassium level using machine learning algorithms. *2017 IEEE Life Sciences Conference, LSC 2017, 2018-January*, 300–303.
<https://doi.org/10.1109/LSC.2017.8268202>
- World IBD Day. (2022). *About IBD (Inflammatory Bowel Diseases) organizations | World IBD Day*. <https://worldibdday.org/about-us#world-organisations>