

PROPUESTA DE TRABAJO FINAL o PROYECTO DE TESIS MAESTRÍA

TÍTULO: Diagnóstico no invasivo del estado de salud del fríjol común (*Phaseolus vulgaris* L) en Colombia:

Un enfoque basado en la huella espectral y la inteligencia artificial

DIRECTOR: Maria Constanza Torres Madroñero

PROGRAMA: Maestría en ingeniería - Analítica

PERFIL: Profundización

AUTOR

John Mario Montoya Zapata

Cédula: 1048019951

E-mail: jmmontoyaz@unal.edu.co

Teléfono: 3 107278305

1. PLANTEAMIENTO DEL PROBLEMA

Colombia es un país cuya tradición agropecuaria enmarca el cotidiano vivir de una gran parte de su población, teniendo más del 90% de su territorio en zona rural (Barbosa Duran, 2022) y alrededor de 15.8% de la población colombiana habitando este territorio rural para 2018 según el DANE (DANE, 2018) (cerca de 11 millones de habitantes identificados subjetivamente como campesinos) (Agronegocios, 2025; Merchán Hernández, 2015). Esto hace del agro un renglón importante en la economía nacional, visibilizado tanto en el sector internacional donde para el mes de diciembre de 2024 alcanzó exportaciones de US\$1.178,9 millones de FOB, presentando un crecimiento de 29.5% comparado con el mismo mes del año 2023 (DANE, 2025). Así mismo, el sector agropecuario representa un importante renglón para el desarrollo interno del país, donde este sector ha venido aumentando su representatividad dentro del Producto Interno Bruto (PIB). Las cifras históricas del DANE (DANE, 2024) demuestran que la variación porcentual del sector ha estado en promedio en 1.5% entre 2018 y 2023, alcanzando para 2024 una variación de 8.1%, que significó un aporte de 0.8 puntos porcentuales a la variación total nacional que se ubicó en 1.7%, es decir, para 2024 el sector agrícola significó un 47% de la actividad económica nacional (MinAgricultura, 2025). Estas cifras significativas han puesto de primera mano la necesidad de la tecnificación del sector agropecuario y la adquisición de metodologías, tecnologías y herramientas, como lo son el proyecto TIC + agro (MinTIC, 2015); y el desarrollo del Plan Estratégico de Ciencia, Tecnología e Innovación del sector Agropecuario colombiano (PECTIA) (MinAgricultura et al., 2016) que potencien el agro a fin de asegurar la calidad y la continuidad de los productos, y con ello el bienestar y seguridad alimentaria del país.

Dentro del sector agropecuario, el fríjol común (*Phaseolus vulgaris* L.) posee una importancia no solo a nivel de comercio, si no que a su vez representa uno de los alimentos prioritarios dentro de la dieta colombiana dado su alto valor nutricional, reflejado en altas cantidades de proteína y minerales, que a su vez pueden emplearse para la extracción de componentes bioactivos que mejoran la durabilidad y promueven el desarrollo de macromoléculas de colágeno humano (Añazco et al., 2023). Además, es un cultivo que se puede dar a la par del crecimiento de otros, como es el caso del café (Jaramillo & Jaramillo-Jiménez Alexander, 2025) enriqueciendo aún más los diferentes usos que puede darse del producto dentro de la economía nacional.

Estudios demuestran que alrededor del 8% de la producción nacional es empleada para el autoconsumo y el restante es usado para el comercio, alcanzando relaciones costo-beneficio de hasta 1.43% demostrando la solvencia económica del cultivo y su aporte a la seguridad alimentaria de las familias colombianas (Martínez-Reina et al., 2021). Como resultado de este potencial, la implementación de procesos y técnicas que mejoren la productividad del cultivo y la sostenibilidad a mediano y largo plazo representan un reto para el sector agropecuario requiriendo mayor acompañamiento tanto de entidades gubernamentales como de carácter técnico-científico (Acevedo Pérez & Zuluaga Sánchez, 2021).

Uno de los procesos críticos en la producción agrícola en general, y particularmente para el cultivo de frijol, es el uso eficiente de fertilizantes. Dentro de estos, el fósforo juega un papel fundamental en los procesos fisiológicos de la planta, como el consumo de agua y la fotosíntesis. Se ha demostrado que según el proceso de fertilización se puede obtener mejores rendimientos, por ejemplo, la fertilización de base puede aumentar el rendimiento del cultivo de frijol común en un 38% en comparación con el abonado de cobertera. Además, la combinación del fertilizante de base con el riego en la fase de llenado de semillas se ha identificado como la estrategia más eficiente en el uso del agua, logrando el máximo rendimiento por cada unidad de este recurso (7.2 kg/(hm²·mm)) (Y. Gao et al., 2016).

Estos resultados demuestran que al controlar las variables que influyen en el crecimiento y producción del cultivo se incrementa su productividad que a su vez se refleja en mayores ganancias para el agricultor. Así pues, dentro de la industria ha venido desarrollándose el concepto de agricultura de precisión, que consiste en la implementación de tecnologías de la información y la comunicación (TIC) para observar, medir y responder a la variabilidad espacio-temporal en los campos de cultivo; es decir, lo que pretende es desarrollar un cultivo inteligente que maximice las ganancias, asegure productos de alta calidad y emplee de manera eficiente los insumos para la producción (Agencia UNAL, 2022). Al respecto, la emergente aplicación de la analítica avanzada, incluyendo técnicas de aprendizaje automático (Machine Learning - ML) y aprendizaje profundo (Deep Learning - DL), ofrece oportunidades sin precedentes para abordar estas problemáticas en la agricultura. Investigaciones a nivel global han demostrado el potencial de estas herramientas para analizar datos complejos provenientes de diversas fuentes (sensores remotos, imágenes espectrales, datos climáticos, etc.) y detectar patrones sutiles asociados al bienestar del cultivo a menudo antes de que los síntomas sean visibles al ojo humano (Bal & Kayaalp, 2021; Benos et al., 2021; Sherkhane & Ratnaparkhi, 2024; C. Wang et al., 2021).

No obstante, la aplicación específica de estas metodologías para la detección temprana de estrés por exceso de fósforo en el cultivo de frijol, particularmente en el contexto colombiano, no presenta investigaciones. La aplicación se ha centrado en otros cultivos también de alta tradición para la economía nacional, como lo son el cacao (Lamos-Díaz et al., 2020; Talero-Sarmiento et al., 2025) y el café (Corrales et al., 2014; Motta et al., 2025); sin embargo, han sentado precedentes positivos para la extensión de las técnicas a diferentes cultivos, como es el caso del frijol común colombiano.

Por lo tanto, esta investigación se enfoca en explorar y validar la viabilidad de utilizar métodos estadísticos, de ML y DL para clasificar plantas de frijol cultivadas en condiciones controladas, diferenciando entre plantas sanas (etiqueta 0) y plantas sometidas a un régimen de subexposición a la cantidad ideal de fósforo (etiqueta 1) empleando como principal insumo imágenes hiperespectrales (HSI, por sus siglas en inglés) que por su definición permiten la identificación de la firma espectral del cultivo y con ello una posible oportunidad para la detección temprana de la sanidad del cultivo.

2. JUSTIFICACIÓN

La agricultura en Colombia es un sector vital para la economía nacional y la seguridad alimentaria (DANE, 2024, 2025; MinAgricultura, 2025), con una extensa tradición que involucra a una gran parte de su población rural (Agronegocios, 2025; DANE, 2018; Merchán Hernández, 2015). En este contexto, el fríjol (*Phaseolus vulgaris* L.) se destaca como un cultivo de gran importancia tanto nutricional (Añazco et al., 2023) como económica y para la soberanía alimentaria (Martínez-Reina et al., 2021), además de sus beneficios en sistemas de policultivo (Jaramillo & Jaramillo-Jiménez Alexander, 2025). La optimización de su producción, particularmente mediante el manejo eficiente de nutrientes esenciales como el fósforo, cuyo impacto en el rendimiento ha sido demostrado (Y. Gao et al., 2016), representa un desafío constante que requiere acompañamiento técnico-científico. Si bien la agricultura de precisión y diversas tecnologías han comenzado a implementarse, impulsadas por iniciativas nacionales (MinAgricultura et al., 2016; MinTIC, 2015), existe una oportunidad significativa para explorar enfoques más avanzados que permitan un diagnóstico temprano y preciso del estado de las plantas, llevando a una gestión agrícola más sostenible y productiva.

La presente investigación se fundamenta en la ya mencionada brecha de la inclusión de técnicas avanzadas de percepción remota y el uso de análisis de datos para el monitoreo del cultivo de fríjol en Colombia, brecha que ya ha sido explorada exitosamente en otros cultivos como el café y el cacao. Particularmente, se encuentra oportunidad en la aplicación de ML y DL para la detección temprana de estrés nutricional, como la deficiencia de fósforo, a través del análisis de imágenes. Esta brecha tecnológica ahonda en la problemática de toma de decisiones informadas, óptimas y oportuna, que a su vez dificulta el uso eficiente de fertilizantes y recursos en general, creando así cadenas de producción poco eficientes y menos productivas del cultivo de fríjol en el país; así pues, se espera que este estudio aproveche al cierre de dicha brecha tecnológica, ofreciendo un marco metodológico y una aplicación real, con potencial de expansión industrial, que aporte al desarrollo de la agricultura de precisión en el cultivo.

Para abordar esta problemática, se propone como insumo base el empleo de imágenes hiperespectrales, las cuales tienen la capacidad de capturar información de una escena a través de cientos de bandas espectrales estrechas y contiguas, lo cual permite tener un amplio rango del espectro electromagnético (Ver figura 1) de los objetos presentes en la escena, usualmente desde el “visible” (VIS, ~400-700 nm) hasta el “infrarojo” (NIR, ~700-1000 nm) e incluso el infrarrojo de onda corta (SWIR, ~1000-2500 nm) (Bhargava et al., 2024; Cheng et al., 2025; Omia et al., 2023). El potencial de la imagen hiperespectral radica en que cada píxel contiene una “firma espectral” continua y detallada, que representa la reflectancia (fracción de radiación incidente que una superficie refleja), absorbancia (fracción de radiación que absorbe una sustancia o superficie cuando es atravesada por la luz) o emitancia (capacidad de una superficie o sustancia para emitir energía como energía térmica) (Miras et al., 2023) de la superficie en cada una de esas bandas y que actúa como una huella dactilar única del píxel y por tanto del objeto contenido en éste, permitiendo realizar inferencias sobre la composición bioquímica (por ejemplo, pigmentos presentes, cantidad de agua, proteínas, lignina, etc) y la estructura biofísica del objeto (Lu et al., 2020), en este caso de la planta, lo cual permite identificar variaciones sutiles que serían indetectables empleando otros medios.

La principal diferencia entre las imágenes hiperespectrales (HSI), multiespectrales (MSI) y RGB radica, como se ha mencionado, en la resolución espectral alcanzada (ver figura 1). Por un lado, se tienen las imágenes RGB (Rojo, Verde, Azul) las cuáles son las más comunes, incluso de uso diario, y que puede capturar tres bandas anchas del espectro electromagnético, asociadas a los colores mencionados, que corresponden aproximadamente con la sensibilidad del ojo humano proporcionando información visual básica pero carente de detalle espectral para análisis de carácter biofísico o bioquímico profundo (Lowe et al., 2017). También se cuenta con las MSI que pueden capturar algunas bandas más (alrededor de 10 o un

poco más) pero no necesariamente continuas dejando así registros espectrales imposibles de rastrear y con ello propiedades indecibles a partir de su uso, estas imágenes suelen ser útiles para el cálculo de índices de vegetación estándar (como el NDVI (Omia et al., 2023)). Finalmente, como se ha mencionado, en la actualidad podemos encontrar imágenes HSI que ofrecen un espectro casi continuo, mostrando así una ventaja sobre el uso de otro tipo de imágenes ya que, como menciona (J. Zhang et al., 2019) “La alta resolución espectral del sensor hiperspectral permite capturar cambios espectrales débiles o discretos, lo cual es fundamental para el monitoreo de enfermedades y plagas de plantas en etapas tempranas o en escenarios complejos”, esto antes de que sean visualmente aparentes o detectables con RGB/MSI y conservando el carácter no destructivo o invasivo sobre el cultivo, lo cual es una oportunidad crucial para la intervención temprana en las plantaciones de frijol.




Figura 1. Distribución del rango espectral en una onda de luz. Tomado de “*Hyperspectral image analysis techniques for the detection and classification of the early onset of plant disease and stress*” (Lowe et al., 2017)

Ahora bien, el uso de HSI presenta retos importantes, como lo son:

1. Gran volumen de datos requiriendo así una considerable capacidad de almacenamiento y procesamiento
2. presencia de colinealidad y redundancia en bandas adyacentes (Fenómeno de Hughes (Hughes, 1968))
3. Necesidad de preprocesamientos exhaustivos que realizan correcciones de tipo atmosférico, radiométrico, geográfico, reducción de ruido, desmezclado espectral, entre otros (Yel & Tunc Gormus, 2023)
4. Altos costos para la adquisición de los sensores capaces de capturar estas imágenes y complejidad en la operación

Dichos retos, si bien representan un desafío para la presente investigación, son tratables dada la oportunidad manifiesta, ya que al ser combinados con técnicas de ML y DL se puede ahondar en la identificación de patrones en las plantaciones de frijol y dar manejo a la alta dimensionalidad de los datos iniciales para obtener modelos predictivos que apunten tanto al desarrollo de las propuestas gubernamentales anteriormente mencionadas, así como al desarrollo de la agricultura de precisión.

Como muestra de su potencial, HSI ha sido aplicado en múltiples campos, desde la geología y el monitoreo ambiental hasta la industria alimentaria y médica. En la agricultura, su aplicación ha arrojado resultados notables en la detección temprana de enfermedades (Corrales et al., 2014; N. Li et al., 2024; Y. Liu et

al., 2025; Lowe et al., 2017; Morchid et al., 2024; Pfordt & Paulus, 2025; J. Zhang et al., 2019), la evaluación del estrés hídrico (Bhargava et al., 2024; Kim et al., 2011; Krishna et al., 2019; Patiluna et al., 2025) y la estimación del estado nutricional a través de la cuantificación de macronutrientes como el nitrógeno, el fósforo y el potasio en cultivos diversos cultivos (Tang et al., 2024; Y. Zhang et al., 2024) siendo prometedor para el uso en cultivos de frijol. Además, existen aplicaciones significativas en geología y minería, para la identificación y mapeo de minerales en la superficie del suelo (Tan et al., 2020) terrestre; en el monitoreo ambiental, para evaluar la salud de los ecosistemas (Z. Li et al., 2014), y mapear la cobertura vegetal y tipos de suelo (Y. Xu et al., 2019); en la industria alimentaria, para el control de calidad, la detección de contaminantes y adulteraciones, y la caracterización de propiedades de los alimentos (Goyal et al., 2024); y en medicina, para el diagnóstico no invasivo de enfermedades, como la detección de neuropatía diabética periférica (Sheen et al., 2025), la investigación de enfermedades renales (Tian et al., 2024), y la detección temprana de células cancerosas (Youssef et al., 2024).

Las ventajas transversales de la HSI, como su naturaleza no invasiva, su capacidad para cubrir áreas extensas mediante plataformas aéreas o satelitales, o para realizar mediciones detalladas a corta distancia en laboratorio o campo, junto con la riqueza de la información espectral que proporciona, fundamentan su creciente adopción. Los resultados obtenidos demuestran consistentemente una mayor precisión y la capacidad de detección temprana en comparación con métodos tradicionales o sensores más simples, especialmente cuando se combinan con análisis avanzados de datos como el ML y DL.

Esta investigación se propone, por lo tanto, aprovechar estas ventajas y oportunidades aplicando la HSI junto con métodos de ML y DL para clasificar plantas de frijol según su estado de sanidad general (sana versus no sana) con base en su contenido relativo de fósforo. Al hacerlo, no solo se abordará una brecha existente en la investigación para el cultivo de frijol en Colombia, sino que también se contribuirá con conocimiento y herramientas aplicables. Estas contribuciones tienen el potencial de potenciar la agricultura de precisión, mejorar la eficiencia en el uso de fertilizantes y, en última instancia, fortalecer la seguridad alimentaria y la sostenibilidad (Pandey & Pandey, 2023) del sector agrícola colombiano.

3. OBJETIVOS

3.1. OBJETIVO GENERAL

Desarrollar un modelo de inteligencia artificial para soportar el diagnóstico no invasivo del estado de salud de cultivos de frijol común desde huellas hiperespectrales

3.2. OBJETIVOS ESPECÍFICOS

1. Establecer una base de datos hiperespectrales etiquetados y organizados para el entrenamiento de modelos de inteligencia artificial que permitan el diagnóstico del estado de salud de cultivos de frijol común
2. Caracterizar la huella hiperespectral de frijol común para facilitar el diagnóstico del estado de salud de un cultivo
3. Seleccionar un modelo de inteligencia artificial supervisado para el diagnóstico del estado de salud de plantas de frijol común desde huellas hiperespectrales, basados en el estrés de fósforo al cual se encuentran sometidas las plantas.

4. MARCO TEÓRICO

4.1. Agricultura de precisión

La agricultura de precisión (AP), también conocida como agricultura inteligente o “smart farming” consiste en un paradigma que busca optimizar y mejorar la gestión de cultivos agrícolas haciendo uso de tecnologías vanguardistas y metodologías fundamentadas en datos cuyo enfoque abarca tanto la variabilidad espacial como la temporal de los cultivos (Kushwaha et al., 2024). El objetivo primordial es la maximización en la eficiencia productiva y el uso de recursos a través del ajuste de insumos (pesticidas, riego, fungicidas, nutrientes, etc) a las necesidades específicas de las plantas individuales o de microzonas dentro de una parcela de tierra, en contraposición a las aplicaciones uniformes que tradicionalmente se realizan sobre terrenos extendidos (Mahanto et al., 2024). Dicha optimización se realiza para abordar problemas directamente relacionados con la producción de alimentos, como lo son: el crecimiento demográfico y con ello el aumento del consumo, el cambio climático y las crisis que conlleva, entre otros, todos ellos abordados de manera que se dé un aumento en la producción a la vez que se tienen una reducción en la huella ambiental (Saini et al., 2025).

Así pues, la AP se concentra en la gestión específica de un sitio y sus insumos, reconociendo la heterogeneidad en las propiedades del suelo, la topografía, el clima (o microclima) y otros factores de carácter agronómicos que varían incluso al interior de un mismo cultivo. Esta aplicación dirigida de los insumos y el manejo específico de la microzona permiten que el cultivo reciba las dosis adecuadas en el momento y lugar precisos, optimizando el crecimiento y rendimiento de cada planta, reduciendo el desperdicio y minimizando el impacto ambiental. (Kushwaha et al., 2024).

Para que dicha aplicación sea eficiente y realizable, es requerida la recopilación de datos exactos y oportunos, recopilados a través de múltiples tecnologías de sensores e imagenología, como por ejemplo las imágenes HSI que proporcionan información de las bandas espectrales de manera casi continua, lo que permite una caracterización detallada del grado de sanidad de cada planta. Como se ha mencionado, la HSI se basa en la propiedad que tienen los materiales para absorber selectivamente algunas longitudes de onda lumínica mientras que otras son reflejadas o dispersadas, habilitando así un método no invasivo para su estudio. En este contexto, se utilizan sensores hiperespectrales próximos al cultivo, que pueden ser terrestres, montados en Vehículos Aéreos No Tripulados (UAV) portátiles de mano o espectralradiómetros, entre otros, usados para diversas aplicaciones agrícolas (Ram et al., 2024).

Adicionalmente, la AP integra sensores específicos para el monitoreo del ambiente o microclima del cultivo, como por ejemplo sensores de humedad y temperatura edáfica para realizar un seguimiento riguroso de las condiciones del suelo y el aire, o tecnologías para determinar el contenido de macronutrientes como nitrógeno (N), fósforo (P), potasio (K) y el contenido de materia orgánica (Saini et al., 2025). Las tecnologías de localización son igualmente relevantes en el área ya que permiten la ubicación geoespacial de objetos y con ello facilitan el seguimiento, navegación y control de las operaciones en el cultivo, destacando entre ellas los Sistemas de Posicionamiento Global (GPS) y la teledección (Kushwaha et al., 2024; Mahanto et al., 2024) que ofrecen cobertura global e información en tiempo real, elementos cruciales para la AP.

Otra área de importancia para el desarrollo de la AP es el uso de El Interet de las Cosas (IoT) el cual desempeña un rol conector, enlazando dispositivos tales como sensores de suelo, drones y maquinaria inteligente, para posibilitar el monitoreo continuo y la automatización de procesos. El IoT facilita la supervisión precisa de la calidad del suelo, las condiciones climáticas, la sanidad vegetal y la eficiencia en la cadena de suministro (Debnath et al., 2024; Saini et al., 2025). Actualmente, con base en la información adquirida, se ha venido aumentando de manera progresiva la implementación de Inteligencia Artificial

(AI) y técnicas de ML, capacitando a los sistemas para aprender, analizar e identificar patrones, y realizar predicciones acerca de diferentes áreas de interés sobre el cultivo, como lo son la estimación del rendimiento, la detección temprana de enfermedades, la presencia de maleza, el análisis de la composición del suelo e incluso la optimización de los recursos asignados (Debnath et al., 2024; Mahanto et al., 2024). No obstante, la implementación de la AP enfrenta múltiples desafíos y limitaciones. Un obstáculo importante radica en los altos costos de adquisición e implementación de nuevas tecnologías, restringiendo así su accesibilidad, especialmente para pequeños agricultores, aumentando así la brecha digital. También es requerido una infraestructura adecuada para la recopilación, procesamiento y gestión de los datos adquiridos; y además, una alta capacidad para la operabilidad y escalabilidad de la información ya que la AP genera extensos conjuntos de información, demandando así conceptos metodológicos de almacenamiento, procesamiento y estandarización robustas. Tales demandas, a su vez implican consumos energéticos elevados, producto del uso de sistemas de AI e IoT (Debnath et al., 2024).

Otros desafíos específicos para su implementación incluyen la interferencia de señales, las limitaciones en la precisión y el rendimiento en tiempo real de las tecnologías de localización en entornos agrícolas dinámicos y complejos. Por ejemplo, la localización basada en TOA (Tiempo de Llegada) requiere una sincronización horaria estricta, hecho complicado dada la falta de infraestructura adecuada. Similarmente, la implementación de robots que apoyen las tareas agrícolas sigue siendo un problema (Diao et al., 2025), más aún en entornos colombianos cuya geografía representa un reto dada su variabilidad climática y los cambios geográficos teniendo terrenos identificados como sabanas hasta entornos montañosos. Adicionalmente, aún existen debates de carácter ético sobre la privacidad de la información recolectada, la propiedad intelectual de las soluciones y el acceso equitativo a soluciones impulsadas por AI para que dichas tecnologías beneficien a todas las partes interesadas (Debnath et al., 2024). Finalmente, una problemática no menor radica en la dependencia de etiquetado de alta calidad para la data recolectada de manera que pueda explotarse todo el potencial de los algoritmos de ML o DL (Saini et al., 2025).

Ahora bien, las oportunidades que se tienen al emplear AP son de relevancia para el entorno agrícola colombiano, en términos de asegurar sostenibilidad y alta productividad. Dentro de sus ventajas podemos nombrar una reducción del impacto ambiental al minimizar el uso de fertilizantes, la lixiviación de nitrógeno, las emisiones de gases nocivos y la optimización del consumo de materias primas, lo que termina en una reducción de la huella de carbono. A su vez, permite optimizar la eficiencia en el uso de recursos naturales como el agua, aportando así a la conservación de los recursos naturales (Saini et al., 2025); también es destacable la detección temprana de problemas en los cultivos como lo son el estrés de las plantas, enfermedades y deficiencia de nutrientes, ayudando así a desarrollar una mejor gestión del riesgo ante eventos de difícil predicción (Saini et al., 2025) dados por la ya mencionada variabilidad climática del entorno colombiano.

El potencial que representa la AP para el área agrícola es tal que la adopción de dicho enfoque está creciendo rápidamente a nivel global. La investigación muestra una expansión sustancial y veloz en el campo, particularmente desde el año 2000, impulsada por la introducción de IoT, los Robots Agrícola (AR) y la inteligencia artificial (AI) (Ver figura 2), por ejemplo, se evidencia que entre 2017 y 2023, la tasa promedio anual de publicaciones experimentó un aumento exponencial, alcanzando los 2215 artículos, con más de 3860 artículos publicados en 2023. También se encuentra que China es el país más productivo en términos de publicaciones relacionadas con agricultura de precisión, mientras que Estados Unidos es quien lidera la salida de nuevas patentes. (Saini et al., 2025). En el caso de la agricultura colombiana, y en general de los países en desarrollo, los retos están dados por los costos de implementación, la infraestructura inadecuada, la brecha digital y las dificultades de acceso para los pequeños agricultores (Debnath et al., 2024).




Figura 2. Distribución por años de las publicaciones sobre agricultura de precisión. Tomado de: ***“A Comprehensive review on technological breakthroughs in precision agriculture: IoT and emerging data analytics”*** (Saini et al., 2025)

Las perspectivas futuras para la agricultura de precisión se centran en la innovación continua y la superación de las barreras existentes (Kushwaha et al., 2024). La investigación futura deberá priorizar la recopilación precisa de datos provenientes de múltiples y diversas fuentes, con un enfoque particular en la fusión de datos multisensoriales (Diao et al., 2025; Saini et al., 2025). Es crucial mejorar la interpretabilidad y adaptabilidad de los modelos de ML mediante el desarrollo de características explicables para los agricultores, facilitando así su adopción y confianza en estas herramientas (Saini et al., 2025). Paralelamente, se debe poner un énfasis significativo en la creación de soluciones tecnológicas que sean rentables y de bajo consumo energético, así como en el desarrollo de sistemas robustos y en la mejora continua de hardware y algoritmos. Abordar la seguridad de los datos y perfeccionar los métodos de fusión de información son aspectos críticos para lograr tecnologías de localización agrícola que sean escalables y efectivas en campo (Diao et al., 2025). Adicionalmente, el desarrollo de maquinaria agrícola altamente personalizada y eficiente, la integración de nanomateriales biogénicos para la nutrición y protección de cultivos, y los avances en tecnologías como la impresión 3D para la fabricación de herramientas y repuestos agrícolas, se perfilan como direcciones futuras prometedoras y transformadoras para el sector (Debnath et al., 2024).

4.2. Percepción remota e imágenes hiperspectrales

La percepción remota se define como una estrategia de gestión que utiliza un conjunto de tecnologías avanzadas de información, comunicación y análisis de datos para observar la tierra desde la distancia (Huang et al., 2018; Sishodia et al., 2020). Desde la década de 1960, los satélites de observación de la tierra han sido un pilar fundamental en este campo, permitiendo el monitoreo simultáneo de una amplia gama de objetivos terrestres (Y. Wang et al., 2023) y generando un vasto volumen de datos (Z. Zhang & Zhu, 2023). En el contexto de la agricultura de precisión (AP), la percepción remota es una tecnología clave que, junto con los datos de posicionamiento global y la información geográfica, produce datos e información espacialmente variable para optimizar los insumos agrícolas, aumentar la producción y reducir el impacto ambiental, al considerar la variabilidad dentro del campo (Huang et al., 2018).

No obstante, la teledetección tradicional basada en satélites presentaba limitaciones significativas para la AP. La resolución espacial de las imágenes satelitales era a menudo baja, limitando la capacidad de capturar variaciones de pequeña escala en la salud de los cultivos, por ejemplo, las cámaras pancromáticas de los satélites en ese momento solo podían identificar objetos cuya longitud fuese de 3 o más metros (Z. Zhang & Zhu, 2023). Además, la calidad de las imágenes y la selección de éstas se veía afectada gravemente dadas las condiciones meteorológicas, como la nubosidad y las condiciones de iluminación del objetivo (Sishodia et al., 2020), limitando así el alcance y las direcciones de investigación en teledetección. En la última década, la emergencia de los vehículos aéreos no tripulados (UAVs), en particular los multirrotores, ha transformado gradualmente estas limitaciones, ofreciendo una plataforma más flexible y adaptable (Allu & Mesapam, 2025).

Como una tecnología prometedora, han surgido las imágenes hiperespectrales (HSI) que pueden ser tomadas desde los UAVs. Las HSI, como se ha mencionado, son un tipo de datos de teledetección que se caracterizan por capturar información en cientos de bandas de longitud de onda estrechas y contiguas (generalmente con un ancho de banda inferior a 10 nm. A diferencia de las cámaras multispectrales, que capturan datos en unas pocas bandas discretas, las hiperespectrales proporcionan un espectro casi continuo para cada píxel) (Bhargava et al., 2024; Cheng et al., 2025; Omia et al., 2023; Z. Zhang & Zhu, 2023). Esta capacidad permite que se capturen las variaciones mínimas en propiedades bioquímicas y biofísicas de las plantas que controlan capacidades como la reflectancia de la planta, así como el análisis detallado de la composición química y el contenido de agua y nutrientes (Kganyago et al., 2024; Lu et al., 2020). Por ello, son fundamentales para identificar bandas espectrales significativas donde los rasgos de las plantas absorben energía electromagnética (características de absorción) (Miras et al., 2023).

En el contexto de la AP, como se ha mencionado, las imágenes hiperespectrales juegan un papel crucial. Su resolución espacial ultra-alta (de centímetros o incluso milímetros por píxel), permite observar problemas imperceptibles a nivel satelital, como las manchas de enfermedades en las hojas de las plantas de solo 1-2 mm de diámetro en las primeras etapas (Z. Zhang & Zhu, 2023). Además de la observación y detección temprana de enfermedades en diversos cultivos, los datos hiperespectrales son valiosos para estimar el contenido de agua del suelo, monitorear el contenido de nutrientes (como el nitrógeno, el potasio, el fósforo y clorofila), y realizar estimaciones de rendimiento del cultivo. También son esenciales para la clasificación e identificación de malezas y la diferenciación de especies vegetales (Sishodia et al., 2020).

En este sentido, los UAVs juegan un rol fundamental como plataformas de teledetección, puesto que pueden equiparse flexiblemente con una variedad de sensores según la tarea que se vaya a realizar (Z. Zhang & Zhu, 2023). Las categorías principales de sensores incluyen: cámaras RGB (ópticas) que capturan el espectro visible, utilizadas para mapeo de vegetación y monitoreo ambiental; cámaras multispectrales que capturan múltiples bandas espectrales para identificar características específicas como especies vegetales o calidad del agua (Sishodia et al., 2020); y cámaras hiperespectrales que, como se mencionó, proporcionan un detalle espectral mucho mayor. Además de los sensores de imagen, los UAVs también pueden equiparse con un LIDAR para obtener información tridimensional y otros sensores como detectores de gases o partículas de aire (Z. Zhang & Zhu, 2023).

Las ventajas clave de los UAVs como plataformas de sensores en la agricultura de precisión son numerosas. Ofrecen una resolución espacial de decímetros, centímetros o incluso milímetros por píxel, lo que es inalcanzable para la mayoría de los satélites actuales y vital para detectar problemas a pequeña escala (Sishodia et al., 2020). Permiten una flexibilidad y control de vuelo excepcionales, pudiendo programar todo el proceso y realizar observaciones a demanda, lo que permite múltiples vuelos en poco tiempo y la adquisición de datos en momentos cruciales del ciclo de cultivo (Z. Zhang & Zhu, 2023). Son menos

susceptibles a condiciones meteorológicas como nubes y lluvia debido a su baja altitud. Además, los UAVs son más estables, confiables y económicos de operar y mantener en comparación con aeronaves tripuladas y, para áreas pequeñas, con satélites comerciales. Su capacidad para generar información tridimensional del terreno y los cultivos mediante técnicas como Structure-from-Motion (SfM-MVS) o escaneo LIDAR es invaluable (Huang et al., 2018).

A pesar de sus múltiples ventajas, el uso de UAVs en la AP también presenta desafíos y limitaciones. La duración de vuelo es relativamente corta para los multirrotores, típicamente alrededor de 30 minutos, lo que limita la cobertura de grandes extensiones (Sishodia et al., 2020). Para áreas extensas, los UAVs de ala fija son más adecuados, pero la resolución de las imágenes puede ser menor a mayor altitud (Z. Zhang & Zhu, 2023). El gran volumen y complejidad de los datos generados por los sensores de alta resolución (conocido como "Big Data") requiere métodos avanzados de procesamiento, almacenamiento, análisis y visualización (Huang et al., 2018). Los costos iniciales de adquisición de equipos, procesamiento de datos y software pueden ser significativos para pequeños agricultores, por ejemplo, se ha estimado que los costos relacionados a la captura de imágenes está alrededor de los USD 7,4 a 12,4/ha (USD 3-5/acre) (Khanal et al., 2020). Además, existen restricciones regulatorias (como volar dentro de la línea de visión) y limitaciones de carga útil que restringen el uso simultáneo de múltiples sensores. La falta de procedimientos estandarizados para la calibración en vuelo de los sensores de UAVs puede resultar en representaciones inexactas de las señales espectrales debido a la variación de las condiciones ambientales (Sishodia et al., 2020). Las imágenes de ultra-alta resolución de UAVs también pueden introducir incertidumbre debido a la alta variabilidad espacial, incluyendo el ruido de los espacios entre hileras, el suelo, las malezas, la hojarasca y las sombras, lo que requiere pasos de preprocesamiento como el enmascaramiento (Kganyago et al., 2024). Finalmente, la adopción a gran escala se ve dificultada por la complejidad del procesamiento de imágenes y la necesidad de experiencia técnica.

Para abordar la gestión de los masivos datos generados por la teledetección en AP, las redes neuronales y los métodos de aprendizaje automático (ML y DL) se han convertido en enfoques predominantes para el procesamiento de datos de imágenes (RGB, multiespectrales, hiperespectrales) (Bal & Kayaalp, 2021; Benos et al., 2021; Debnath et al., 2024). La fusión de datos de múltiples fuentes (satélite, UAV y plataformas terrestres) es crucial para superar las limitaciones individuales y mejorar la precisión. Sin embargo, la adopción a gran escala sigue siendo un desafío debido a la complejidad del procesamiento, la necesidad de conocimiento técnico y la falta de marcos automatizados o establecidos. Por lo tanto, se necesita desarrollar flujos de trabajo simples pero confiables y sistemas fáciles de usar para una adopción más amplia de estas tecnologías (Sishodia et al., 2020). A pesar de los avances, persisten incertidumbres en la recuperación de parámetros bioquímicos y biofísicos debido a errores en las mediciones in-situ, condiciones de adquisición y la parametrización de los modelos de transferencia radiativa (RTMs) y algoritmos de Machine Learning (Kganyago et al., 2024).

4.3. Inteligencia artificial y sus aplicaciones en la agricultura

4.3.1. Procesamiento de imágenes hiperespectrales

Previo a la aplicación de Inteligencia Artificial (por ejemplo, algoritmos de ML o DL) bien sea para el análisis, extracción de información o predicción de alguna condición particular, es necesario realizar un preprocesamiento y procesamiento de las HSI con el fin de mejorar la calidad de los datos, reducir la complejidad y extraer características relevantes, permitiendo así que los algoritmos funcionen de manera efectiva.

Adquisición y Generación del Cubo de Datos

La fase inicial y fundamental para el análisis de HSI consiste en la adquisición y generación del cubo de datos. Como se explica en (Tejasree & Agilandeewari, 2024) el proceso de adquisición y generación del cubo implica la recolección de datos en cientos de bandas espectrales continuas y estrechas, a diferencia de las imágenes tradicionales RGB o multispectrales que carecen de esta precisión espectral y rango, dando como resultado la creación de un cubo de datos tridimensional (3D), que captura una vasta cantidad de información detallada sobre la superficie de un objeto. Cada píxel en una HSI puede considerarse un vector de alta dimensión que representa la reflectancia espectral en longitudes de onda específicas (S. Li et al., 2019).

La adquisición de estas imágenes se realiza mediante sensores hiperespectrales montados en diversas plataformas. Inicialmente, esta tecnología se empleó en satélites y aeronaves tripuladas, pero más recientemente, los sistemas aéreos no tripulados (UAS/UAVs) han surgido como una alternativa muy popular y rentable. Los sensores utilizados para esta conversión de fotones incidentes en electrones suelen ser de tipo "Dispositivos de Carga Acoplada" (CCD) (Charge-Coupled Device) o los dispositivos "Semiconductor de Óxido Metálico Complementario" (CMOS) (Complementary Metal-Oxide-Semiconductor). Mientras que los sensores basados en CCD poseen una mayor sensibilidad para la adquisición de datos de banda, los CMOS de alta calidad exhiben una eficiencia cuántica superior en el infrarrojo cercano (NIR)10. Ejemplos de sensores comerciales compatibles con UAVs incluyen el BaySpec OCI-UAV-1000 y el Brandywine Photonics CHAI S-64011 (Adão et al., 2017).

Como menciona (Adão et al., 2017), existen cuatro modos principales para la adquisición de datos hiperespectrales (Ver figura 3): barrido de punto (whiskbroom), barrido de línea (pushbroom), barrido de plano y toma única (single shot). El modo whiskbroom captura todas las bandas píxel a píxel, resultando en un cubo de datos bandas entrelazadas por píxel (Band-Interleaved-by-Pixel (BIP)). Por su parte, el modo pushbroom adquiere una secuencia completa de píxeles que forman una línea, constituyendo un cubo de bandas intercaladas por líneas (Band-Interleaved-by-Line (BIL)), y se caracteriza por su tamaño compacto, bajo peso, operación más sencilla y una mayor relación señal-ruido. El barrido de plano genera un cubo secuencial de banda (Band Sequential (BSQ)) a partir de múltiples imágenes tomadas simultáneamente. Finalmente, la toma única, o "snapshot imager", es un modo más reciente que captura todos los datos espaciales y espectrales de una vez.




Figura 3. Modos para la adquisición de datos hiperespectrales. Tomado de: **"Hyperspectral Imaging: A Review on UAV-Based Sensors, Data Processing and Applications for Agriculture and Forestry"** (Adão et al., 2017)

Una vez la luz es capturada por los sensores, se utiliza un prisma o rejilla de difracción para dividirla en sus longitudes de onda constituyentes (bandas). Cada elemento del sensor detecta una longitud de onda diferente. Al apilar múltiples imágenes de una escena, se construye un cubo de datos 3D, donde las dimensiones X e Y representan las coordenadas espaciales y la dimensión Z encapsula la longitud de onda de la luz capturada. Matemáticamente, un cubo HSI puede expresarse como

$$X = [x_1, x_2, \dots, x_b]^T \in \mathbb{R}^{B \times (N \times M)}$$

donde $N \times M$ es el número total de píxeles y B es el número de canales. A medida que el número de bandas aumenta y los intervalos de longitud de onda se vuelven más estrechos, se puede obtener una curva casi continua que representa la información espectral de cada píxel (Zhao et al., 2025).

Calibración y correcciones

Las HSI capturan un espectro casi continuo, sin embargo, los datos brutos adquiridos suelen estar afectados por diversos factores que introducen ruido y distorsiones. Por ello, la fase de "Calibración y Correcciones" es crucial para transformar estos datos crudos en información fiable y utilizable para el análisis posterior, incluyendo los algoritmos de AI. Este paso de preprocesamiento asegura la utilidad de los datos hiperespectrales, abordando problemas como el ruido radiométrico, la interferencia atmosférica y las distorsiones geométricas, que pueden degradar la calidad de la imagen y ocultar detalles importantes. El objetivo final es obtener cubos hiperespectrales espacial y espectralmente fiables, a menudo denominados **datos de nivel uno** (Adão et al., 2017).

- **Calibración Radiométrica (RC):** La calibración radiométrica (RC) es un proceso esencial para transformar los valores brutos de los píxeles de una imagen, conocidos como Números Digitales Crudos (RDN), en unidades físicas significativas como la radiancia o la reflectancia. Este paso es fundamental porque los RDN se ven afectados por múltiples factores externos, como la iluminación solar, las condiciones atmosféricas y las características propias del sensor. Al realizar esta corrección, se eliminan estas distorsiones y se garantiza el rigor científico de los datos, lo que permite una comparación fiable entre imágenes adquiridas en diferentes momentos o incluso con distintos sensores. Una RC adecuada es vital para obtener cubos hiperespectrales confiables que puedan ser utilizados en etapas posteriores de análisis (Tejasree & Agilandeewari, 2024).

Para llevar a cabo la calibración existen varios métodos, como el uso de paneles de referencia con reflectancia conocida en el campo o la calibración en laboratorio. A pesar de su importancia, el proceso enfrenta desafíos como el ruido radiométrico, especialmente en sistemas aéreos no tripulados (UAS) donde las condiciones de luz varían, y la posible pérdida de calibración del sensor por su transporte e instalación. También es crucial corregir el ruido inherente del sensor, como la "corriente oscura". Para facilitar esta tarea, muchos fabricantes de sensores hiperespectrales proporcionan herramientas de software especializadas que ayudan a realizar estas correcciones y a georreferenciar los datos (Adão et al., 2017).

- **Corrección Atmosférica (AC):** La Corrección Atmosférica es un proceso esencial que elimina los efectos atmosféricos sobre las firmas espectrales de los materiales en una imagen. Los gases y partículas presentes en la atmósfera pueden distorsionar estas firmas espectrales a través de la

absorción y dispersión de la luz. Esta corrección asegura que los investigadores puedan identificar y clasificar materiales con precisión en la imagen, sin impedimentos.

Algunas técnicas de implementación común son:

- **Modelo de Transferencia Radiativa (RTM):** Es un método comúnmente utilizado que consiste en un modelo computacional que replica la trayectoria de la luz a través de la atmósfera. El modelo estima la cantidad de luz absorbida y dispersada por la atmósfera, lo que permite a los investigadores eliminar estos efectos de la imagen (Tejasree & Agilandeewari, 2024). Por ejemplo, el modelo SMARTS (Simple Model Of The Atmospheric Radiative Transfer Of Sunshine) ha sido utilizado para la corrección atmosférica, simulando la irradiancia total entrante en intervalos de 1 nm (Adão et al., 2017).
- **Espectro de Referencia:** Otra técnica implica el uso de un espectro de referencia. Un espectro de referencia es la firma espectral de un material conocido, como un panel de referencia blanco. Los investigadores comparan la firma espectral de un píxel en la imagen con el espectro de referencia para estimar la cantidad de luz absorbida y dispersada por la atmósfera y así eliminar estos efectos de la imagen (Tejasree & Agilandeewari, 2024).
- **Corrección Geométrica (GC):** Busca rectificar las distorsiones geométricas en la imagen. Su objetivo principal es asegurar que la imagen hiperespectral se alinee con precisión con otros datos geoespaciales, como imágenes satelitales y mapas. Este proceso es crucial porque las distorsiones pueden surgir de diversos factores, incluyendo la plataforma del sensor, la curvatura y rotación de la Tierra, y la refracción atmosférica (Tejasree & Agilandeewari, 2024). Para lograr estas correcciones, (Adão et al., 2017) menciona algunos puntos clave:
 - **Calibración de Hardware:** Antes de adquirir datos hiperespectrales, es necesario calibrar todo el hardware, incluyendo la unidad de medida inercial (IMU) y el sensor de imagen. La calibración de la IMU, por ejemplo, debe realizarse con respecto al campo magnético local de la Tierra, ya que, de lo contrario, la orientación del UAV podría verse comprometida.
 - **Puntos de Control en Tierra (GCPs):** El uso de GCPs es absolutamente necesario para mejorar la georreferenciación. Como se demostró en (Dong et al., 2021) se necesita control terrestre para mejorar la precisión altimétrica, ya que se notaron menos discrepancias para los GCPs colocados en el borde de la imagen en lugar de en sus esquinas. Los resultados preliminares mostraron una discrepancia de alrededor de 40 cm en la coordenada Z, lo cual es suficiente para aplicaciones forestales pero podría no serlo para otras.
 - **Sistemas de Georreferenciación Directa:** A pesar de la importancia de los GCPs, los avances recientes en las tecnologías de georreferenciación directa y de imágenes, como la integración de sistemas globales de navegación por satélite (GNSS) y sistemas de navegación inercial (INS), han permitido una cartografía precisa con un número mínimo de GCPs.
 - **Desafíos en UAVs:** La baja calidad de la georreferenciación en UAVs, especialmente en espectrómetros de barrido de línea (pushbroom), ha sido señalada por su impacto

negativo. De hecho, los sensores GPS de grado de navegación no facilitan el escaneo hiperspectral de tipo pushbroom en un UAV.

- **Efectos Angulares:** (Adão et al., 2017) demostró en su estudio que el uso de un sistema de goniómetro basado en UAV para caracterizar la dependencia angular de las mediciones hiperspectrales sobre el trigo podría ser un paso útil hacia el desarrollo de técnicas de corrección para atenuar los efectos de las reflexiones angulares en los espectros.
- **Corrección Espectral:** La Corrección Espectral es un proceso esencial cuyo propósito fundamental es eliminar las distorsiones y variaciones en las firmas espectrales de los materiales capturadas en una imagen hiperspectral. En esencia, busca asegurar que los valores espectrales registrados para cada píxel representen con la mayor precisión posible la reflectancia o emisividad real de la superficie terrestre, libre de influencias externas no deseadas.

Componentes y Métodos Clave de la Corrección Espectral:

1. **Calibración Radiométrica (CR):** Aunque a menudo se considera un paso separado, la calibración radiométrica es un pilar fundamental de la corrección espectral. Al normalizar los valores de los píxeles, la CR asegura que las firmas espectrales de los materiales sean precisas y consistentes, transformando los valores digitales brutos del sensor en unidades de radiancia o reflectancia, lo cual es esencial para el análisis cuantitativo.
 2. **Corrección Atmosférica (CA):** Es un proceso vital que elimina los efectos de la atmósfera —principalmente la absorción y dispersión de la luz por gases y partículas— sobre las firmas espectrales (Previamente explicado).
 3. **Matriz de Corrección Espectral (SCM) y Normalización de Datos:** En algunos casos, se utiliza una matriz de corrección espectral (SCM), donde cada banda individual es un conjunto de constantes de corrección espectral de bandas virtuales. Esto implica un ajuste directo o una normalización de los valores espectrales. Además, la normalización de datos reduce los niveles de brillo causados por la iluminación, manteniendo el valor RMS (Root Mean Square) de las firmas espectrales, lo que asegura que los valores espectrales sean consistentes independientemente de las variaciones de iluminación (Tejasree & Agilandeeswari, 2024).
 4. **Calibración Espectral del Sensor:** Este paso garantiza que el sensor esté capturando las longitudes de onda correctas para cada banda. En ocasiones, si el fabricante ya proporciona las longitudes de onda centrales y el ancho a media altura (FWHM) de las bandas, la calibración espectral específica podría no ser necesaria (Adão et al., 2017).
- **Reducción de Ruido y Mejora de la Señal (Restauración):** La Reducción de Ruido y Mejora de la Señal (Restauración) es un conjunto de procesos críticos cuyo objetivo fundamental **es mitigar o eliminar el ruido inherente y las distorsiones que se introducen en las imágenes hiperspectrales durante su adquisición y transmisión, y simultáneamente potenciar la información espectral y espacial útil** (Adão et al., 2017). Estas imperfecciones pueden degradar significativamente la calidad de la imagen, difuminar detalles importantes y causar distorsiones, afectando la precisión de la información cuantitativa que se puede extraer.

La necesidad de este proceso radica en las múltiples fuentes de ruido y los desafíos inherentes a la adquisición de datos hiperspectrales:

- **Ruido del sensor y de la plataforma:** Los sensores, independientemente de su sofisticación, introducen ruido. Fenómenos como la corriente oscura (dark current), dependiente de la temperatura, pueden generar "píxeles defectuosos" (blemish pixels) que contaminan las lecturas del sensor (Adão et al., 2017). La baja calidad de la georreferenciación en plataformas como los UAV, especialmente en espectrómetros de barrido lineal (pushbroom), también impacta negativamente.
- **Interferencias ambientales y atmosféricas:** Aunque las plataformas UAV vuelan más cerca de la superficie terrestre, reduciendo la influencia atmosférica en comparación con los satélites, las condiciones de iluminación variables y la influencia del micro-relieve en la iluminación pueden dificultar el preprocesamiento y causar diferencias radiométricas significativas entre imágenes. La atmósfera también puede introducir ruido atmosférico, especialmente en imágenes satelitales (Adão et al., 2017).
- **Características inherentes a los datos hiperespectrales:** Las HSI a menudo contienen cientos o miles de bandas espectrales, algunas de las cuales pueden ser redundantes o ruidosas. Una baja relación señal-ruido (SNR) debe ser eliminada por su efecto negativo en los datos, ya que una evaluación precisa de la SNR es crucial para el análisis cuantitativo (Richter et al., 2011a).

4.3.2. Técnicas de ML y DL aplicadas en el sector agrícola

Como se ha mencionado anteriormente, uno de los desafíos relevantes en el uso de HSI es la alta dimensionalidad dada tanto por el escaneo de la zona del cultivo, así como por la adquisición casi continua de bandas espectrales, siendo esta última la de mayor impacto, aumentando así la complejidad computacional y poniendo de manifiesto el llamado "fenómeno de Hughes" (Hughes, 1968). Esta alta dimensionalidad hace que poseamos un número limitado de etiquetas dado el alto costo en términos de tiempo e incluso económicos, por lo cual, el uso de técnicas de ML y más recientemente de DL, incluso en etapas iniciales del procesamiento ha tomado fuerza. Algunas de los algoritmos de aprendizaje automático que se han empleado son:

- **Análisis de Componentes Principales (PCA):** Transforma las bandas de imágenes correlacionadas en un conjunto de variables linealmente no correlacionadas para extraer información de las bandas informativas (S. Li et al., 2019; Licciardi et al., 2012; Prasad & Bruce, 2008).
- **Análisis de Componentes Independientes (ICA):** Segrega eficientemente los datos en componentes independientes, utilizado para extraer características esenciales ocultas en los datos hiperespectrales (S. Li et al., 2019; Villa et al., 2011).
- **Análisis Discriminante Lineal (LDA):** Una técnica de extracción de características que identifica combinaciones lineales de características que maximizan la separación entre diferentes clases (Bandos et al., 2009a; S. Li et al., 2019).
- **t-distributed Stochastic Neighbor Embedding (t-SNE):** Reduce los datos de alta dimensión a un espacio de baja dimensión manteniendo la estructura de similitud de los datos (K. Gao et al., 2020; Tejasree & Agilandeewari, 2024).
- **Kernel PCA:** Una extensión de PCA que utiliza una función kernel para mapear los datos de entrada a un espacio de mayor dimensión, facilitando la distinción entre diferentes tipos de datos (Liao et al., 2010; Tejasree & Agilandeewari, 2024).

Ahora bien, los algoritmos de aprendizaje automático también han sido ampliamente empleados para la clasificación en diferentes problemas de toda índole, yendo desde campos como la salud y la agricultura hasta uso en sectores financieros o deportivos (Adão et al., 2017). Estos métodos se suelen subdividir en métodos de clasificación supervisada, es decir que requieren etiquetas con las clases a identificar durante el entrenamiento del algoritmo, y clasificación no supervisada que buscan agrupar la información al encontrar patrones en su interior.

Dentro de los métodos de clasificación supervisada podemos encontrar los siguientes:

- **Máquinas de Soporte Vectorial (SVM):** Ampliamente utilizadas por su capacidad para manejar datos de alta dimensión y relaciones no lineales, identificando un hiperplano óptimo para separar las clases. Pueden emplear diversas funciones kernel como la función de base radial gaussiana (RBF), polinomial o basadas en SAM (Spectral Angle Mapper).
- **Bosques Aleatorios (Random Forest - RF):** Un método de conjunto que combina múltiples árboles de decisión para mejorar la precisión y solidez de la clasificación.
- **k-Vecinos Más Cercanos (k-NN):** Clasifica un punto de datos en función de las clases de sus k vecinos más cercanos en el espacio de características.
- **Árboles de Decisión (Decision Trees - DT):** Construyen un modelo de clasificación con una estructura similar a un árbol, dividiendo los datos en subconjuntos basados en valores de atributos.
- **Máquinas de Aprendizaje Extremo (Extreme Learning Machine - ELM):** Conocidas por su rápido entrenamiento y buen rendimiento en la clasificación.
- **Clasificación de Máxima Verosimilitud (Maximum Likelihood Classification - MLC):** Asigna un píxel a la clase con la mayor probabilidad de pertenencia, asumiendo una distribución normal para los datos de entrenamiento.

En el caso de la clasificación no supervisada, (Tejasree & Agilandeeswari, 2024) describe, entre otros, los siguientes algoritmos:

- **k-means:** Un algoritmo de agrupación popular que divide los datos en k clústeres basándose en distintas métricas de similitud para agrupar la información.
- **Mapas Auto-Organizativos (Self-Organizing Maps - SOM):** Redes neuronales artificiales que mapean datos de alta dimensión a un espacio de menor dimensión, preservando la distribución de los datos de entrada.
- **ISODATA:** Un algoritmo de clustering que permite un número variable de clústeres y es una extensión de k-means.
- **Autoencoders (AE):** Aunque son modelos de DL, las versiones tempranas de Autoencoders Apilados (SAE) se usaron de manera no supervisada para la extracción de características y reducción de dimensionalidad, actuando como pre-procesamiento para clasificadores tradicionales (Zhao et al., 2025).

Una variación muy interesante de estos 2 mundos es el uso de métodos semisupervisados que abordan el problema de escasez de datos etiquetados, empleando una pequeña cantidad de datos y un gran conjunto

de datos sin etiquetas, para encontrar y generalizar patrones (Cui et al., 2019; Wu & Prasad, 2018). Algunos métodos de este tipo son:

- **Transductive SVM (TSVM):** Extiende la SVM en algoritmos que buscan de forma iterativa un hiperplano de separación óptimo en el espacio de características, incorporando muestras no etiquetadas durante la fase de entrenamiento. (Adão et al., 2017)
- **Laplacian SVM (LapSVM):** También es una extensión de las SVM que introducen un término de regularización adicional basado en el Laplaciano de un grafo, empleando tanto datos etiquetados como sin etiqueta. (Wu & Prasad, 2018)

Al respecto, también se han empleado métodos basados en grafos para el desarrollo de modelos semisupervisados (Zhao et al., 2025) puesto que abordan problemas como la dimensionalidad y la clasificación; estos emplean los nodos para representar muestras de datos y las aristas para representar similitudes, propagando información de etiquetas a través del grafo para clasificar muestras no etiquetadas.

A pesar de su alto potencial, los métodos tradicionales de ML en algunas ocasiones pueden ser pobres para abordar las problemáticas de la dimensionalidad, por lo cual, cada vez ha venido en aumento la implementación de metodologías de Deep learning (DL) ya que han demostrado ser particularmente potentes para abordar información de carácter no lineal como la obtenida de las firmas espectrales a través de las HSI. Dentro del mundo del Deep Learning podemos encontrar los siguientes enfoques para el procesamiento de imágenes hiperespectrales:

1. **Redes Neuronales Convolucionales (CNNs):** Las CNNs son un pilar fundamental en el procesamiento de imágenes debido a su capacidad para extraer características locales mediante operaciones de convolución (Tejasree & Agilandeeswari, 2024). Son más adecuadas para el procesamiento y la extracción de características de HSI en comparación con modelos DL anteriores que requerían la transformación de HSI a vectores (Stacked AutoEncoder (SAE), recurrent neural network (RNN), and deep belief networks (DBN)) (K. Gao et al., 2020).
 - **CNNs 1D:** Se utilizan para extraer características espectrales directamente de los vectores de píxeles, operando principalmente en el dominio espectral, sin embargo, inicialmente, ignoraban el contexto espacial.
 - **CNNs 2D:** A menudo combinadas con técnicas de reducción de dimensionalidad como PCA, se aplican para explotar la información espacial en la región vecina de un píxel, ya que la convolución 2D opera en el dominio espacial (S. Li et al., 2019). Modelos como AlexNet y GoogLeNet han sido adaptados para extraer características espaciales profundas.
 - **CNNs 3D:** Son especialmente adecuadas para las HSI, ya que pueden procesar el cubo de datos tridimensional (espacial y espectral) directamente, extrayendo características espectro-espaciales de manera conjunta y haciendo pleno uso de la información espacial y espectral (K. Gao et al., 2020).

Algunas de las variaciones y mejoras mencionadas por (Zhao et al., 2025), que han tenido las CNN en los últimos años incluyen:

- **Redes con Aprendizaje Residual (ResNets):** Incorporan aprendizaje residual para construir redes más profundas y amplias, permitiendo la extracción de características más discriminativas y abordando problemas como el desvanecimiento del gradiente

- **Redes Densely Connected (DenseNets):** Mejoran el flujo de información y la reutilización de características en redes profundas
 - **Redes Neuronales Convolucionales Totalmente Conectadas (FCN):** Originalmente utilizadas en segmentación semántica, se han aplicado para reconstruir datos hiperespectrales y aprender características profundas de manera supervisada o no supervisada (S. Li et al., 2019).
 - **CNNs con Atención (Attention-aided CNNs):** Integran mecanismos de atención para que la red se enfoque en las bandas espectrales más relevantes y suprima la información irrelevante, mejorando el rendimiento y reduciendo la complejidad computacional (K. Gao et al., 2020).
- 2. Redes Neuronales Recurrentes (RNNs):** Las RNNs son efectivas para manejar datos secuenciales, lo que las hace adecuadas para las HSI si se consideran los píxeles hiperespectrales como secuencias espectrales (S. Li et al., 2019; Tejasree & Agilandeewari, 2024).
- **Long Short-Term Memory (LSTM) y Gated Recurrent Units (GRU):** Estas son arquitecturas de RNN más sofisticadas que abordan el problema del desvanecimiento del gradiente en secuencias largas, lo que les permite capturar dependencias a largo plazo en los datos espectrales.
 - **Redes Neuronales Recurrentes Convolucionales (CRNNs):** Combinan capas convolucionales y recurrentes. Las capas convolucionales extraen características locales invariantes de la secuencia hiperespectral de entrada, y las capas recurrentes extraen información contextual de estas características (Wu & Prasad, 2018).
- 3. Autoencoders (AEs) y Redes de Creencia Profunda (DBNs):** Estos modelos fueron de los primeros en ser aplicados para la extracción de características y la reducción de dimensionalidad en HSI (K. Gao et al., 2020).

En el caso de los autoencoders, algunas variaciones que se encuentran en la literatura son:

- **Autoencoders (AEs):** Redes simétricas no supervisadas que aprenden a reconstruir sus datos de entrada a partir de una representación comprimida, lo que ayuda a reducir el ruido y a aprender características (Zhao et al., 2025).
- **Stacked Autoencoders (SAEs):** Apilan múltiples AEs para aprender representaciones jerárquicas profundas (S. Li et al., 2019).
- **Stacked Denoising Autoencoder (SDA):** Una variante que aprende representaciones robustas a partir de entradas corruptas, útil para la pre-entrenamiento en entornos semi-supervisados (Wu & Prasad, 2018).

Respecto a las Redes de Creencia Profunda (DBNs), estas son compuestas por múltiples capas de Máquinas de Boltzmann Restringidas (RBMs) y buscar aprender una representación jerárquica profunda de los datos de entrenamiento; además, pueden usarse como clasificadores al añadir una capa de regresión logística al final de la red (S. Li et al., 2019). Se han propuesto modelos mejorados para regularizar los procedimientos de pre-entrenamiento y ajuste fino (Zhong et al., 2017).

- 4. Redes Generativas Antagónicas (GANs):** Las GANs consisten en una red generadora y una discriminadora que compiten entre sí, la red discriminadora aprende a distinguir entre muestras reales y generadas, mientras la red generadora intenta crear muestras que engañen al discriminador, mejorando la capacidad de generalización (S. Li et al., 2019). Han sido utilizadas para aumentar datos (K. Gao et al., 2020), generar muestras sintéticas y para la clasificación.

5. **Modelos de Transformadores (Transformers):** Recientemente, los modelos de transformadores, originalmente desarrollados para procesamiento de lenguaje natural (Vaswani et al., 2017), han demostrado un gran potencial en la visión por computadora y en HSI, aprovechando sus mecanismos de autoatención para capturar características globales, por ejemplo, el Vision Transformer (ViT) (Dosovitskiy et al., 2020; Tejasree & Agilandeewari, 2024) adapta la arquitectura del transformador para tareas de visión, incluyendo la clasificación de HSI, al tratar las imágenes como secuencias de "parches".
6. **Redes Neuronales Gráficas (GNNs):** Las GNNs han surgido como una solución prometedora para HSI, ya que pueden manejar la información espectral y espacial de manera conjunta, especialmente en estructuras de datos no euclidianas. Han mostrado una capacidad superior para capturar relaciones complejas y requieren menos muestras etiquetadas en comparación con otros métodos de DL. En el trabajo de (Zhao et al., 2025) se detallan las siguientes variantes:
- **Redes Neuronales Recurrentes Gráficas (GRNNs):** Extienden las RNNs a estructuras de grafos, utilizando mecanismos de paso de mensajes para actualizar las representaciones de los nodos. Incluyen variantes como Graph LSTM y Graph GRU. Son eficaces para capturar información secuencial y contextual, y pueden ayudar a reducir la dimensionalidad de los datos.
 - **Redes Convolucionales Gráficas (GCNs):** Aplicadas para extraer características y adaptarse a datos estructurados en grafos. Capturan tanto las características espectrales como las relaciones espaciales mediante operaciones de convolución en el grafo. Dentro de ellas encontramos:
 - GCNs basados en el dominio espectral
 - GCNs basados en el dominio espacial
 - **Graph Attention Networks (GATs):** Introducen mecanismos de atención para ponderar la información de los vecinos, permitiendo a la red aprender la importancia de cada conexión.
 - **GraphSAGE:** Un método inductivo que muestrea y agrega características de vecindarios locales de nodos, reduciendo la complejidad espacial.
 - **Autoencoders Gráficos (GAEs):** Aprovechan estrategias de auto-supervisión para extraer características valiosas de grandes volúmenes de datos no etiquetados, abordando la escasez de muestras etiquetadas. Modelos como el Variational Graph Autoencoder (VGAE) son ejemplos.
 - **Redes Neuronales Gráficas Híbridas:** Combinan GNNs con otros modelos de Deep Learning (como CNNs o Transformers) para aprovechar sus fortalezas complementarias y capturar diversas características espectrales y espaciales
7. **Meta-Learning y Few-Shot Learning:** Estas estrategias abordan directamente el problema de la escasez de datos etiquetados en HSI, permitiendo que los modelos aprendan a clasificar nuevas clases con muy pocas muestras de entrenamiento. (K. Gao et al., 2020) aborda ampliamente estos conceptos. Aquí se presentan algunos apartados:
- **Redes de Relación (Relation Networks - RN-FSC):** Un modelo basado en meta-aprendizaje que compara la similitud entre muestras para clasificar nuevas HSI con solo unas pocas muestras etiquetadas. Incluyen módulos de aprendizaje de características (a menudo 3D CNN) y módulos de aprendizaje de relación.
 - **Aprendizaje Semi-supervisado con Pseudo-etiquetas (PL-SSDL):** Utiliza datos no etiquetados con "pseudo-etiquetas" (generadas por algoritmos de clustering, como el modelo de

mezcla de procesos de Dirichlet - DPMM) para pre-entrenar redes neuronales profundas (como CRNNs), y luego se ajustan con una cantidad limitada de datos etiquetados reales. Esto ayuda a la inicialización y reduce el sobreajuste (Wu & Prasad, 2018)

- *Aprendizaje por Transferencia (Transfer Learning)*: Se utiliza información aprendida de conjuntos de datos fuente más grandes (a menudo de visión por computadora general o de HSI relacionadas) para inicializar o pre-entrenar modelos para tareas específicas de HSI con datos etiquetados limitados (S. Li et al., 2019).

4.4. Antecedentes

Como se mencionó en la sección **4.1 Agricultura de precisión**, los trabajos que versan sobre la aplicación de imágenes hiperespectrales en conjunto con implementaciones de Machine Learning y Deep Learning, han venido creciendo exponencialmente en los últimos años (Saini et al., 2025) como resultado de la introducción de nuevas tecnologías, metodologías y arquitecturas, así como del potencial que han mostrado los estudios para impulsar campos como la agricultura, la salud, la minería, entre otros.

La historia reciente de la clasificación HSI comenzó con la consolidación de técnicas de machine learning robustas. En 2005, la investigación sobre el marco de Random Forest desarrollada por (Ham et al., 2005) demostró la eficacia de los clasificadores de conjunto para manejar la alta dimensionalidad de los datos hiperespectrales (Bandos et al., 2009b; Zhao et al., 2025; Zhong et al., 2017). Paralelamente, en (Zhao et al., 2025), también se destacan los estudios tempranos de (Gori et al., 2005) y (Scarselli et al., 2008) sobre modelos de aprendizaje en dominios de grafos sentando una base teórica para las Redes Neuronales de Grafos (GNNs) que, aunque muy reciente y poco profundizada para ese tiempo, resultaría como una dirección prometedora más de una década después.

Durante este período, las aplicaciones eran diversas; un ejemplo notable de 2007 fue el uso de algoritmos de mapeo de ángulo espectral para clasificar contaminantes en aves de corral (Park et al., 2007; Yan et al., 2010), demostrando el potencial de la tecnología para la detección de anomalías biológicas. Hacia 2010, el campo reconoció una necesidad crítica: la integración de información espacial-espectral, como investigaron (Yan et al., 2010), para mejorar la precisión de la clasificación, un concepto que se convertiría en un pilar para los desarrollos futuros.

La segunda década del siglo XXI fue testigo de la llegada del deep learning como fuerza dominante. Si bien el desarrollo de infraestructuras clave como el programa alemán EnMAP, fundamental en el estudio de (Richter et al., 2011b), prometía una nueva generación de datos hiperespectrales de alta calidad; y enfoques más de carácter militar como el tratado en (Ma et al. 2012) llamado “Characterization of hyperspectral reconnaissance technology and analysis of its threat to military targets on the ground” citado por (Zhao et al., 2025) tuvieron parte en la evolución del HSI y su integración con ML y DL, fueron los avances algorítmicos los que cambiaron el paradigma. La introducción de las Generative Adversarial Nets (GANs) por (Goodfellow et al., 2014) abrió nuevas vías para el aumento de datos y el aprendizaje no supervisado. Otros trabajos como los realizados por (Y. Li et al., 2015) donde se abordaron los problemas de convergencia de las GNNs integrando Unidades Recurrentes de Compuerta (GRU) en el proceso de paso de mensajes, y los desarrollos de (Hong et al., 2015) para el reconocimiento de las huellas de palma empleando enfoques jerárquicos basados en imágenes multispectrales, seguían solidificando la teoría y la aplicación práctica a diferentes campos de estudio; así mismo, aplicaciones como las realizadas por (Sun et al., 2015) demostraron el potencial al combinar las HSI con técnicas como PCA para el manejo de la alta dimensionalidad, y con ello lograr altas tasas en procesos de clasificación de fríjol negro.

Poco después, el campo de la HSI comenzó a adoptar directamente arquitecturas de redes neuronales profundas. En 2017, un año clave como lo mencionan (S. Li et al., 2019; Zhao et al., 2025), (Mou et al.,

2017), aplicaron Redes Neuronales Recurrentes Profundas (RNNs), mientras que (Zhong et al., 2017) utilizó Redes Neuronales de Creencia Profunda (DBN) para la clasificación; y (Hamilton et al., 2017) propusieron un marco de red semi-supervisado inductivo, denominado GrpahSAGE, que lo diferencia de las GCNs espectrales, ya que opera en el dominio espacial, agregando información directamente de los nodos vecinos. Sin embargo, el avance más disruptivo de ese año en todos los campos de la inteligencia artificial fue la publicación del paper "Attention Is All You Need" (Vaswani et al., 2017), que introdujo la arquitectura Transformer. Aunque su impacto inicial fue en el procesamiento del lenguaje natural, su mecanismo de atención sentaría las bases para futuras innovaciones en la visión por computadora y la HSI.

A partir de este punto, como se mencionó anteriormente y se evidencia en la figura 2, el interés por las aplicaciones y el desarrollo de HSI creció exponencialmente (Saini et al., 2025). La sinergia entre la teoría de grafos y el deep learning se materializó en una explosión de investigación sobre las Redes Neuronales de Grafos (GNNs) y, en particular, las Redes Convolucionales de Grafos (GCNs). (Shahraki & Prasad, 2018) aplicaron GCNs directamente a la clasificación de datos hiperespectrales en 2018, similarmente (H. Wang et al., 2018) trabajaron en un enfoque que combinada el aprendizaje de representación de grafos con las Redes Generativas Adversarias (GANs). A su vez, las aplicaciones en el campo de la agricultura se comenzó a desarrollar con más índole, por ejemplo, en Brasil (Martínez-Martínez et al., 2018) utilizaron un sistema basado en ANN y Análisis de Componentes Principales (PCA) para estimar la severidad de la enfermedad de la Mancha Angular de la Hoja (ALS, por sus siglas en inglés) en cultivos de frijól común (*Phaseolus vulgaris*) logrando R² de hasta 0.87, así mismo, (Phuangsombut et al., 2018) desarrollaron un estudio que se centró en el frijól mungo, utilizando HSI en el infrarrojo cercano (NIR-HSI) junto con PLS-DA para separar los granos duros y no germinativos de los normales, logrando un coeficiente de correlación (R) de 0.919. Este trabajo destacó una conclusión a tener en cuenta: la orientación física del grano en el momento de la medición afectaba los resultados de la clasificación, una lección importante para el diseño de sistemas de inspección automatizados.

Las anteriores aplicaciones y teorías desarrolladas demostraron un hecho importante para el avance del uso de las HSI en los diferentes campos, en particular en la agricultura, poniendo de manifiesto la necesidad de combinar las características espaciales y espectrales ya que superaban significativamente a cualquiera de las dos por separado. Así pues, a partir del año 2020 se comenzaron a explorar aplicaciones que abordaran ambas características, por ejemplo, se introdujo GraphSAGE en el campo de la clasificación HSI de manera aplicada por parte de (P. Yang et al., 2020), utilizando la distancia espectral-espacial para construir la adyacencia de los grafos. Modelos como las redes de atención de grafos (Sha et al., 2020) y las redes convolucionales de grafos no locales (Mou et al., 2020) demostraron la flexibilidad y potencia de tratar los píxeles de una imagen y sus relaciones espectrales como un grafo. A su vez, estas consideraciones de dependencia espectro-espacial llevaron a evolucionar los conceptos de las 1D CNNs, pasando por la 2D CNNs, hasta llegar a las 3D CNNs como es relatado por (Bera et al., 2022).

Es en este contexto de madurez tecnológica que los avances comenzaron a tener un impacto tangible y documentado en la agricultura de precisión, especialmente en Latinoamérica. Un hito clave ocurrió en 2021, cuando (Marin et al., 2021) utilizaron imágenes de drones (UAV) y modelos de machine learning para la detección de la roya de la hoja del café. Este trabajo marcó una de las primeras aplicaciones directas de estas técnicas a un problema crítico para la economía agrícola de la región.

El año 2023 consolidó esta tendencia de manera definitiva. Mientras los modelos teóricos a nivel global continuaban refinándose con arquitecturas que fusionaban GCNs y Transformers (GTFN) (A. Yang et al., 2023), o proponían nuevos enfoques como Mamba (Gu & Dao, 2023), una serie de estudios en Latinoamérica se enfocaron en la caficultura: (Motta et al., 2025) describen a profundidad la serie de estudios que se dieron alrededor del cultivo de café, por ejemplo, (Nogueira Martins et al., 2023) aplicaron imágenes multiespectrales de UAV para el mapeo digital de la madurez del café. En Perú, (Tuesta-Monteza

et al., 2023) crearon Coleaf-DB, un conjunto de datos público de imágenes de hojas de café, un recurso fundamental para entrenar y validar nuevos modelos de detección de deficiencias nutricionales. Simultáneamente, la investigación de (Suarez et al., 2023) se centraron específicamente en los métodos de detección de la roya en cultivos de café, un problema de enorme relevancia para Colombia y países vecinos.

Recientemente, la investigación teórica continuó con lo ya mencionado en 2023, avanzando cada vez hacia modelos más sofisticados como las redes convolucionales de grafos difusas (Fuzzy GCN) (J. Liu et al., 2024; J. Xu et al., 2024) y duales (Dual GCN) (J. Liu et al., 2024); aplicaciones pensadas para arquitecturas tipo transformers (Scheibenreif et al., 2023; H. Wang & Wang, 2025; Y. Xu et al., 2024)

5. METODOLOGÍA

5.1. Recolección de información

La base de datos para este proyecto se fundamenta en la campaña de adquisición documentada en el **Anexo 41. Reporte técnico - imágenes multiespectrales**. Se prestará especial atención al conjunto de datos directamente relevante para el objetivo de este estudio: el experimento de estrés nutricional en frijol. La documentación precisa de este protocolo garantiza la trazabilidad y reproducibilidad de la investigación.

- **Dataset:** El conjunto de datos seleccionado es el correspondiente al experimento **Frijol C.I. La Selva 2022 - Estrés nutricional – Deficiencia de Fósforo**.
- **Fecha de Adquisición:** La campaña de recolección de datos se llevó a cabo entre el 3 y el 23 de noviembre de 2023.
- **Instrumentación:** Se empleó una cámara multiespectral **Mjolnir** (Como referencia, se puede consultar: (NEO, 2025)).
- **Plataforma de Adquisición:** La cámara fue montada en un Dron (UAV). Esta plataforma aérea permite una adquisición de datos flexible y a gran escala, capturando la variabilidad espacial del cultivo en una sola pasada. A diferencia de las mediciones terrestres, esta aproximación es ideal para obtener una visión sinóptica del estado del cultivo, aunque puede requerir correcciones geométricas y atmosféricas más rigurosas (Wu & Prasad, 2018).
- **Diseño Experimental:** El protocolo consistió en la captura de una única imagen que cubre la totalidad del experimento.




Figura 4. Mosaico construido desde las imágenes hiperespectrales capturadas el 23 noviembre 2021 sobre el experimento de frijol.

Adicionalmente, se podrán emplear los siguientes conjuntos de datos como información complementaria, especialmente para el entrenamiento y la validación de modelos a nivel de planta individual y hoja:

- **Dataset Complementario 1 (Proximal - Estrés Nutricional):** Corresponde al mismo experimento de estrés nutricional, pero adquirido el **3 de noviembre de 2021** con una cámara **Mica Sense** (imagen multiespectral) sobre un **trípode**. En este caso, se organizaron hojas en una matriz de 4x8, permitiendo una caracterización espectral controlada y detallada de diferentes genotipos.

5.1.1. Preprocesamiento Espectral y Corrección Radiométrica

Como se mencionó en la sección 4.3.1 *Procesamiento de imágenes hiperespectrales*, los datos brutos obtenidos del sensor, expresados en números digitales (DN), no son directamente utilizables para el análisis cuantitativo. Están afectados por el ruido del sensor, las condiciones de iluminación variables, los efectos atmosféricos (aunque mínimos en la adquisición con trípode) y los fenómenos de dispersión de la luz en la superficie de la hoja.

Por tal motivo, la imagen capturada durante el experimento ha sido sujeta a procesos de corrección radiométrica, geométrica y atmosférica. Los datos con que se cuentan están estandarizados a reflectancia.

5.2. Estrategias para el etiquetado de la imagen

Uno de los desafíos más significativos en la aplicación del aprendizaje profundo a la teledetección es la escasez de datos de entrenamiento etiquetados. Este proyecto cuenta con la identificación de plantas control de las cuales se conoce su estado nutricional de fósforo; así pues, una parte importante previa a la aplicación de metodologías de ML y DL es realizar el etiquetado de las demás plantas para realizar los procesos de entrenamiento de modelos.

Dada la alta dimensionalidad de la información se explorarán algunas estrategias de procesos semi-supervisados para el desarrollo de las etiquetas a fin de evaluar la viabilidad y agilidad de los métodos de ML sobre el etiquetado manual. Como alternatis del marco de trabajo en esta etapa se tienen 2 propuestas:

La primera ha sido desarrollada en (Wu & Prasad, 2018) y consiste, grosso modo, en los siguientes pasos:

- **Paso 1: Agrupamiento No Supervisado (Unsupervised Clustering):** Se tratarán todos los datos disponibles (el pequeño conjunto etiquetado y el gran conjunto no etiquetado) como un único acervo de datos. Se aplicará un algoritmo de agrupamiento bayesiano no paramétrico, específicamente el Modelo de Mezcla de Procesos de Dirichlet (DPMM). El DPMM posee la ventaja crucial de inferir automáticamente el número de clústeres a partir de los datos, lo cual es ideal para descubrir un número desconocido de niveles de severidad de la enfermedad o incluso otros tipos de estrés no anticipados presentes en el campo.
- **Paso 2: Generación de Pseudo-Etiquetas:** La identidad del clúster asignada por el DPMM a cada muestra se utilizará como su "pseudo-etiqueta". Este proceso resulta en la creación de un gran conjunto de datos completamente (pseudo)etiquetado.
- **Paso 3: Pre-entrenamiento del Modelo Profundo:** Se utilizará una red neuronal profunda (por ejemplo, una versión preliminar de la 3D-CNN) para ser pre-entrenada con este gran conjunto de datos y sus pseudo-etiquetas. El objetivo de esta fase no es lograr una clasificación perfecta, sino forzar a la red a aprender una representación de características rica y discriminativa que capture la estructura intrínseca de todo el conjunto de datos, tanto de las plantas sanas como de las enfermas.
- **Paso 4: Ajuste Fino (Fine-Tuning):** La red pre-entrenada, con sus capas de extracción de características ya optimizadas, se someterá a un ajuste fino. En esta etapa, las capas de extracción de características se "congelan" (sus pesos no se actualizan) o se entrenan con una tasa de aprendizaje muy baja. Solo las capas finales de clasificación se entrenan intensivamente utilizando únicamente el pequeño conjunto de datos de alta calidad y etiquetado manualmente. Este paso final adapta las potentes características aprendidas de forma no supervisada a las clases específicas y verificadas del problema.

Como segunda opción se tienen la propuesta realizada en (González Santiago et al., 2020) que consiste, grosso modo, en:

- **Paso 1: Segmentación de la imagen hiperespectral:** El proceso inicia con la segmentación de la imagen hiperespectral. Se utiliza una versión adaptada del algoritmo SLIC (Simple Linear Iterative Clustering) que, en lugar de medir la similitud por color, emplea el Mapeador de Ángulo Espectral (SAM) para agrupar los píxeles. El objetivo es dividir la imagen en múltiples regiones pequeñas y homogéneas llamadas "superpíxeles". Esta fase disuelve la estructura rígida de la imagen, elimina redundancias y reduce la complejidad

para las etapas siguientes. A cada superpíxel resultante se le asigna una firma espectral media, calculada a partir de los píxeles que lo componen.

- **Paso 2: Agrupamiento (Clustering) de superpíxeles para generar etiquetas:** Los superpíxeles generados en el paso anterior se agrupan utilizando dos técnicas de clustering de forma complementaria:
 - **Clustering Jerárquico Aglomerativo (HAC):** Inicialmente, se aplica el método HAC para agrupar los superpíxeles similares en una jerarquía de clústeres. Este método no requiere definir previamente el número de clústeres. Utilizando métricas de distancia como la euclidiana y funciones de enlace, se crea un árbol jerárquico o dendrograma, que luego se analiza para determinar la división óptima y generar los clústeres iniciales.
 - **Fuzzy C-Means (FCM):** Esta técnica se emplea para resolver el problema de solapamiento de clases, que ocurre cuando objetos de diferentes clases tienen características muy similares (por ejemplo, edificios y calles). El algoritmo FCM asigna a cada punto de datos un grado de pertenencia a diferentes clústeres, lo que permite manejar la incertidumbre y separar clases que en el espacio de características se encuentran muy próximas entre sí.

5.3. Segmentación de la Planta y Extracción de Regiones de Interés (ROI)

Para garantizar que el modelo de clasificación aprenda características relevantes para la salud de la planta y no variables de confusión como el tipo de suelo, la sombra o la hojarasca, es imperativo segmentar con precisión los píxeles de la planta del fondo. Esta etapa del flujo de trabajo crea una máscara binaria que aísla las regiones de interés (las plantas de frijol), asegurando que solo los píxeles de vegetación se utilicen para el análisis posterior y el entrenamiento del modelo.

Se explorarán 2 líneas para la segmentación, una empleando métodos tradicionales como la *umbralización basada en índices de vegetación* y el *agrupamiento no supervisado*; y la otra buscando la implementación de métodos más robustos y de vanguardia como la *segmentación semántica con redes neuronales (U-Net)* y la *segmentación basada en grafos*.

5.3.1 Umbralización basada en índices de vegetación (VI-based Thresholding)

Este es el enfoque más común y directo para separar la vegetación del suelo. Se calculará el Índice de Vegetación de Diferencia Normalizada (NDVI) para cada píxel del cubo hiperespectral. El NDVI aprovecha el hecho de que la vegetación sana refleja fuertemente la luz en el infrarrojo cercano (NIR) y absorbe la luz en el rojo (Red) (Lunetta et al., 2006). La fórmula es:

$$NDVI = \frac{(NIR - Red)}{(NIR + Red)}$$

Se creará una máscara binaria aplicando un umbral a la imagen NDVI resultante. Los píxeles con valores de NDVI por encima de un umbral determinado (por ejemplo, > 0.3) se clasificarán como vegetación, mientras que los que estén por debajo se clasificarán como fondo (suelo, sombra, etc.). El umbral óptimo se determinará empíricamente mediante inspección visual y análisis de histogramas.

5.3.2 Agrupamiento no supervisado (Clustering)

Se aplicará el algoritmo de agrupamiento **K-Means** directamente a los vectores espectrales de todos los píxeles de la imagen. Al establecer el número de clústeres en $k=2$, el algoritmo particionará los píxeles en dos grupos distintos. Se espera que estos dos clústeres correspondan a "planta" y "fondo". Para asignar las etiquetas correctas, se calculará el NDVI promedio de cada clúster; el clúster con el NDVI promedio más alto será etiquetado como "planta".

5.3.3 Segmentación Semántica con Redes Neuronales (U-Net):

Se implementará una arquitectura **U-Net**, un tipo de Red Neuronal Convolutiva (CNN) diseñada específicamente para tareas de segmentación de imágenes biomédicas y de satélite. La arquitectura de U-Net, con su estructura de codificador-decodificador y conexiones de salto (*skip connections*), le permite capturar tanto el contexto de alto nivel como los detalles espaciales de grano fino. Esto la hace extremadamente eficaz para producir máscaras de segmentación precisas que siguen fielmente los contornos de las plantas. Para entrenar el modelo U-Net, será necesario anotar manualmente un pequeño subconjunto de imágenes, creando máscaras a nivel de píxel que distingan entre planta y fondo.

5.3.4 Segmentación basada en grafos

Este enfoque representa un cambio de paradigma con respecto a los métodos basados en píxeles. Primero, la imagen se agrupa en regiones atómicas perceptualmente significativas llamadas **superpíxeles**, utilizando un algoritmo como **Entropy Rate Superpixel (ERS)** o **Simple Linear Iterative Clustering (SLIC)**. Este paso transforma la imagen de una rejilla rígida de píxeles a un grafo, donde cada nodo es un superpíxel y las aristas representan la adyacencia entre ellos. A continuación, se extraen características para cada superpíxel (por ejemplo, el espectro medio, la textura, la forma). Finalmente, un clasificador simple (como un SVM) puede ser utilizado para etiquetar cada superpíxel como "planta" o "fondo". Este método preserva los límites de los objetos de forma mucho más eficaz que los métodos basados en píxeles y reduce drásticamente la complejidad computacional para los pasos posteriores del análisis.

5.4. Desarrollo y entrenamiento de modelos de clasificación para la identificación del estado de sanidad de plantas de frijol

5.4.1. Extracción y selección de características para modelos tradicionales

Los modelos de aprendizaje automático (ML) tradicionales, como SVM y Random Forest, no pueden manejar directamente el cubo hiperespectral completo debido a su alta dimensionalidad. El fenómeno conocido como la "maldición de la dimensionalidad" dicta que el rendimiento del clasificador puede degradarse a medida que aumenta el número de características (bandas espectrales) si el número de muestras de entrenamiento no crece exponencialmente. Por lo tanto, un paso de extracción o selección de características es indispensable (Huang et al., 2018; Z. Zhang & Zhu, 2023).

- **Análisis de Componentes Principales (PCA):** Se aplicará el Análisis de Componentes Principales (PCA) a los datos hiperespectrales. PCA es una técnica de extracción de características no supervisada que transforma los datos originales, que están altamente correlacionados, en un nuevo conjunto de variables linealmente no correlacionadas llamadas componentes principales. Los primeros componentes principales, que capturan la mayor parte de la varianza en los datos, se utilizarán como un conjunto de

características compacto y denso en información para entrenar los modelos (Liao et al., 2010; Licciardi et al., 2012).

- **Selección de Características (Selección de Bandas):** A diferencia de PCA, que crea nuevas características artificiales, la selección de bandas identifica un subconjunto de las bandas espectrales originales más informativas. Esto preserva el significado físico de los datos, permitiendo una interpretación más directa de los resultados. Se evaluarán dos métodos (Y. Zhang et al., 2024):
 1. **Importancia de Características Basada en Random Forest (RF):** Se entrenará un modelo preliminar de Random Forest sobre todo el espectro. RF tiene la capacidad intrínseca de calcular la importancia de cada característica (banda) en la tarea de clasificación. Se utilizarán estas puntuaciones de importancia para clasificar las bandas y seleccionar el subconjunto más discriminativo.
 2. **Algoritmo de Proyecciones Sucesivas (SPA):** SPA es un método de selección de variables hacia adelante (forward selection) que tiene como objetivo seleccionar un subconjunto de bandas con una colinealidad mínima entre ellas. El resultado es un conjunto pequeño de bandas altamente informativas, lo que reduce la redundancia y mejora la eficiencia del modelo.

5.4.2. Aprendizaje automático (ML)

Estos modelos se entrenarán utilizando las características extraídas en la sección 5.4.1. Servirán como líneas de base robustas e interpretables, contra las cuales se podrá comparar el rendimiento del modelo de aprendizaje profundo (DL).

- **Modelo 1: Máquina de Vectores de Soporte (SVM):** Las SVM son algoritmos de clasificación potentes, especialmente eficaces en espacios de alta dimensionalidad y con un número limitado de muestras de entrenamiento. Son un punto de referencia estándar en la clasificación de imágenes hiperespectrales.

Se utilizará una SVM con un kernel de Función de Base Radial (RBF). El kernel RBF es particularmente adecuado para manejar las fronteras de clase complejas y no lineales que son típicas de los datos espectrales. La entrada al modelo será el vector de características (componentes principales o bandas seleccionadas) para cada píxel de la planta.

- **Modelo 2: Bosque Aleatorio (Random Forest - RF):** RF es un clasificador de conjunto (ensemble) que construye múltiples árboles de decisión y combina sus predicciones. Es robusto al sobreajuste, funciona bien con un gran número de características y no requiere un ajuste de hiperparámetros tan exhaustivo como otros modelos.
- **Modelo 3: Potenciación de Gradiente Extremo (XGBoost):** XGBoost (Extreme Gradient Boosting) es un algoritmo de conjunto avanzado basado en árboles de decisión que ha demostrado una eficacia y velocidad excepcionales en una amplia gama de tareas de clasificación. A menudo supera a otros algoritmos tradicionales como SVM y Random Forest en términos de precisión. Su implementación optimizada y su capacidad para manejar datos dispersos y reducir el sobreajuste lo convierten en un candidato ideal para la clasificación de datos hiperespectrales.

Se entrenará un clasificador XGBoost utilizando el mismo conjunto de características (componentes principales o bandas seleccionadas) que los modelos SVM y RF para una comparación directa. El modelo funciona construyendo secuencialmente árboles de decisión, donde cada nuevo árbol corrige los errores de los anteriores. Se realizará un ajuste de hiperparámetros (como la tasa de aprendizaje, la profundidad máxima del árbol y el número de estimadores) para optimizar su rendimiento en la clasificación de la enfermedad del fríjol.

5.4.3. Aprendizaje Profundo (DL)

Este enfoque representa el estado del arte en clasificación de imágenes y tiene la ventaja de aprender automáticamente las características relevantes directamente de los datos, eliminando la necesidad de la ingeniería de características manual.

- **Modelo 4: Red Neuronal Convolutiva 3D (3D-CNN):** Los datos hiperespectrales son inherentemente tridimensionales (2 dimensiones espaciales, 1 dimensión espectral). Una 3D-CNN es la arquitectura natural para procesar este tipo de datos. Utiliza núcleos convolutivos 3D que se deslizan tanto en el espacio como en el espectro, lo que permite el aprendizaje simultáneo, y combinado de características espaciales y características espectrales. Este enfoque integrado es conceptualmente más potente que las 2D-CNN, que tratan las bandas espectrales como canales separados, o las 1D-CNN, que ignoran por completo el contexto espacial.

La entrada al modelo consistirá en pequeños parches 3D (por ejemplo, de tamaño 16×16 píxeles por todas las bandas espectrales) extraídos de la imagen hiperespectral, centrados en cada píxel a clasificar. La arquitectura constará de varias capas convolutivas 3D, seguidas de capas de agrupación (pooling) para reducir la dimensionalidad y, finalmente, capas totalmente conectadas (fully connected) para la clasificación final. El modelo se entrenará de extremo a extremo (end-to-end).

5.4.4. Enfoques de vanguardia para la clasificación de imágenes hiperespectrales

Como alternativa extra, se considera la implementación de metodologías de vanguardia que permitan evaluar el desempeño de los 2 enfoques previamente mencionados contra el estado del arte y las tendencias actuales. La necesidad de implementar o no dichas estrategias estará precedida por la evaluación de los 2 enfoques anteriores.

- **Modelo 5 (Opcional): Clasificación Semi-Supervisada con CRNN:** Basándose en la estrategia de pseudo-etiquetado (Sección 5.2), se puede explorar una Red Neuronal Convolutiva Recurrente (CRNN). Este modelo híbrido utiliza primero capas convolutivas para extraer características espaciales de los parches de imagen y luego alimenta la secuencia de características resultante a una red recurrente (como LSTM o GRU) que procesa la dimensión espectral como una secuencia. Esto modela explícitamente la naturaleza secuencial y las dependencias entre las bandas espectrales adyacentes, lo que puede ser beneficioso para capturar firmas espectrales complejas.
- **Modelo 6 (Opcional): Clasificación Basada en Redes Neuronales de Grafos (GNN):** Partiendo de la segmentación por superpíxeles (Sección 5.3.4), se puede aplicar una Red Neuronal de Grafos (GNN), como una Red Convolutiva de Grafos (GCN). En este enfoque, la imagen se representa como un grafo donde los superpíxeles son los nodos y la adyacencia define las aristas. La GCN aprende a clasificar cada nodo (superpíxel)

agregando información de sus vecinos, modelando eficazmente el contexto espacial y la posible propagación de la enfermedad a través de la superficie de la hoja.

5.5. Evaluación del modelo, validación y análisis comparativo

La fase final del proyecto implica la evaluación rigurosa de los modelos entrenados para cuantificar su rendimiento de manera objetiva y seleccionar el enfoque más adecuado para la tarea de detección de enfermedades en el fríjol.

5.5.1. Métricas de Evaluación de Desempeño

Para proporcionar una evaluación completa y matizada del rendimiento de la clasificación, se utilizará un conjunto estándar de métricas, cada una de las cuales ofrece una perspectiva diferente sobre el éxito del modelo:

- **Matriz de Confusión:** Una tabla que visualiza el rendimiento del clasificador. Permite una inspección detallada de los errores, mostrando qué clases se confunden entre sí (por ejemplo, si la etapa temprana de la enfermedad se confunde con plantas sanas).
- **Exactitud Global (Overall Accuracy - OA):** La proporción de píxeles clasificados correctamente sobre el total de píxeles. Es una métrica general útil, pero puede ser engañosa en conjuntos de datos desequilibrados.
- **Precisión, Recall y Puntuación F1 (Precision, Recall, F1-Score):** Estas métricas se calcularán por clase para evaluar el rendimiento en clases mayoritarias y minoritarias, lo cual es especialmente importante para las clases positivas ya que busca aumentar la confiabilidad en que la planta (o píxeles) seleccionadas poseen efectivamente un estrés en la cantidad de fósforo.
 - **Precisión:** De todos los píxeles clasificados como una clase, ¿cuántos eran realmente de esa clase?
 - **Recall (Sensibilidad):** De todos los píxeles que realmente pertenecen a una clase, ¿cuántos fueron clasificados correctamente?
 - **Puntuación F1:** La media armónica de la precisión y el recall, proporcionando una única medida de rendimiento por clase.
- **Coefficiente Kappa:** Una medida estadística de concordancia que tiene en cuenta la posibilidad de que la clasificación correcta ocurra por azar. Proporciona una medida más robusta que la exactitud global en conjuntos de datos multiclase.

5.5.2. Proceso de evaluación

Para garantizar que los resultados del modelo sean fiables y generalizables, se seguirá el siguiente proceso de evaluación:

- **División de Datos:** El conjunto de datos completo se dividirá en tres subconjuntos independientes y mutuamente excluyentes: **Entrenamiento** (por ejemplo, 70%), **Validación** (por ejemplo, 15%) y **Prueba** (por ejemplo, 15%). El conjunto de entrenamiento se utiliza para ajustar los pesos del modelo, el conjunto de validación se utiliza para el ajuste de hiperparámetros (por ejemplo, la tasa de aprendizaje, el número de capas), y el conjunto de prueba se mantiene completamente al margen hasta el final.
- **Validación Cruzada (k-fold Cross-Validation):** Para asegurar que el modelo no es sensible a la división particular de entrenamiento/validación y para obtener una estimación más robusta

del rendimiento durante el ajuste de hiperparámetros, se realizará una validación cruzada de k-pliegues (por ejemplo, $k=5$ o $k=10$) en el conjunto de entrenamiento.

- **Prueba Final:** Los modelos finales, con sus hiperparámetros ya optimizados, se evaluarán una única vez en el conjunto de prueba que no se ha utilizado. Los resultados obtenidos en este conjunto de prueba serán los que se reporten como el rendimiento final e imparcial de los modelos.

5.5.3. Análisis comparativo y selección final del modelo

Se llevará a cabo una comparación sistemática de los resultados obtenidos por los modelos SVM, RF, XGBoost y 3D-CNN (opcionalmente las redes CRN y GRNN), basándose en las métricas definidas en la sección 5.5.1.

El análisis no se centrará únicamente en qué modelo logró la mayor exactitud, sino también en las compensaciones entre rendimiento, complejidad computacional e interpretabilidad. Por ejemplo, aunque se espera que la 3D-CNN tenga el mejor rendimiento, modelos como RF o XGBoost podrían proporcionar información valiosa sobre qué bandas espectrales son más importantes para la detección de la enfermedad, lo que tiene un valor científico y práctico significativo.

6. ALCANCES DEL TRABAJO

Objetivo 1: Establecer una base de datos hiperespectrales etiquetados y organizados para el entrenamiento de modelos de inteligencia artificial que permitan el diagnóstico del estado de salud de cultivos de frijol común

La base de datos contendrá los cubos de datos hiperespectrales de las plantas de frijol y sus etiquetas correspondientes, principalmente para la clasificación binaria de sano (clase 0) y enfermo por estrés nutricional de fósforo (clase 1). Estará organizada de forma lógica para facilitar su uso en el entrenamiento y validación de los modelos de inteligencia artificial. Las etiquetas estarán dadas según los resultados obtenidos durante el proceso comparativo entre el etiquetado manual y el pseudo-etiquetado mencionados en la sección 5.2

La base de datos estará disponible como parte del repositorio final del proyecto, con una estructura de carpetas clara y un archivo README.md que documente su contenido y formato.

Objetivo 2: Caracterizar la huella hiperespectral de frijol común para facilitar el diagnóstico del estado de salud de un cultivo

A lo largo del proyecto se desarrollará un análisis documentado de la firma espectral del frijol común bajo condiciones de salud y de estrés por deficiencia de fósforo. Se identificarán las bandas y características espectrales más informativas que permitan diferenciar entre los dos estados de la planta. Este análisis se basará en las técnicas de extracción y selección de características descritas en la metodología, como PCA, Random Forest y el Algoritmo de Proyecciones Sucesivas (SPA).

Se dispondrá de un capítulo o sección en el documento final del trabajo de grado que presente los resultados del análisis, incluyendo gráficos de las firmas espectrales promedio, mapas de calor de correlación y tablas que listen las bandas espectrales más relevantes para la clasificación.

Objetivo 3: Seleccionar un modelo de inteligencia artificial supervisado para el diagnóstico del estado de salud de plantas de frijol común desde huellas hiperespectrales, basados en el estrés de fósforo al cual se encuentran sometidas las plantas.

Se seleccionará un modelo de inteligencia artificial supervisado, entrenado y validado, seleccionado como el de mejor rendimiento para el diagnóstico del estado de salud de las plantas de frijol. El producto principal será un modelo capaz de realizar la clasificación binaria (sano vs. enfermo por estrés de fósforo). La selección se basará en una evaluación comparativa rigurosa de los modelos propuestos en la metodología (SVM, RF, XGBoost, 3D-CNN). La exploración de arquitecturas más avanzadas como CRNN y GNN será opcional y dependerá de la viabilidad y los resultados obtenidos en las fases previas.

El código fuente del modelo seleccionado, junto con sus pesos entrenados (en caso de seleccionar una red neuronal), estará disponible en el repositorio de GitHub. Se adjuntará una sección de rendimiento que detallará las métricas de exactitud global (OA), coeficiente Kappa, precisión, recall y F1-Score sobre el conjunto de prueba, validando su capacidad predictiva.

Limitaciones del Alcance

Para definir claramente las fronteras de este proyecto, se establecen las siguientes limitaciones:

- No se realizarán correcciones sobre los datos entregados, dado que estos ya han sido procesados y corregidos previamente.
- El objetivo principal es la clasificación binaria. Aunque se podrá explorar la viabilidad de modelos multiclase para determinar niveles de fósforo, el proyecto no se compromete a desarrollar la metodología para modelos multiclase; esto queda como una línea de trabajo futuro.
- El entregable final del proyecto consiste en un repositorio de GitHub que contiene el código desarrollado para el entrenamiento y validación del mejor modelo encontrado para la clasificación binaria.
- Está fuera del alcance de este proyecto entregar un flujo de trabajo de carácter industrial. El proyecto se limita meramente a la investigación y a la búsqueda del mejor modelo posible para la clasificación del estrés nutricional por fósforo.

7. PLAN DE TEMAS Y CRONOGRAMA

Actividades	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6
Etiquetamiento de las imágenes						
Segmentación de la imagen						
Entrenamiento de modelos						
Evaluación y comparación						
Escritura documento final						

8. BIBLIOGRAFÍA Y FUENTES DE INFORMACIÓN

- Acevedo Pérez, Y. T., & Zuluaga Sánchez, G. P. (2021). Custodios de variedades de frijol (*Phaseolus lunatus*, *P. coccineus*, *P. vulgaris*) y prácticas de conservación en Antioquia, Colombia. *Sociedad y Ambiente*, 24, 1–28. <https://doi.org/10.31840/sya.vi24.2230>
- Adão, T., Hruška, J., Pádua, L., Bessa, J., Peres, E., Morais, R., & Sousa, J. J. (2017). Hyperspectral imaging: A review on UAV-based sensors, data processing and applications for agriculture and forestry. *Remote Sensing*, 9(11). <https://doi.org/10.3390/RS9111110>
- Agencia UNAL. (2022, October 20). *Agricultura de precisión, más eficiente y amigable con el campo*. <https://agenciadenoticias.unal.edu.co/detalle/agricultura-de-precision-mas-eficiente-y-amigable-con-el-campo>
- Agronegocios. (2025, February 12). *Informe del Dane revela que Colombia tiene una población campesina de 11,3 millones* | *Agronegocios.co*. <https://www.agronegocios.co/agricultura/informe-del-dane-revela-que-colombia-tiene-una-poblacion-campesina-de-11-337-personas-4061154>
- Allu, A. R., & Mesapam, S. (2025). Impact of remote sensing data fusion on agriculture applications: A review. *European Journal of Agronomy*, 164, 127478. <https://doi.org/10.1016/J.EJA.2024.127478>
- Añazco, C., Ojeda, P. G., & Guerrero-Wyss, M. (2023). Common Beans as a Source of Amino Acids and Cofactors for Collagen Biosynthesis. In *Nutrients* (Vol. 15, Issue 21, pp. 45–61). Multidisciplinary Digital Publishing Institute (MDPI). <https://doi.org/10.3390/nu15214561>
- Bal, F., & Kayaalp, F. (2021). Review of machine learning and deep learning models in agriculture. *International Advanced Researches and Engineering Journal*, 5(2), 309–323. <https://doi.org/10.35860/iarej.848458>
- Bandos, T. V., Bruzzone, L., & Camps-Valls, G. (2009a). Classification of hyperspectral images with regularized linear discriminant analysis. *IEEE Transactions on Geoscience and Remote Sensing*, 47(3), 862–873. <https://doi.org/10.1109/TGRS.2008.2005729>
- Bandos, T. V., Bruzzone, L., & Camps-Valls, G. (2009b). Classification of hyperspectral images with regularized linear discriminant analysis. *IEEE Transactions on Geoscience and Remote Sensing*, 47(3), 862–873. <https://doi.org/10.1109/TGRS.2008.2005729>
- Barbosa Duran, W. A. (2022). The Gap in Access to Information and Communication Technologies in Rural Colombia. *International Journal of Advanced Research in Science, Communication and Technology*, 513–515. <https://doi.org/10.48175/ijarsct-5713>
- Benos, L., Tagarakis, A. C., Dolias, G., Berruto, R., Kateris, D., & Bochtis, D. (2021). Machine learning in agriculture: A comprehensive updated review. *Sensors*, 21(11). <https://doi.org/10.3390/s21113758>
- Bera, S., Shrivastava, V. K., & Satapathy, S. C. (2022). Advances in Hyperspectral Image Classification Based on Convolutional Neural Networks: A Review. In *CMES - Computer Modeling in Engineering and Sciences* (Vol. 133, Issue 2, pp. 219–250). Tech Science Press. <https://doi.org/10.32604/cmes.2022.020601>
- Bhargava, A., Sachdeva, A., Sharma, K., Alsharif, M. H., Uthansakul, P., & Uthansakul, M. (2024). Hyperspectral imaging and its applications: A review. In *Heliyon* (Vol. 10, Issue 12). Elsevier Ltd. <https://doi.org/10.1016/j.heliyon.2024.e33208>

- Cheng, M.-F., Mukundan, A., Karmakar, R., Valappil, M. A. E., Jouhar, J., & Wang, H.-C. (2025). Modern Trends and Recent Applications of Hyperspectral Imaging: A Review. *Technologies*, 13(5), 170. <https://doi.org/10.3390/technologies13050170>
- Corrales, D. C., Peña, A. J., León, C., Figueroa, A., & Carlos Corrales, J. (2014). Early warning system for coffee rust disease based on error correcting output codes: a proposal. *Revista Ingenierías Universidad de Medellín*, 13, 57–64. http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S1692-33242014000200005&lng=en&nrm=iso
- Cui, Y., Ji, X., Wang, H., Xu, K., Wu, S., & Wang, L. (2019). A new framework for hyperspectral image classification using multiple semisupervised collaborative classification algorithm. *IEEE Access*, 7, 125155–125175. <https://doi.org/10.1109/ACCESS.2019.2933589>
- DANE. (2018). *info-CNPC-2018total-nal-colombia*. <https://www.dane.gov.co/files/censo2018/infografias/info-CNPC-2018total-nal-colombia.pdf>
- DANE. (2024, December). *DANE - Históricos Producto Interno Bruto -PIB-*. <https://www.dane.gov.co/index.php/estadisticas-por-tema/cuentas-nacionales/cuentas-nacionales-trimestrales/historicos-producto-interno-bruto-pib>
- DANE. (2025). *DANE - Exportaciones Históricas*. <https://www.dane.gov.co/index.php/estadisticas-por-tema/comercio-internacional/exportaciones/exportaciones-historicos>
- Debnath, J., Kumar, K., Roy, K., Choudhury, R. D., & U, A. K. P. (2024). Precision Agriculture: A Review of AI Vision and Machine Learning in Soil, Water, and Conservation Practice. *International Journal for Research in Applied Science and Engineering Technology*, 12(12), 2130–2141. <https://doi.org/10.22214/ijraset.2024.66166>
- Diao, Z., Chen, L., Yang, Y., Liu, Y., Yan, J., He, S., & Zhang, B. (2025). Localization technologies for smart agriculture and precision farming: A review. In *Computers and Electronics in Agriculture* (Vol. 236). Elsevier B.V. <https://doi.org/10.1016/j.compag.2025.110464>
- Dong, W., Zhou, C., Wu, F., Wu, J., Shi, G., & Li, X. (2021). Model-Guided Deep Hyperspectral Image Super-Resolution. *IEEE Transactions on Image Processing*, 30, 5754–5768. <https://doi.org/10.1109/TIP.2021.3078058>
- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2020). *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*. <http://arxiv.org/abs/2010.11929>
- Gao, K., Liu, B., Yu, X., Qin, J., Zhang, P., & Tan, X. (2020). Deep relation network for hyperspectral image few-shot classification. *Remote Sensing*, 12(6). <https://doi.org/10.3390/rs12060923>
- Gao, Y., Xu, D., Ren, H., Shang, Q., Wang, F., Jiang, C., & Huang, W. (2016). Effects of Water and Fertilization Treatments on Water Consumption and Yield of Common Bean. *Crops*, 32(6), 124–127. <https://doi.org/10.16035/J.ISSN.1001-7283.2016.06.021>
- González Santiago, J., Schenkel, F., Gross, W., & Middelmann, W. (2020). An unsupervised labeling approach for hyperspectral image classification. *International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences - ISPRS Archives*, 43(B3), 407–415. <https://doi.org/10.5194/isprs-archives-XLIII-B3-2020-407-2020>

- Goodfellow, I. J., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). Generative Adversarial Nets. *Proceedings of the 27th International Conference on Neural Information Processing Systems*, 2, 2672–2680. <https://doi.org/10.5555/2969033.2969125>
- Gori, M., Monfardini, G., & Scarselli, F. (2005, August 4). A New Model for learning in graph Domains. *Proceedings. 2005 IEEE International Joint Conference on Neural Networks, 2005*. <https://doi.org/10.1109/IJCNN.2005.1555942>
- Goyal, R., Singha, P., & Singh, S. K. (2024). Spectroscopic food adulteration detection using machine learning: Current challenges and future prospects. *Trends in Food Science and Technology*, 146. <https://doi.org/10.1016/J.TIFS.2024.104377>
- Gu, A., & Dao, T. (2023). *Mamba: Linear-Time Sequence Modeling with Selective State Spaces*. <https://arxiv.org/pdf/2312.00752>
- Ham, J. S., Chen, Y., Crawford, M. M., & Ghosh, J. (2005). Investigation of the random forest framework for classification of hyperspectral data. *IEEE Transactions on Geoscience and Remote Sensing*, 43(3), 492–501. <https://doi.org/10.1109/TGRS.2004.842481>
- Hamilton, W. L., Ying, R., & Leskovec, J. (2017). Inductive Representation Learning on Large Graphs. In *Advances in Neural Information Processing Systems* (Vol. 30). Curran Associates, Inc. https://papers.nips.cc/paper_files/paper/2017/hash/5dd9db5e033da9c6fb5ba83c7a7e9a9-Abstract.html
- Hong, D., Liu, W., Su, J., Pan, Z., & Wang, G. (2015). A novel hierarchical approach for multispectral palmprint recognition. *Neurocomputing*, 151(P1), 511–521. <https://doi.org/10.1016/j.neucom.2014.09.013>
- Huang, Y., CHEN, Z. xin, YU, T., HUANG, X. zhi, & GU, X. fa. (2018). Agricultural remote sensing big data: Management and applications. *Journal of Integrative Agriculture*, 17(9), 1915–1931. [https://doi.org/10.1016/S2095-3119\(17\)61859-8](https://doi.org/10.1016/S2095-3119(17)61859-8)
- Hughes, G. (1968). On the mean accuracy of statistical pattern recognizers. *IEEE Transactions on Information Theory*, 14(1), 55–63. <https://doi.org/10.1109/TIT.1968.1054102>
- Jaramillo, S., & Jaramillo-Jiménez Alexander. (2025). Nuevas variedades de frijol arbustivo biofortificado adaptadas al sistema intercalado con café. *Avances Técnicos Cenicafe*, 571, 1–8. <https://doi.org/10.38141/10779/0571>
- Kganyago, M., Adjorlolo, C., Mhangara, P., & Tsoeleng, L. (2024). Optical remote sensing of crop biophysical and biochemical parameters: An overview of advances in sensor technologies and machine learning algorithms for precision agriculture. *Computers and Electronics in Agriculture*, 218. <https://doi.org/10.1016/J.COMPAG.2024.108730>
- Khanal, S., Kushal, K. C., Fulton, J. P., Shearer, S., & Ozkan, E. (2020). Remote sensing in agriculture—accomplishments, limitations, and opportunities. *Remote Sensing*, 12(22), 1–29. <https://doi.org/10.3390/RS12223783>
- Kim, Y., Glenn, D. M., Park, J., Ngugi, H. K., & Lehman, B. L. (2011). Hyperspectral image analysis for water stress detection of apple trees. *Computers and Electronics in Agriculture*, 77(2), 155–160. <https://doi.org/10.1016/J.COMPAG.2011.04.008>
- Krishna, G., Sahoo, R. N., Singh, P., Bajpai, V., Patra, H., Kumar, S., Dandapani, R., Gupta, V. K., Viswanathan, C., Ahmad, T., & Sahoo, P. M. (2019). Comparison of various modelling approaches for water deficit stress monitoring in rice crop through hyperspectral remote sensing. *Agricultural Water Management*, 213, 231–244. <https://doi.org/10.1016/J.AGWAT.2018.08.029>

- Kushwaha, M., Singh, S., Singh, V., & Dwivedi, S. (2024). Precision Farming: A Review of Methods, Technologies, and Future Prospects. *International Journal of Environment, Agriculture and Biotechnology*, 9(2). <https://doi.org/10.22161/ijeab>
- Lamos-Díaz, H., Puentes-Garzón, D. E., & Zarate-Caicedo, D. A. (2020). Comparison Between Machine Learning Models for Yield Forecast in Cocoa Crops in Santander, Colombia. *Revista Facultad de Ingeniería*, 29(54), e10853. <https://doi.org/10.19053/01211129.v29.n54.2020.10853>
- Li, N., Huo, L., & Zhang, X. (2024). Using only the red-edge bands is sufficient to detect tree stress: A case study on the early detection of PWD using hyperspectral drone images. *Computers and Electronics in Agriculture*, 217. <https://doi.org/10.1016/J.COMPAG.2024.108665>
- Li, S., Song, W., Fang, L., Chen, Y., Ghamisi, P., & Benediktsson, J. A. (2019). Deep learning for hyperspectral image classification: An overview. *IEEE Transactions on Geoscience and Remote Sensing*, 57(9), 6690–6709. <https://doi.org/10.1109/TGRS.2019.2907932>
- Li, Y., Tarlow, D., Brockschmidt, M., & Zemel, R. (2015). *Gated Graph Sequence Neural Networks*. <https://doi.org/10.48550/arXiv.1511.05493>
- Li, Z., Xu, D., & Guo, X. (2014). Remote sensing of ecosystem health: Opportunities, Challenges, and future perspectives. *Sensors (Switzerland)*, 14(11), 21117–21139. <https://doi.org/10.3390/S141121117>
- Liao, W., Pizurica, A., Philips, W., & Pi, Y. (2010, September 29). *A fast iterative kernel PCA feature extraction for hyperspectral images*. <https://doi.org/10.1109/ICIP.2010.5651670>
- Licciardi, G., Marpu, P. R., Chanussot, J., & Benediktsson, J. A. (2012). Linear versus nonlinear PCA for the classification of hyperspectral data based on the extended morphological profiles. *IEEE Geoscience and Remote Sensing Letters*, 9(3), 447–451. <https://doi.org/10.1109/LGRS.2011.2172185>
- Liu, J., Li, T., Zhao, F., & Liu, Y. (2024). Dual Graph Convolutional Network for Hyperspectral Images with Spatial Graph and Spectral Multigraph. *IEEE Geoscience and Remote Sensing Letters*, 21, 1–5. <https://doi.org/10.1109/LGRS.2024.3398439>
- Liu, Y., Luo, Y., Yu, R., Ren, L., Jiang, Q., He, S., Chen, X., & Yang, G. (2025). Combined Use of Spectral and Structural Features for Improved Early Detection of Pine Shoot Beetle Attacks in Yunnan Pines. *Remote Sensing*, 17(7). <https://doi.org/10.3390/RS17071109>
- Lowe, A., Harrison, N., & French, A. P. (2017). Hyperspectral image analysis techniques for the detection and classification of the early onset of plant disease and stress. In *Plant Methods* (Vol. 13, Issue 1). BioMed Central Ltd. <https://doi.org/10.1186/s13007-017-0233-z>
- Lu, B., Dao, P. D., Liu, J., He, Y., & Shang, J. (2020). Recent advances of hyperspectral imaging technology and applications in agriculture. In *Remote Sensing* (Vol. 12, Issue 16). MDPI AG. <https://doi.org/10.3390/RS12162659>
- Lunetta, R. S., Knight, J. F., Ediriwickrema, J., Lyon, J. G., & Worthy, L. D. (2006). Land-cover change detection using multi-temporal MODIS NDVI data. *Remote Sensing of Environment*. <https://doi.org/10.1016/j.rse.2006.06.018>
- Mahanto, S., Chattopadhyay, R., Kundu, S., & Kanthal, S. (2024). Precision farming: Innovations, techniques and sustainability. *International Journal of Agriculture Extension and Social Development*, 7(4), 42–47. <https://doi.org/10.33545/26180723.2024.v7.i4a.513>

- Marin, D. B., Ferraz, G. A. e. S., Santana, L. S., Barbosa, B. D. S., Barata, R. A. P., Osco, L. P., Ramos, A. P. M., & Guimarães, P. H. S. (2021). Detecting coffee leaf rust with UAV-based vegetation indices and decision tree machine learning models. *Computers and Electronics in Agriculture*, 190, 106476. <https://doi.org/10.1016/J.COMPAG.2021.106476>
- Martínez-Martínez, V., Gomez-Gil, J., Machado, M. L., & Pinto, F. A. C. (2018). Leaf and canopy reflectance spectrometry applied to the estimation of angular leaf spot disease severity of common bean crops. *PLOS ONE*, 13(4), e0196072. <https://doi.org/10.1371/JOURNAL.PONE.0196072>
- Martínez-Reina, A. M., Grandett-Martínez, L. M., Tordecilla-Zumaqué, L., Rodríguez-Pinto, M. D. V., Cordero-Cordero, C. C., & Tofiño-Rivera, A. P. (2021). Technological and socio-economic analysis of the local production system of the pink Zaragoza bean (*Phaseolus vulgaris* L.) in the Caribbean of Colombia. *Revista Colombiana de Ciencias Hortícolas*, 15(1). <https://doi.org/10.17584/rcch.2021v15i1.11520>
- Merchán Hernández, C. A. (2015). Sector rural colombiano: dinámica laboral y opciones de afiliación a la seguridad social. In *Coyuntura Económica: Vol. XLV* (Issue 2). Fedesarrollo.
- MinAgricultura. (2025, February 17). *El sector Agricultura, protagonista en 2024 de la reactivación económica del país*. <https://www.minagricultura.gov.co/noticias/Paginas/El-sector-Agricultura,-protagonista-en-2024-de-la-reactivaci%C3%B3n-econ%C3%B3mica-del-pa%C3%ADs.aspx>
- MinAgricultura, Colciencias, & Corpoica. (2016). *Plan Estratégico de Ciencia, Tecnología e Innovación del Sector Agropecuario Colombia (PECTIA)*. <https://minciencias.gov.co/sites/default/files/upload/noticias/pectia-2017-actualizado.pdf>
- MinTIC. (2015, August 31). *A través de las TIC, Gobierno impulsará proyectos para el agro colombiano*. <https://mintic.gov.co/portal/inicio/Sala-de-prensa/Noticias/12897:A-traves-de-las-TIC-Gobierno-impulsara-proyectos-para-el-agro-colombiano>
- Miras, J. A., González-Portillo, L. F., & Abbas, R. (2023). Analysis of the absorptance and emittance in particle curtains by means of a discrete MCRT method. *Results in Engineering*, 19. <https://doi.org/10.1016/j.rineng.2023.101241>
- Morchid, A., Marhoun, M., El Alami, R., & Boukili, B. (2024). Intelligent detection for sustainable agriculture: A review of IoT-based embedded systems, cloud platforms, DL, and ML for plant disease detection. *Multimedia Tools and Applications*, 83(28), 70961–71000. <https://doi.org/10.1007/S11042-024-18392-9>
- Motta, I. V. C., Vuillerme, N., Pham, H. H., & de Figueiredo, F. A. P. (2025). Machine learning techniques for coffee classification: a comprehensive review of scientific research. *Artificial Intelligence Review*, 58(1). <https://doi.org/10.1007/s10462-024-11004-w>
- Mou, L., Ghamisi, P., & Zhu, X. X. (2017). Deep recurrent neural networks for hyperspectral image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 55(7), 3639–3655. <https://doi.org/10.1109/TGRS.2016.2636241>
- Mou, L., Lu, X., Li, X., & Zhu, X. X. (2020). Nonlocal Graph Convolutional Networks for Hyperspectral Image Classification. *IEEE Transactions on Geoscience and Remote Sensing*, 58(12), 8246–8257. <https://doi.org/10.1109/TGRS.2020.2973363>
- NEO. (2025). *HySpex Mjolnir*. <https://www.hyspex.com/hyspex-products/hyspex-mjolnir/>
- Nogueira Martins, R., de Assis de Carvalho Pinto, F., Marçal de Queiroz, D., Sárvio Magalhães Valente, D., Tadeu Fim Rosas, J., Fagundes Portes, M., & Sânzio Aguiar Cerqueira, E. (2023). Digital mapping of coffee ripeness using UAV-based multispectral

- imagery. *Computers and Electronics in Agriculture*, 204, 107499.
<https://doi.org/10.1016/J.COMPAG.2022.107499>
- Omia, E., Bae, H., Park, E., Kim, M. S., Baek, I., Kabenge, I., & Cho, B. K. (2023). Remote Sensing in Field Crop Monitoring: A Comprehensive Review of Sensor Systems, Data Analyses and Recent Advances. In *Remote Sensing* (Vol. 15, Issue 2). MDPI.
<https://doi.org/10.3390/rs15020354>
- Pandey, P. C., & Pandey, M. (2023). Highlighting the role of agriculture and geospatial technology in food security and sustainable development goals. *Sustainable Development*, 31(5), 3175–3195. <https://doi.org/10.1002/SD.2600>
- Park, B., Windham, W. R., Lawrence, K. C., & Smith, D. P. (2007). Contaminant Classification of Poultry Hyperspectral Imagery using a Spectral Angle Mapper Algorithm. *Biosystems Engineering*, 96(3), 323–333.
<https://doi.org/10.1016/j.biosystemseng.2006.11.012>
- Patiluna, V., Owen, J., Maja, J. M., Neupane, J., Behmann, J., Bohnenkamp, D., Borra-Serrano, I., Peña, J. M., Robbins, J., & de Castro, A. (2025). Using Hyperspectral Imaging and Principal Component Analysis to Detect and Monitor Water Stress in Ornamental Plants. *Remote Sensing*, 17(2). <https://doi.org/10.3390/RS17020285>
- Pfordt, A., & Paulus, S. (2025). A review on detection and differentiation of maize diseases and pests by imaging sensors. *Journal of Plant Diseases and Protection*, 132(1).
<https://doi.org/10.1007/S41348-024-01019-4>
- Phuangsoambut, K., Ma, T., Inagaki, T., Tsuchikawa, S., & Terdwongworakul, A. (2018). Near-infrared hyperspectral imaging for classification of mung bean seeds. *International Journal of Food Properties*, 21(1), 799–807.
<https://doi.org/10.1080/10942912.2018.1476378>
- Prasad, S., & Bruce, L. M. (2008). Limitations of principal components analysis for hyperspectral target recognition. *IEEE Geoscience and Remote Sensing Letters*, 5(4), 625–629. <https://doi.org/10.1109/LGRS.2008.2001282>
- Ram, B. G., Oduor, P., Igathinathane, C., Howatt, K., & Sun, X. (2024). A systematic review of hyperspectral imaging in precision agriculture: Analysis of its current state and future prospects. *Computers and Electronics in Agriculture*, 222.
<https://doi.org/10.1016/J.COMPAG.2024.109037>
- Richter, R., Schlapfer, D., & Muller, A. (2011a). Operational atmospheric correction for imaging spectrometers accounting for the smile effect. *IEEE Transactions on Geoscience and Remote Sensing*, 49(5), 1772–1780.
<https://doi.org/10.1109/TGRS.2010.2089799>
- Richter, R., Schlapfer, D., & Muller, A. (2011b). Operational atmospheric correction for imaging spectrometers accounting for the smile effect. *IEEE Transactions on Geoscience and Remote Sensing*, 49(5), 1772–1780.
<https://doi.org/10.1109/TGRS.2010.2089799>
- Saini, A. K., Yadav, A. K., & Dhiraj. (2025). A Comprehensive review on technological breakthroughs in precision agriculture: IoT and emerging data analytics. *European Journal of Agronomy*, 163. <https://doi.org/10.1016/j.eja.2024.127440>
- Scarselli, F., Gori, M., Tsoi, A. C., Hagenbuchner, M., & Monfardini, G. (2008). The graph neural network model. *IEEE Transactions on Neural Networks*, 20(1), 61–80.
<https://doi.org/10.1109/TNN.2008.2005605>
- Scheibenreif, L., Mommert, M., & Borth, D. (2023). Masked Vision Transformers for Hyperspectral Image Classification. *IEEE Computer Society Conference on Computer*

- Vision and Pattern Recognition Workshops, 2023-June*, 2166–2176.
<https://doi.org/10.1109/CVPRW59228.2023.00210>
- Sha, A., Wang, B., Wu, X., & Zhang, L. (2020). Semisupervised Classification for Hyperspectral Images Using Graph Attention Networks. *IEEE Geoscience and Remote Sensing Letters*, 18(1), 157–161. <https://doi.org/10.1109/LGRS.2020.2966239>
- Shahraki, F. F., & Prasad, S. (2018, November 28). Graph convolutional neural networks for hyperspectral data classification. *2018 IEEE Global Conference on Signal and Information Processing (GlobalSIP)*. <https://doi.org/10.1109/GlobalSIP.2018.8645969>
- Sheen, Y. J., Wang, H. C., Sung, C. C., Fu, Y. W., Pan, K. J., Chen, J. P., Hao, T. Te, & Chen, H. M. (2025). Advanced diabetic peripheral neuropathy detection: Validation of expert models and development of active short-wave infrared multispectral imaging techniques. *Expert Systems with Applications*, 269.
<https://doi.org/10.1016/J.ESWA.2025.126462>
- Sherkhane, P. D., & Ratnaparkhi, N. S. (2024). Deep Learning Techniques Used in Agriculture: A Review. *International Journal for Research in Applied Science and Engineering Technology*, 12(3), 1–5. <https://doi.org/10.22214/ijraset.2024.58567>
- Sishodia, R. P., Ray, R. L., & Singh, S. K. (2020). Applications of remote sensing in precision agriculture: A review. *Remote Sensing*, 12(19), 1–31.
<https://doi.org/10.3390/RS12193136>
- Suarez, J. A. H., Trujillo, J. L. A., & Perez-Ruiz, A. (2023). Research on the methods used for the detection of rust in coffee crops in different parts of the world. *AmITIC 2023 - 6th Congreso Internacional En Inteligencia Ambiental, Ingenieria de Software y Salud Electronica y Movil*. <https://doi.org/10.1109/AMITIC60194.2023.10366355>
- Sun, J., Jiang, S., Mao, H., Wu, X., & Li, Q. (2015). Classification of black beans using visible and near infrared hyperspectral imaging. *International Journal of Food Properties*, 19(8), 1687–1695. <https://doi.org/10.1080/10942912.2015.1055760>
- Talero-Sarmiento, L., Roa-Prada, S., Caicedo-Chacon, L., & Gavanzo-Cardenas, O. (2025). A Data-Driven Approach to Improve Cocoa Crop Establishment in Colombia: Insights and Agricultural Practice Recommendations from an Ensemble Machine Learning Model. *AgriEngineering*, 7(1). <https://doi.org/10.3390/agriengineering7010006>
- Tan, K., Wang, H., Chen, L., Du, Q., Du, P., & Pan, C. (2020). Estimation of the spatial distribution of heavy metal in agricultural soils using airborne hyperspectral imaging and random forest. *Journal of Hazardous Materials*, 382.
<https://doi.org/10.1016/J.JHAZMAT.2019.120987>
- Tang, X., Kuang, F., Fu, G., Yan, L., Huang, Q., Wang, X., Wang, B., & Ou, Q. (2024). Hyperspectral estimation for nitrogen and phosphorus content in Camellia oleifera leaves based on machine learning algorithms. *Journal of Applied Remote Sensing*, 18(03).
<https://doi.org/10.1117/1.JRS.18.038502>
- Tejasree, G., & Agilandeswari, L. (2024). An extensive review of hyperspectral image classification and prediction: techniques and challenges. *Multimedia Tools and Applications*. <https://doi.org/10.1007/s11042-024-18562-9>
- Tian, C., Chen, Y., Liu, Y., Wang, X., Lv, Q., Li, Y., Deng, J., Liu, Y., & Li, W. (2024). Accurate classification of glomerular diseases by hyperspectral imaging and transformer. *Computer Methods and Programs in Biomedicine*, 254.
<https://doi.org/10.1016/J.CMPB.2024.108285>
- Tuesta-Monteza, V. A., Mejia-Cabrera, H. I., & Arcila-Diaz, J. (2023). CoLeaf-DB: Peruvian coffee leaf images dataset for coffee leaf nutritional deficiencies detection and classification. *Data in Brief*, 48, 109226. <https://doi.org/10.1016/J.DIB.2023.109226>

- Vaswani, A., Brain, G., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). *Attention Is All You Need*.
- Villa, A., Benediktsson, J. A., Chanussot, J., & Jutten, C. (2011). Hyperspectral image classification with Independent component discriminant analysis. *IEEE Transactions on Geoscience and Remote Sensing*, 49(12 PART 1), 4865–4876. <https://doi.org/10.1109/TGRS.2011.2153861>
- Wang, C., Liu, B., Liu, L., Zhu, Y., Hou, J., Liu, P., & Li, X. (2021). A review of deep learning used in the hyperspectral image analysis for agriculture. *Artificial Intelligence Review*, 54(7), 5205–5253. <https://doi.org/10.1007/s10462-021-10018-y>
- Wang, H., Wang, J., Wang, J., Zhao, M., Zhang, W., Zhang, F., Xie, X., & Guo, M. (2018). GraphGAN: Graph Representation Learning with Generative Adversarial Nets. *The 32nd AAAI Conference on Artificial Intelligence (AAAI 2018)*. <https://arxiv.org/abs/1711.08267>
- Wang, H., & Wang, L. (2025). Masked vision transformer for hyperspectral image classification. <https://doi.org/10.1117/12.3066060>, 13634, 1363402. <https://doi.org/10.1117/12.3066060>
- Wang, Y., Sun, Y., Cao, X., Wang, Y., Zhang, W., & Cheng, X. (2023). A review of regional and Global scale Land Use/Land Cover (LULC) mapping products generated from satellite remote sensing. *ISPRS Journal of Photogrammetry and Remote Sensing*, 206, 311–334. <https://doi.org/10.1016/J.ISPRSJPRS.2023.11.014>
- Wu, H., & Prasad, S. (2018). Semi-Supervised Deep Learning Using Pseudo Labels for Hyperspectral Image Classification. *IEEE Transactions on Image Processing*, 27(3), 1259–1270. <https://doi.org/10.1109/TIP.2017.2772836>
- Xu, J., Li, K., Li, Z., Chong, Q., Xing, H., Xing, Q., & Ni, M. (2024). Fuzzy graph convolutional network for hyperspectral image classification. *Engineering Applications of Artificial Intelligence*, 127, 107280. <https://doi.org/10.1016/J.ENGAPPAI.2023.107280>
- Xu, Y., Du, B., Zhang, L., Cerra, D., Pato, M., Carmona, E., Prasad, S., Yokoya, N., Hansch, R., & Le Saux, B. (2019). Advanced multi-sensor optical remote sensing for urban land use and land cover classification: Outcome of the 2018 ieee grss data fusion contest. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 12(6), 1709–1724. <https://doi.org/10.1109/JSTARS.2019.2911113>
- Xu, Y., Wang, D., Zhang, L., & Zhang, L. (2024). *Dual Selective Fusion Transformer Network for Hyperspectral Image Classification*. <http://arxiv.org/abs/2410.03171>
- Yan, Y., Zhao, Y., Xue, H., Kou, X., & Liu, Y. (2010, August 31). Integration of spatial-spectral information for Hyperspectral image classification. *2010 Second IITA International Conference on Geoscience and Remote Sensing*. <https://doi.org/10.1109/IITA-GRS.2010.5603229>
- Yang, A., Li, M., Ding, Y., Hong, D., Lv, Y., & He, Y. (2023). GTFN: GCN and Transformer Fusion Network With Spatial-Spectral Features for Hyperspectral Image Classification. *IEEE Transactions on Geoscience and Remote Sensing*, 61. <https://doi.org/10.1109/TGRS.2023.3314616>
- Yang, P., Tong, L., Qian, B., Gao, Z., Yu, J., & Xiao, C. (2020). Hyperspectral Image Classification with Spectral and Spatial Graph Using Inductive Representation Learning Network. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 14, 791–800. <https://doi.org/10.1109/JSTARS.2020.3042959>



- Yel, S. G., & Tunc Gormus, E. (2023). Exploiting hyperspectral and multispectral images in the detection of tree species: A review. In *Frontiers in Remote Sensing* (Vol. 4). Frontiers Media SA. <https://doi.org/10.3389/frsen.2023.1136289>
- Youssef, A., Moa, B., & El-Sharkawy, Y. H. (2024). A novel visible and near-infrared hyperspectral imaging platform for automated breast-cancer detection. *Photodiagnosis and Photodynamic Therapy*, 46. <https://doi.org/10.1016/J.PDPDT.2024.104048>
- Zhang, J., Huang, Y., Pu, R., Gonzalez-Moreno, P., Yuan, L., Wu, K., & Huang, W. (2019). Monitoring plant diseases and pests through remote sensing technology: A review. In *Computers and Electronics in Agriculture* (Vol. 165). Elsevier B.V. <https://doi.org/10.1016/j.compag.2019.104943>
- Zhang, Y., Guan, M., Wang, L., Cui, X., Li, T., & Zhang, F. (2024). In Situ Nondestructive Detection of Nitrogen Content in Soybean Leaves Based on Hyperspectral Imaging Technology. *Agronomy*, 14(4). <https://doi.org/10.3390/AGRONOMY14040806>
- Zhang, Z., & Zhu, L. (2023). A Review on Unmanned Aerial Vehicle Remote Sensing: Platforms, Sensors, Data Processing Methods, and Applications. *Drones*, 7(6). <https://doi.org/10.3390/DRONES7060398>
- Zhao, X., Ma, J., Wang, L., Zhang, Z., Ding, Y., & Xiao, X. (2025). A review of hyperspectral image classification based on graph neural networks. *Artificial Intelligence Review*, 58(6). <https://doi.org/10.1007/s10462-025-11169-y>
- Zhong, P., Gong, Z., Li, S., & Schonlieb, C. B. (2017). Learning to Diversify Deep Belief Networks for Hyperspectral Image Classification. *IEEE Transactions on Geoscience and Remote Sensing*, 55(6), 3516–3530. <https://doi.org/10.1109/TGRS.2017.2675902>

Fecha de presentación: 2025-07-03

Nota: El profesor responsable debe ingresar en el SIA la calificación del proyecto o la propuesta.